Escuela de Ingeniería en Medioambiente

Ingeniería Ambiental

Facultad de Ingeniería

INTELIGENCIA ARTIFICIAL APLICADA AL APROVECHAMIENTO ENERGÉTICO, MEDIANTE DIGESTIÓN ANAEROBIA, DE RESIDUOS ORGÁNICOS DE LA INDUSTRIA CERVECERA.

TRABAJO DE TITULACIÓN PARA OPTAR AL TÍTULO DE INGENIERO AMBIENTAL

AUTOR: FRANCISCO ECCHIO GAETE

PROFESOR GUÍA: OCIEL COFRÉ CARVAJAL

VALPARAÍSO, 2025

RESUMEN

El presente estudio tuvo como objetivo desarrollar un modelo predictivo basado en técnicas de aprendizaje automático para estimar la producción de biogás a partir de residuos cerveceros mediante digestión anaerobia. Este proceso, si bien ampliamente utilizado para la valorización de residuos orgánicos, presenta importantes limitaciones asociadas a la complejidad de las interacciones entre variables operacionales y a su comportamiento no lineal, lo que dificulta su predicción y optimización mediante enfoques tradicionales.

Para abordar esta problemática, se construyó un dataset a partir de información experimental recopilada de literatura científica, considerando variables fisicoquímicas relevantes como sólidos totales (TS), sólidos volátiles (VS), relación carbono/nitrógeno (C/N), pH, temperatura, tiempo de retención hidráulica (HRT), entre otras. Posteriormente, se implementó un modelo de tipo Random Forest, el cual fue entrenado y validado para predecir tres variables de salida: producción total de biogás, porcentaje de remoción de sólidos volátiles (TVS) y porcentaje de metano (CH_4) en el biogás.

Los resultados obtenidos evidenciaron un buen desempeño del modelo en las tres variables evaluadas, alcanzando coeficientes de determinación (R^2) de 0,749 para la predicción de la producción de biogás, 0,669 para la remoción de TVS y 0,856 para el contenido de metano. Estos resultados indican una alta capacidad del modelo para capturar las relaciones complejas entre las variables del sistema, especialmente en la predicción del contenido de CH_4, que presentó el mejor desempeño global.

Adicionalmente, se aplicaron técnicas de interpretabilidad, como la importancia de variables y el análisis mediante SHAP, lo que permitió identificar los factores más influyentes en cada predicción y comprender cómo afectan los resultados del modelo. Esto aporta valor no solo desde el punto de vista predictivo, sino también como herramienta de apoyo para la toma de decisiones en la optimización de procesos de digestión anaerobia.

En conclusión, el uso de modelos de aprendizaje automático, y en particular Random Forest, demostró ser una herramienta eficaz para mejorar la predicción del rendimiento de sistemas de digestión anaerobia aplicados a residuos cerveceros, contribuyendo al desarrollo de soluciones más eficientes y sostenibles en el manejo de residuos orgánicos.

ÍNDICE

RESUMEN....2
1. INTRODUCCIÓN.... 13
1.1. RESIDUOS ORGÁNICOS Y CAMBIO CLIMÁTICO.... 13
1.2. INDUSTRIA CERVECERA: SUS RESIDUOS Y PROBLEMÁTICAS.... 14
1.3. BASES DE LA DIGESTIÓN ANAEROBIA COMO ALTERNATIVA DE VALORIZACIÓN ENERGÉTICA.... 17
1.4. INTELIGENCIA ARTIFICIAL COMO HERRAMIENTA EN LA TOMA DE DECISIONES PARA PROCESOS BIOTECNOLÓGICOS.... 19
2. PROBLEMA.... 21
3. OBJETIVOS DEL PROYECTO....22
3.1. OBJETIVO GENERAL.... 22
3.2. OBJETIVO ESPECÍFICO....22
4. REVISIÓN BIBLIOGRÁFICA.... 23
4.1. LA INDUSTRIA CERVECERA Y SUS RESIDUOS.... 23
4.1.1. Producción de residuos orgánicos en cervecerías de Chile y LATAM....23
4.1.2. Tipos y características de residuos generados....24
4.1.3. Problemáticas ambientales asociadas....24
4.2. DIGESTIÓN ANAEROBIA COMO ALTERNATIVA DE VALORIZACIÓN....25
4.2.1. Concepto y proceso básico....25
4.2.2. Aplicación a residuos cerveceros....25
4.2.3. Parámetros y condiciones críticas del proceso....26
4.2.3.1. pH....26
4.2.3.2. Temperatura....27
4.2.3.3. Tiempo de Retención Hidráulico (HRT)....27
4.2.3.4. Velocidad de Carga Orgánica (OLR).... 27
4.2.3.5. Relación C/N (Carbono/Nitrógeno).... 27
4.2.3.6. Agitación o mezcla....28
4.2.3.7. Tipo y calidad del inóculo....28
4.2.3.8. Ácidos Grasos Volátiles (VFA) y Alcalinidad....28
4.2.3.9. Otros factores....28
4.2.4. Ventajas....29
4.2.5. Desafíos técnicos....29
4.2.6. Estado actual y brecha en Chile y LATAM.... 29
4.3. APLICACIONES DE INTELIGENCIA ARTIFICIAL EN PROCESOS BIOTECNOLÓGICOS.... 30
4.4. BRECHAS Y DESAFÍOS EN CONTEXTOS DESCENTRALIZADOS.... 30
5. MATERIALES Y MÉTODOS....32
5.1. METODOLOGÍA PRIMER OBJETIVO ESPECÍFICO....32

5.1.1. Búsqueda y recopilación de bibliografía especializada.....32
5.1.2. Criterios de inclusión y exclusión de los estudios.....32
5.1.3. Organización y análisis cualitativo de la información.....33
5.2. METODOLOGÍA SEGUNDO OBJETIVO ESPECÍFICO.....33
5.2.1. Recolección de datos.....34
5.2.2. Selección y análisis exploratorio de variables.....35
5.2.3. Preprocesamiento de datos.....35
5.2.3.1. Recolección y organización preliminar.....36
5.2.3.2. Conversión a formato .csv.....36
5.2.3.3. Carga en el entorno de trabajo.....36
5.2.3.4. Estructura del conjunto de datos.....36
5.2.4. Verificación Inicial.....37
5.2.5. Unificación y almacenamiento.....38
5.2.6. Limpieza de datos.....38
5.2.6.1. Eliminación de datos duplicados.....39
5.2.6.2. Detección y tratamiento de valores extremos (outliers).....39
5.2.6.3. Corrección de errores de formato y codificación.....40
5.2.6.4. Verificación de inconsistencias internas.....40
5.2.7. Imputación de datos faltantes.....41
5.2.7.1. Identificación de datos faltantes.....41
5.2.7.2. Análisis del patrón de faltantes.....41
5.2.7.3. Estrategias de imputación utilizadas.....42
5.2.7.4. Documentación de las imputaciones.....42
5.2.8. Codificación de variables categóricas.....43
5.2.9. Normalización o estandarización.....43
5.2.10. Construcción de la inteligencia artificial.....45
5.2.10.1. Elección del algoritmo.....45
5.2.10.2. Importación de herramientas de la librería.....46
5.2.10.3. División del conjunto de datos.....47
5.2.10.3.1. Carga de datos.....48
5.2.10.3.2. Hold Out del 20%.....48
5.2.10.3.3. K-fold del 80%.....49
5.2.10.4. Prueba del modelo sobre Hold Out.....49
5.3. METODOLOGÍA TERCER OBJETIVO ESPECÍFICO.....50
5.3.1. Evaluación del modelo.....51
5.3.2. Explicación del modelo.....52
5.3.2.1. Análisis de importancia de características (Feature Importance).....52
5.3.2.2. SHAP (SHapley Additive exPlanations).....53
6. DESARROLLO DEL MODELO PREDICTIVO Y ANÁLISIS DE VARIABLES.....54
6.1. RELACIÓN GENERAL ENTRE VARIABLES Y LA PRODUCCIÓN DE BIOGÁS.....54
6.2. VARIABLES DE COMPOSICIÓN DEL SUSTRATO.....54

6.2.1. Bagazo Cervecero (Bagazo de Cerveza, BSG) – Residuos de Grano.....54
6.2.2. Lodo Cervecero (Biosólidos/Levadura Residual).....56
6.2.3. Agua Residual Cervecera (Aguamiel Cervecera)..... 58
6.3. PARÁMETROS FÍSICOS Y QUÍMICOS DEL SUSTRATO.....60
6.3.1. Sólidos Totales (TS%).....60
6.3.2. Sólidos Volátiles (VS% de TS)..... 60
6.3.3. Relación C/N del sustrato mixto.....61
6.3.4. Contenido de lignina y fibra.....61
6.3.5. pH inicial del sustrato..... 61
6.4. VARIABLES DE LAS CONDICIONES DEL PROCESO..... 63
6.4.1. Temperatura de Operación (Mesofílico vs Termofílico).....63
6.4.2. pH del Sistema y Alcalinidad.....65
6.4.3. Velocidad de Carga Orgánica (OLR) y Tiempo de Retención (HRT).....66
6.4.4. Agitación (Mixing) del Reactor..... 68
6.5. SELECCIÓN DE VARIABLES OBJETIVO (OUTPUTS) PARA EL MODELO PREDICTIVO..... 70
6.5.1. Producción total de biogás (m^3/kg VS).....71
6.5.2. Producción acumulada de metano (mL CH_4/g VS)..... 71
6.5.3. Contenido de metano en el biogás (% CH_4).....71
6.5.4. Tasa de producción de metano (mL/g VS·día).....71
6.5.5. Tiempo hasta el pico de producción.....72
6.5.6. Reducción de sólidos volátiles (VS).....72
6.5.7. Estabilidad del sistema (pH, VFA, alcalinidad).....72
6.6. Justificación del uso de aprendizaje automático en el presente estudio..... 75
6.7. Implementación del modelo Random Forest en el presente estudio.....75
6.7.1. Estructura del modelo aplicado.....75
6.7.2. Justificación de la elección del modelo Random Forest..... 76
6.8. Descripción del dataset y selección de variables.....76
6.9. Preprocesamiento de datos: normalización, codificación y manejo de variables categóricas.....79
6.10. Entrenamiento de modelos individuales por variable objetivo..... 81
6.11. Optimización de hiperparámetros mediante GridSearchCV..... 83
6.12. Evaluación del desempeño de los modelos: métricas de error y coeficiente R^2.....84
6.12.1. Métricas obtenidas..... 85
6.13. Interpretabilidad del modelo mediante SHAP..... 86
6.13.1. Visualizaciones SHAP utilizadas.....86
6.13.2. Principales hallazgos del análisis SHAP.....87
6.13.3. Relevancia de SHAP en el uso real del modelo..... 88
6.14. Implementación de una interfaz de usuario para el uso práctico del modelo..... 88
6.15. Limitaciones del modelo y consideraciones finales..... 90
6.15.1. Dependencia del modelo respecto al dataset disponible.....90

6.15.2. Limitaciones asociadas a la extrapolación de resultados..... 90
6.15.3. Simplificación de variables categóricas mediante agrupación..... 91
6.15.4. Naturaleza empírica del modelo frente a modelos mecanísticos..... 91
6.15.5. Sensibilidad a la calidad de los datos de entrada..... 91
6.15.6. Consideraciones finales sobre la aplicabilidad del modelo..... 92
7. RESULTADOS Y DISCUSIÓN..... 92
7.1.1. Producción total de biogás [mL/g VS]..... 93
7.1.2. Porcentaje de remoción de sólidos volátiles totales (% Remoción TVS)..... 94
7.1.3. Porcentaje de metano en el biogás (% CH_4)..... 95
Tabla 8.3: Métricas Modelo Optimizado - Porcentaje de remoción TVS..... 96
Fuente: Elaboración propia..... 96
7.1.4. Comparación global entre las tres variables de salida..... 97
7.2. Análisis de importancia de variables mediante SHAP..... 98
7.2.1. Interpretabilidad del modelo de producción total de biogás..... 98
7.2.1.1. Interpretación del SHAP Summary Plot..... 98
7.2.1.2. Interpretación del SHAP Bar Plot..... 100
7.2.1.3. Interpretación del SHAP Waterfall Plot..... 102
7.2.2. Interpretabilidad del modelo de Porcentaje de remoción TVS..... 104
7.2.2.1. Interpretación del summary plot..... 104
7.2.2.2. Análisis del bar plot de importancia media..... 106
7.2.2.3. Análisis del waterfall plot (ejemplo individual)..... 108
7.2.3. Interpretabilidad del modelo de Porcentaje de CH_4 en biogás..... 109
7.2.3.1. Interpretación del summary plot..... 109
7.2.3.2. Análisis del bar plot (importancia media absoluta)..... 111
7.2.3.3. Análisis del waterfall plot (explicación local de una predicción)..... 113
7.2.3.4. Sintesis interpretativa..... 114
7.2.4. Comparación de patrones de importancia entre modelos..... 114
7.3. Análisis de sensibilidad del modelo..... 116
7.3.1. Concepto de análisis de sensibilidad en modelos de ML..... 116
7.3.2. Sensibilidad del modelo de producción total de biogás..... 117
7.3.3. Sensibilidad del modelo de porcentaje de Remoción TVS..... 118
7.3.4. Sensibilidad del modelo de porcentaje de CH_4..... 119
7.3.5. Comparación de sensibilidad entre variables de salida..... 120
7.4. Discusión integrada de los resultados..... 121
8. CONCLUSIONES..... 124
8.1. Conclusión general..... 124
8.2. Cumplimiento de objetivos específicos..... 124
8.2.1. Objetivo específico 1: Identificar las variables más relevantes que influyen en la producción de biogás a partir de residuos cerveceros mediante digestión anaerobia.. 124
8.2.2. Objetivo específico 2: Desarrollar un modelo predictivo, basado en Random Forest, enfocado en el rendimiento de producción de biogás bajo distintas condiciones

del sustrato y del proceso..... 124
8.2.3. Objetivo específico 3: Realizar un análisis de sensibilidad del modelo desarrollado 125
9. BIBLIOGRAFÍA.....126

ÍNDICE DE FIGURAS

Figura 1.1: Emisiones globales de gases de efecto invernadero por tipo de gas (1850–2023)..... 17
Se incluyen todas las fuentes, considerando emisiones provenientes de la agricultura y el cambio en el uso del suelo. Las emisiones están expresadas en toneladas equivalentes de dióxido de carbono (CO_2-eq) utilizando un horizonte de 100 años..... 17
Figura 1.2: Evolución de la producción de cerveza en los últimos años..... 18
Figura 1.3: La curva de producción diaria de biogás en un digestor reiniciado muestra un aumento inicial en la producción seguido de una estabilización, lo cual es característico del proceso de digestión anaerobia..... 21
Figura 4.1: Etapas del proceso de digestión anaerobia..... 29
Figura 7.1: Summary Plot Producción total de Biogás..... 103
Figura 7.2: Bar Plot Producción total de Biogás..... 104
Figura 7.3: Waterfall Plot Producción total de Biogás..... 106
Figura 7.4: Summary Plot Porcentaje de remoción TVS..... 108
Figura 7.5: Bar Plot Porcentaje de remoción TVS..... 110
Figura 7.6: Waterfall Plot Porcentaje de remoción TVS..... 111
Figura 7.7: Summary Plot Porcentaje de remoción TVS..... 113
Figura 7.8: Bar Plot Porcentaje de remoción TVS..... 115
Figura 7.9: Waterfall Plot Porcentaje de remoción TVS..... 116

ÍNDICE DE TABLAS

Tabla 1.1: Proporciones aproximadas de algunos residuos generados en la industria cervecera...20
Tabla 5.1: Métricas utilizadas para la evaluación del modelo..... 55
Tabla 6.1: Resumen general de variables del sustrato..... 63
Tabla 6.2: Resumen general parámetros físico-químicos del sustrato..... 66
Tabla 6.3: Resumen general condiciones del proceso..... 72
Tabla 6.4: Resumen general de variables objetivos..... 76
Tabla 7.1: Métricas Modelo Optimizado - Producción total biogás..... 97
Tabla 7.2: Métricas Modelo Optimizado - Porcentaje de remoción TVS.....98
Tabla 7.3: Métricas Modelo Optimizado - Porcentaje de metano en biogás.....99

LISTADO DE ACRÓNIMOS, ABREVIATURAS Y SÍMBOLOS

AI: Artificial Intelligence, o Inteligencia Artificial. Rama de la informática que permite crear sistemas capaces de aprender, razonar y tomar decisiones de forma autónoma.

COD: Demanda Química de Oxígeno (Chemical Oxygen Demand). Indicador de la cantidad de materia orgánica presente en un residuo.

C/N: Relación Carbono/Nitrógeno. Parámetro crucial para evaluar el equilibrio nutricional de los sustratos en procesos biológicos como la digestión anaerobia.

DT: Decision Tree o Árbol de Decisión. Modelo de aprendizaje automático basado en decisiones binarias.

HRT: Hydraulic Retention Time, o Tiempo de Retención Hidráulico. Tiempo promedio que un sustrato permanece dentro del reactor.

MAE: Mean Absolute Error, o Error Absoluto Medio. Mide la media de las diferencias absolutas entre las predicciones y los valores reales.

MAPE: Mean Absolute Percentage Error, o Error Porcentual Absoluto Medio. Mide el error en términos relativos, expresado como porcentaje.

ML: Machine Learning, o Aprendizaje Automático. Subárea de la IA que permite a los modelos aprender a partir de datos.

N: Nitrógeno. Elemento químico presente en los residuos y esencial para el equilibrio nutricional del proceso anaerobio.

OOB: Out-of-Bag. Técnica de validación interna utilizada por modelos de ensamblado como Random Forest.

P: Fósforo. Nutriente presente en los residuos, relevante para el equilibrio químico del sustrato.

R^2: Coeficiente de determinación. Mide qué tan bien las predicciones del modelo explican la variabilidad observada en los datos.

RF: Random Forest. Algoritmo de ensamble basado en árboles de decisión múltiples, conocido por su precisión y resistencia al sobreajuste.

RMSE: Root Mean Squared Error, o Raíz del Error Cuadrático Medio. Métrica que da más peso a los errores grandes al evaluar la calidad de las predicciones.

SHAP: SHapley Additive exPlanations. Método de interpretación de modelos basado en teoría de juegos, que asigna importancia a cada variable de manera local y global.

TS: Total Solids, o Sólidos Totales. Medida del contenido total de materia en un residuo.

VS: Volatile Solids, o Sólidos Volátiles. Fracción de los sólidos que puede degradarse biológicamente.

Símbolos, unidades y fórmulas químicas

- %: Porcentaje. Fracción relativa respecto a 100.
- °C: Grados Celsius. Unidad de temperatura.
- g/L: Gramos por litro. Unidad de concentración.
- mL: Mililitros. Unidad de volumen.
- mg/L: Miligramos por litro. Unidad de concentración común en análisis de aguas.
- ppm: Partes por millón. Unidad usada para medir concentraciones muy pequeñas.
- CH_4: Metano. Principal componente del biogás.
- CO_2: Dióxido de carbono. Subproducto del proceso de digestión anaerobia.
- C: Carbono. Componente clave en la materia orgánica.
- kg: Kilogramo. Unidad de masa.

Librerías y herramientas de Python utilizadas

scikit-learn: Librería de aprendizaje automático utilizada para la construcción y evaluación del modelo.

sklearn.ensemble: Submódulo que permite trabajar con algoritmos de ensamblado como Random Forest.

sklearn.model_selection: Herramienta para dividir datasets y aplicar técnicas como Hold-Out o Validación Cruzada (k-fold).

sklearn.metrics: Conjunto de funciones para calcular métricas de evaluación de modelos.

matplotlib.pyplot: Librería para la visualización de gráficos, usada para mostrar la importancia de variables.

numpy: Librería de operaciones matemáticas, usada para cálculos como los errores MAE, RMSE y otros.

SHAP: Herramienta avanzada para interpretar modelos, basada en valores de Shapley.

GLOSARIO

Artificial Intelligence (AI): Rama de la informática que desarrolla sistemas capaces de aprender, razonar y tomar decisiones de forma autónoma, imitando la inteligencia humana.

Bagazo cervecero: Subproducto sólido generado durante la elaboración de cerveza, rico en materia orgánica y nutrientes, utilizado como sustrato en procesos de digestión anaerobia.

Carbono (C): Elemento químico esencial en los compuestos orgánicos. Su concentración se relaciona directamente con el poder energético de un residuo.

Coeficiente de determinación (R^2): Métrica de regresión que indica qué porcentaje de la variabilidad observada en los datos puede ser explicada por el modelo predictivo.

Demanda Química de Oxígeno (COD): Medida de la cantidad de materia orgánica en un residuo, expresada como la cantidad de oxígeno necesaria para oxidarla químicamente.

Digestión anaerobia: Proceso biológico en el cual microorganismos descomponen materia orgánica en ausencia de oxígeno, generando biogás como subproducto.

Error Absoluto Medio (MAE): Métrica que indica cuánto se equivocó el modelo, en promedio, sin considerar si sobreestimó o subestimó los valores reales.

Error Porcentual Absoluto Medio (MAPE): Indica el error promedio del modelo expresado en porcentaje respecto a los valores reales. Útil para comparar errores en distintas escalas.

Fósforo (P): Nutriente presente en los residuos, necesario para la actividad microbiana en la digestión anaerobia.

Hold-Out: Técnica de validación que divide el conjunto de datos en una parte para entrenamiento y otra para prueba, comúnmente en una proporción 80/20.

Hiperparámetro: Parámetro externo al modelo que define su configuración inicial, como la profundidad de un árbol o el número de estimadores en un ensamblado.

Machine Learning (ML): Rama de la IA que permite a los sistemas aprender patrones desde los datos y mejorar su desempeño con la experiencia.

Metano (CH_4): Gas inflamable y energético producido en la digestión anaerobia, principal componente del biogás.

Nitrógeno (N): Nutriente esencial para los microorganismos en el proceso de digestión anaerobia. Su exceso o déficit afecta la eficiencia del sistema.

Random Forest (RF): Algoritmo de aprendizaje automático basado en la creación de múltiples árboles de decisión. Es robusto, preciso y resistente al sobreajuste.

Raíz del Error Cuadrático Medio (RMSE): Métrica que mide la desviación estándar de los errores de predicción. Da más peso a los errores grandes.

Relación Carbono/Nitrógeno (C/N): Proporción entre el contenido de carbono y nitrógeno de un sustrato. Es clave para lograr una digestión anaerobia eficiente.

SHAP (SHapley Additive exPlanations): Técnica basada en teoría de juegos que explica cómo cada variable contribuye a las predicciones del modelo, tanto local como globalmente.

Sólidos Totales (TS): Medida del total de materia (orgánica e inorgánica) contenida en una muestra, excluyendo el contenido de agua.

Sólidos Volátiles (VS): Fracción de los sólidos totales que puede degradarse biológicamente. Representa la materia orgánica aprovechable por las bacterias anaerobias.

Validación Cruzada (k-fold): Técnica de evaluación de modelos en la cual se divide el conjunto de datos en k subconjuntos. El modelo se entrena k veces, usando una partición diferente como prueba en cada iteración. Permite una evaluación más robusta y confiable.

1. INTRODUCCIÓN

1.1. RESIDUOS ORGÁNICOS Y CAMBIO CLIMÁTICO

El modelo de desarrollo industrial vigente ha generado importantes beneficios económicos y sociales, pero también ha contribuido de manera significativa al deterioro ambiental del planeta. Entre las principales consecuencias destacan la acumulación de residuos orgánicos y la dependencia estructural de fuentes de energía fósil, factores que están íntimamente ligados a la crisis climática global (IPCC, 2021).

Los residuos orgánicos, especialmente los de origen agroindustrial, representan una fracción sustantiva de los subproductos sólidos generados a nivel mundial. Cuando estos desechos no son gestionados adecuadamente (por ejemplo, al ser depositados en vertederos sin tratamiento) pueden liberar grandes cantidades de metano (CH_4), un gas con un potencial de calentamiento global 28 veces mayor al del dióxido de carbono (CO_2) en un horizonte de 100 años (IPCC, 2021; US EPA, 2023). Este tipo de emisiones, que se han visto al alza en las últimas décadas como se observa en la Figura 1.1, convierte a la gestión de residuos en un factor crítico dentro de cualquier estrategia de mitigación del cambio climático.

Simultáneamente, las matrices energéticas globales continúan dominadas por combustibles fósiles, como el carbón, el petróleo y el gas natural. Esta dependencia no sólo profundiza las emisiones de gases de efecto invernadero, sino que también aumenta la vulnerabilidad energética de los países frente a fluctuaciones del mercado o tensiones geopolíticas (IEA, 2022).

En este contexto, se vuelve urgente avanzar hacia una transición energética que promueva el uso de fuentes limpias y renovables, pero también que incorpore los principios de la economía circular, donde los residuos no se perciben como desechos, sino como recursos valorizables. La valorización energética de subproductos orgánicos mediante tecnologías limpias se posiciona así como una estrategia clave para reducir emisiones, generar energía descentralizada y fortalecer la sostenibilidad de los sistemas productivos (European Commission, 2020).

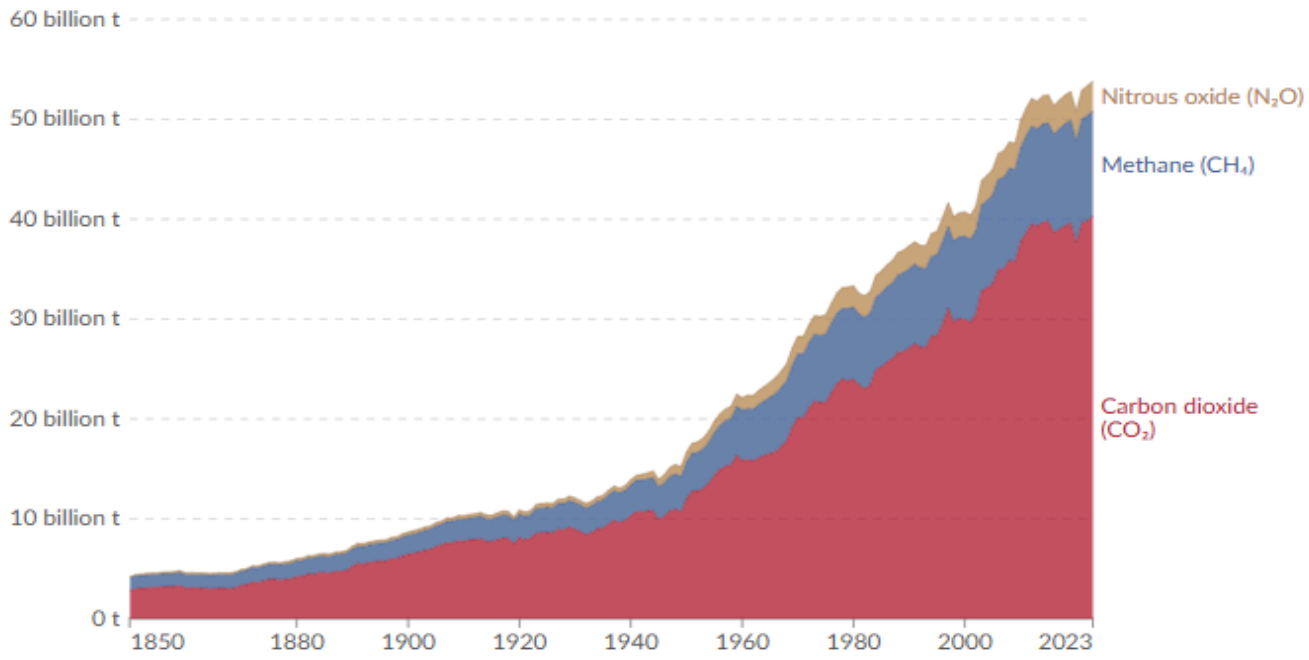

Figura 1.1: Emisiones globales de gases de efecto invernadero por tipo de gas (1850–2023).
Se incluyen todas las fuentes, considerando emisiones provenientes de la agricultura y el cambio en el uso del suelo. Las emisiones están expresadas en toneladas equivalentes de dióxido de carbono (CO_2-eq) utilizando un horizonte de 100 años.
Fuente: Our World in Data. "Greenhouse gas emissions by gas, World, 1850 to 2023."

1.2. INDUSTRIA CERVECERA: SUS RESIDUOS Y PROBLEMÁTICAS

En el marco de la crisis ambiental actual, la gestión de residuos orgánicos industriales ha cobrado una importancia creciente. Entre los sectores productivos que generan grandes volúmenes de subproductos orgánicos destaca la industria cervecera, la cual ha experimentado un crecimiento sostenido durante las últimas décadas, como se puede apreciar en la Figura 1.2, debido a la diversificación de productos, el auge del consumo local y el turismo gastronómico (Gómez & Morales, 2020).

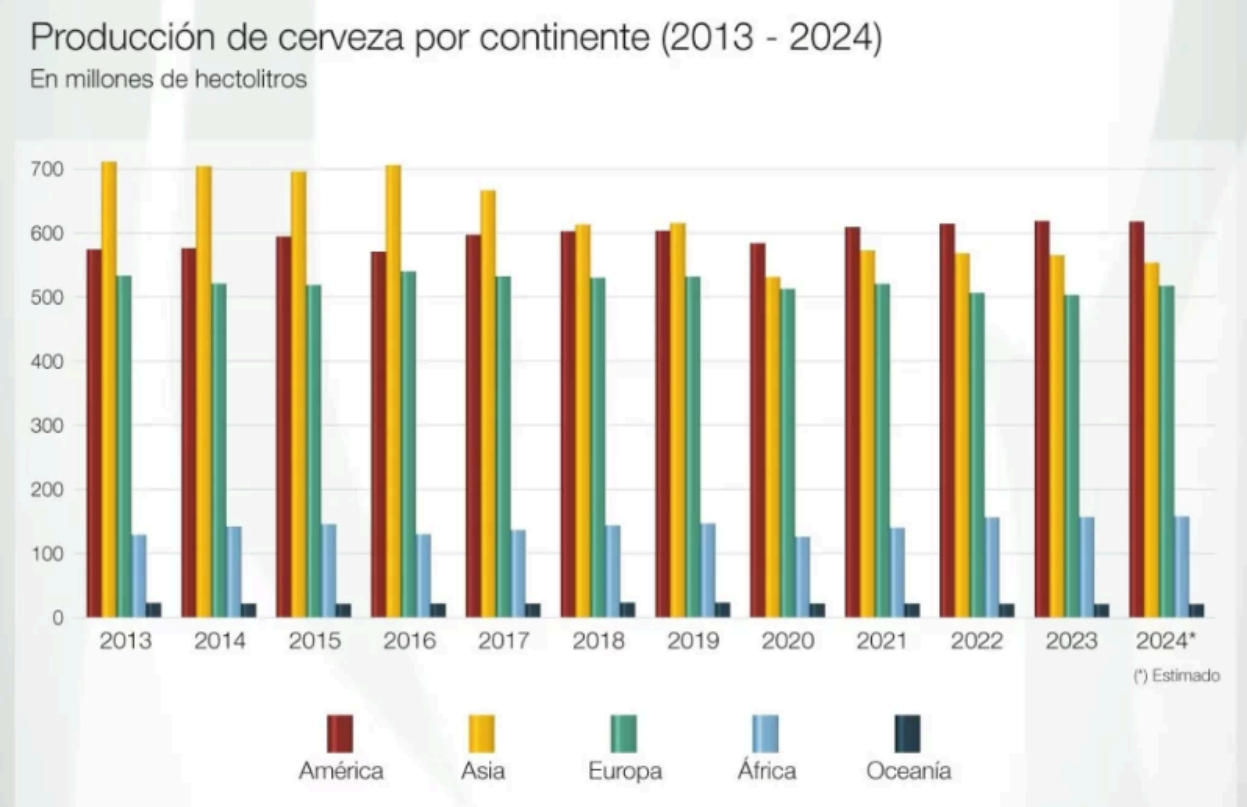

Figura 1.2: Evolución de la producción de cerveza en los últimos años.
Fuente: Producción mundial de cerveza: evolución por continente.

Durante el proceso de elaboración de cerveza, se generan distintos tipos de residuos con alto contenido de materia orgánica y humedad, que si no son tratados adecuadamente, pueden provocar impactos ambientales negativos, como malos olores, lixiviados contaminantes y emisiones de gases de efecto invernadero. A continuación, se describen los principales materiales residuales cerveceros:

- Bagazo cervecero: compuesto mayoritariamente por restos de cebada malteada y agua, representa el residuo sólido más abundante, con una proporción estimada entre 15 a 20 kg por cada 100 litros de cerveza producida (Mussatto et al., 2006).

- Lodos cerveceros: generados durante el proceso de filtración y clarificación, contienen una mezcla de materia orgánica, levadura residual, tierra de diatomeas (utilizada como agente filtrante) y sólidos sedimentados del tratamiento de aguas residuales (Fillaudeau et al., 2006).

    - Levadura residual: proviene del excedente de células de levadura que no son reutilizadas tras la fermentación. Contiene una alta concentración de materia

orgánica, proteínas, minerales y compuestos fácilmente degradables (Aliyu & Bala, 2011).

- Hot break: Se genera durante la ebullición del mosto. Está compuesto por coágulos de proteínas y polifenoles que se precipitan debido al calor. Es rico en compuestos orgánicos de fácil descomposición y puede aumentar la carga contaminante si no se gestiona adecuadamente (Pesta et al., 2020).

- Cold break: Aparece durante el rápido enfriamiento del mosto post-ebullición. Consiste en partículas coloidales, proteínas, lípidos y ácidos nucleicos. Aunque se genera en menor cantidad, su composición orgánica es altamente biodegradable (Pesta et al., 2020).

- Polvo de malta: Proviene de la molienda del grano de cebada previo al macerado. Está formado principalmente por partículas finas de cáscara, almidón y fragmentos celulares. Su composición es rica en fibra, algo de proteína y carbohidratos residuales (Pesta et al., 2020).

- Tierra de diatomea (kieselguhr): Utilizada en la etapa de filtración para clarificar la cerveza. Una vez usada, se convierte en un lodo inerte saturado de materia orgánica retenida (levaduras, proteínas, lípidos). Es difícil de biodegradar y requiere una gestión ambiental adecuada (Pesta et al., 2020).

- Aguas residuales: originadas principalmente en las etapas de lavado, enjuague y enfriamiento, presentan una elevada carga orgánica, sólidos en suspensión y variabilidad en su composición físico-química, dependiendo del tipo de cerveza y del proceso de producción (Braun et al., 2022), como se aprecia en la Tabla 1.1.

Tabla 1.1: Proporciones aproximadas de algunos residuos generados en la industria cervecera.
Fuente: Adaptado de Anaerobic Digestion of Pretreated Industrial Residues and Their Energetic Process Integration, 2020.

Residuo	**Operación donde se genera**	**Cantidad aprox. generada por hL**
Bagazo cervecero	Filtración del mosto (lautering)	20–22 kg
Levadura residual	Fermentación	2.0–2.6 kg
Hot break	Hervido del mosto	0.4–2.0 kg
Cold break	Enfriamiento del mosto	0.1–0.3 kg

Polvo de malta	Molienda de grano	0.05–0.25 kg
Tierra diatomea	Filtración de cerveza	0.4–1.1 kg
Agua residual	Limpieza, enfriamiento, proceso general	350–400 L (≈ kg)

Si bien estos residuos presentan un elevado potencial energético y agroindustrial, en la práctica su valorización es escasa, especialmente en pequeñas y medianas cervecerías que carecen de infraestructura para el tratamiento o reaprovechamiento de subproductos (Fillaudeau et al., 2006). Esto conlleva problemas de almacenamiento, generación de olores, lixiviación, proliferación de patógenos y emisiones directas de GEI.
La implementación de estrategias de gestión y valorización de estos residuos es, por tanto, clave para avanzar hacia una producción cervecera más sostenible, especialmente en contextos rurales y descentralizados.

1.3. BASES DE LA DIGESTIÓN ANAEROBIA COMO ALTERNATIVA DE VALORIZACIÓN ENERGÉTICA

Frente a los desafíos que plantea la gestión de residuos orgánicos industriales, la digestión anaerobia (DA) se posiciona como una alternativa tecnológica prometedora, tanto por su capacidad de reducir impactos ambientales como por su potencial energético. Se trata de un proceso biológico en el que consorcios microbianos descomponen materia orgánica en ausencia de oxígeno, generando como productos principales biogás (una mezcla compuesta mayoritariamente por metano -CH_4- y dióxido de carbono -CO_2-) y un subproducto estabilizado llamado digestato (Appels et al., 2008).

La DA ofrece múltiples beneficios concretos:

- Reducción de carga contaminante: Disminuye significativamente los sólidos volátiles, la demanda química de oxígeno (DQO) y la carga patógena del residuo, contribuyendo a mejorar la calidad ambiental de los efluentes (Weiland, 2010).

- Generación de energía renovable: El biogás producido puede utilizarse directamente como fuente de calor o electricidad, o ser purificado a biometano, permitiendo sustituir al gas natural en diversos usos energéticos (Mata-Alvarez et al., 2014). Además, la digestión anaerobia permite generar volúmenes significativos de biogás en períodos relativamente cortos, lo que la convierte en una tecnología eficiente para el aprovechamiento energético de residuos orgánicos, como se observa en la Figura 1.3.

- Aprovechamiento del digestato: Este subproducto puede aplicarse como fertilizante orgánico, reduciendo la dependencia de fertilizantes sintéticos y cerrando el ciclo de nutrientes (Al Seadi et al., 2008).

La valorización de residuos cerveceros mediante digestión anaerobia no solo permite mitigar las emisiones de gases de efecto invernadero asociadas a su descomposición incontrolada, sino que también representa una oportunidad para diversificar la matriz energética local, especialmente en entornos rurales o industriales con acceso limitado a fuentes limpias.

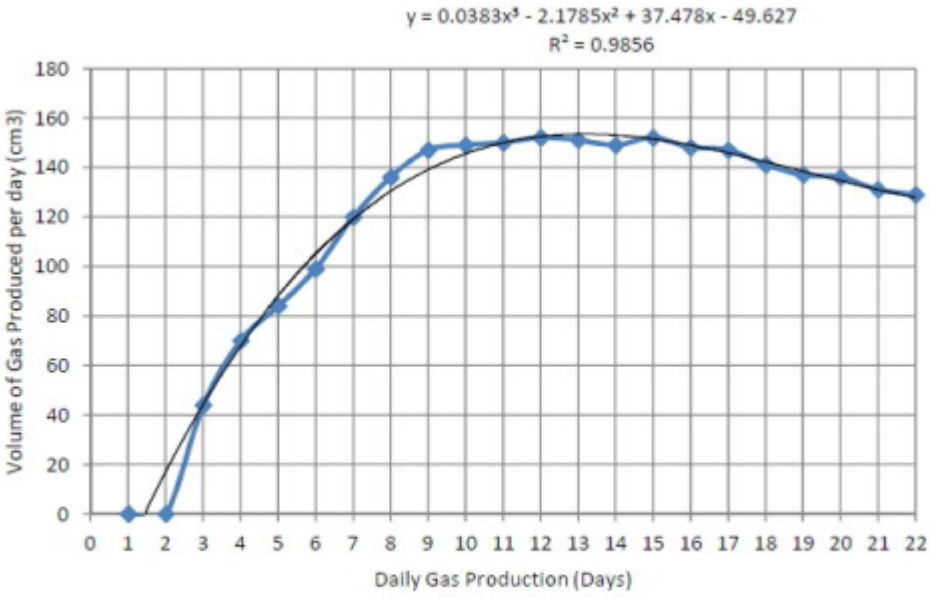

Figura 1.3: La curva de producción diaria de biogás en un digestor reiniciado muestra un aumento inicial en la producción seguido de una estabilización, lo cual es característico del proceso de digestión anaerobia.
Fuente: Comparative study of the optimal ratio of biogas production from various organic wastes and weeds for digester/restarted digester.

No obstante, la eficiencia del proceso depende de múltiples factores interrelacionados, entre ellos:

- Composición del sustrato: relación carbono/nitrógeno (C/N), contenido de sólidos volátiles (SV), y presencia de compuestos inhibitorios como fenoles o sulfuros (Zhang et al., 2011).

- Condiciones operacionales: temperatura, pH, tiempo de retención hidráulica (TRH), tipo de reactor (Zhang et al., 2011).

- Estabilidad microbiana: equilibrio entre las poblaciones acidogénicas, acetogénicas y metanogénicas que participan en las distintas etapas del proceso (Guo et al., 2014).

La alta sensibilidad de estos parámetros y su variabilidad dificultan la predicción del rendimiento y la estabilidad del sistema, lo que representa una barrera importante para su implementación a pequeña escala o en proyectos descentralizados sin capacidad técnica especializada.

1.4. INTELIGENCIA ARTIFICIAL COMO HERRAMIENTA EN LA TOMA DE DECISIONES PARA PROCESOS BIOTECNOLÓGICOS

La inteligencia artificial (IA) surge como una alternativa poderosa para modelar procesos biológicos complejos como la digestión anaerobia. A diferencia de los modelos mecanicistas, los algoritmos de IA no requieren un conocimiento completo de las ecuaciones que rigen el sistema, sino que aprenden patrones y relaciones a partir de datos experimentales. Esto les permite capturar relaciones no lineales y manejar datos heterogéneos, incluso cuando la información es incompleta o ruidosa (Nasir et al., 2015)

Entre las técnicas más comunes aplicadas a la digestión anaerobia destacan:

- Árboles de decisión y Random Forest: Métodos robustos para clasificación y regresión, capaces de manejar variables mixtas y reducir el sobreajuste (Breiman, 2001).

- Máquinas de vectores de soporte (SVM): Útiles para problemas no lineales con datasets pequeños o medianos, logrando buenas predicciones (Cortes & Vapnik, 1995).

- Redes neuronales artificiales (ANN): Modelos inspirados en el cerebro humano, efectivos para identificar patrones complejos en grandes volúmenes de datos y predecir la producción de biogás (Singh et al., 2018).

La IA aporta beneficios concretos en la digestión anaerobia, tales como:

1. Predicción precisa de la producción de biogás, integrando variables como composición del sustrato y condiciones operativas. Por ejemplo, estudios han logrado mejorar la precisión de predicción en un 15% respecto a modelos tradicionales (Patel et al., 2022).

2. Optimización de parámetros operativos, como temperatura y pH, para maximizar la eficiencia del proceso (Nasir et al., 2015).

3. Monitoreo en tiempo real que permite detectar desequilibrios tempranamente, previniendo fallas y mejorando la estabilidad del sistema (Nasir et al.,2015).

Además, estos modelos pueden integrarse con datos experimentales de distintas escalas, desde laboratorios hasta plantas industriales, facilitando su uso en contextos donde los recursos y la información son limitados (Patel et al., 2022).

Así, la IA se posiciona como una herramienta clave para avanzar en la implementación eficiente y sostenible de la digestión anaerobia, contribuyendo a la valorización energética de residuos orgánicos y a la mitigación de impactos ambientales.

2. PROBLEMA

La industria cervecera genera grandes volúmenes de residuos orgánicos, entre ellos bagazo, lodo y aguas residuales, cuyo manejo inadecuado representa un desafío ambiental creciente. Estos subproductos, si bien poseen un alto potencial de valorización energética, suelen ser subutilizados, especialmente en contextos de pequeña escala donde no existen sistemas eficientes de gestión.

A pesar de que la digestión anaerobia se presenta como una alternativa tecnológica eficaz para la valorización energética de residuos cerveceros, su implementación práctica en contextos descentralizados (como micro y pequeñas cervecerías) enfrenta importantes limitaciones técnicas y operativas. Estas dificultades se deben, en gran medida, a la complejidad inherente del proceso biológico, altamente sensible a la composición del sustrato, a las condiciones ambientales y al equilibrio microbiano. La inestabilidad y variabilidad de estos factores vuelve difícil predecir el rendimiento energético del sistema y, por ende, limita su adopción a pequeña escala, donde no existe capacidad técnica para realizar monitoreos complejos ni ajustes finos en tiempo real. En este escenario, las herramientas basadas en inteligencia artificial han demostrado su capacidad para modelar procesos biológicos no lineales, como la digestión anaerobia, permitiendo predecir su comportamiento y optimizar sus condiciones operativas. Sin embargo, su aplicación concreta en entornos productivos rurales o con escaso acceso a infraestructura tecnológica sigue siendo limitada. Esta brecha no se debe a la inexistencia de la tecnología, sino a la falta de modelos predictivos accesibles, robustos y adaptables a realidades con recursos limitados. No resolver este problema equivale a seguir operando sistemas complejos sin aprovechar las herramientas disponibles para mejorar su rendimiento, eficiencia y sostenibilidad, lo cual representa una contradicción técnica y ambiental en un contexto donde la optimización de los procesos es cada vez más urgente. En este contexto, el problema de investigación que se aborda es la ausencia de herramientas predictivas accesibles, robustas y adaptables que permitan estimar de manera eficiente el rendimiento energético de la digestión anaerobia aplicada a residuos cerveceros en entornos descentralizados con limitaciones técnicas y económicas.

3. OBJETIVOS DEL PROYECTO

3.1. OBJETIVO GENERAL

Evaluar la aplicabilidad del algoritmo de inteligencia artificial Random Forest en la predicción del potencial de producción de biogás a partir de residuos cerveceros.

3.2. OBJETIVO ESPECÍFICO

- Identificar las variables más relevantes que influyen en la producción de biogás a partir de residuos cerveceros mediante digestión anaerobia.
- Desarrollar un modelo predictivo, basado en Random Forest, enfocado en el rendimiento de producción de biogás bajo distintas condiciones del sustrato y del proceso.
- Realizar un análisis de sensibilidad del modelo desarrollado.

4. REVISIÓN BIBLIOGRÁFICA

La digestión anaerobia es un proceso biotecnológico complejo influenciado por múltiples factores fisicoquímicos, microbiológicos y operacionales. Comprender estos elementos resulta esencial para optimizar su rendimiento y garantizar la estabilidad del sistema. En esta sección se presenta una revisión de la literatura científica reciente, con el objetivo de identificar los principales parámetros que afectan el proceso, así como las herramientas emergentes, como la inteligencia artificial, que permiten modelar y predecir su comportamiento. Esta revisión proporciona el marco teórico necesario para sustentar el desarrollo de esta investigación.

4.1. LA INDUSTRIA CERVECERA Y SUS RESIDUOS

La industria cervecera genera una gran cantidad de residuos orgánicos, como bagazo, levaduras y aguas residuales. Estos subproductos, si no se gestionan adecuadamente, pueden causar impactos ambientales. Por ello, es clave analizar su composición y explorar alternativas sostenibles para su valorización, como la digestión anaerobia.

4.1.1. Producción de residuos orgánicos en cervecerías de Chile y LATAM

Diversos estudios y reportes técnicos han evidenciado que la producción de cerveza genera una cantidad significativa de residuos orgánicos, incluso a pequeña escala. En general, se estima que por cada hectolitro (hL) de cerveza se generan entre 15 a 20 kg de bagazo cervecero, 0,5 a 1 kg de levadura residual y hasta 5 a 10 hL de aguas residuales con alta carga orgánica (Fillaudeau et al., 2006; Mussatto et al., 2006).

En Chile, Cervecería Szot, ubicada en Santiago, produce aproximadamente 5.000 hl anuales, lo que equivale a la generación de cerca de 100 toneladas de bagazo húmedo por año, además de más de 25.000 hl de efluentes líquidos con alta Demanda Química de Oxígeno (DQO), estimada en más de 40.000 mg/L en su punto de descarga (Szot, 2020; Silva et al., 2021).

En la ciudad de Valdivia, Cervecería Kunstmann, con una producción cercana a los 30.000 hl/año, genera alrededor de 600 toneladas de bagazo, junto con importantes volúmenes de levadura residual y fangos del tratamiento de aguas, los cuales han sido objeto de estudios para su valorización energética y fertilizante (López et al., 2020; Kunstmann, 2022).

En Argentina, la cervecería artesanal Antares, con sede en Mar del Plata, produce aproximadamente 25.000 hl/año, generando más de 500 toneladas de residuos sólidos orgánicos, incluyendo bagazo, levadura y lodos, los cuales son parcialmente destinados a alimentación animal y compostaje, aunque sin un sistema de valorización energética implementado (García et al., 2021).

Estos casos ilustran que incluso cervecerías de mediana escala producen volúmenes significativos de residuos con alto potencial energético y agroindustrial, cuya gestión eficiente podría contribuir a la transición hacia modelos de producción más circulares y sostenibles.

4.1.2. Tipos y características de residuos generados

El proceso cervecero genera una variedad de residuos orgánicos, entre los cuales destacan:

- Bagazo cervecero: Subproducto fibroso resultante de la filtración del mosto, que representa cerca del 85% del total de residuos sólidos generados. Es rico en lignocelulosa, proteínas y compuestos fenólicos (Fillaudeau et al., 2006). En promedio, por cada hectolitro de cerveza se producen aproximadamente 20 kg de bagazo (Mussatto et al., 2006).

- Lodos de fermentación: Residuos derivados de la sedimentación de levaduras y otros sólidos en suspensión, con alta carga orgánica y contenido de nutrientes (Mussatto et al., 2006; García et al., 2019).

- Levadura residual: Se acumula al final del proceso de fermentación; contiene biomasa rica en proteínas, vitaminas del complejo B y lípidos, pero su volumen y perecibilidad dificultan su reutilización inmediata (Mussatto et al., 2006).

- Aguas residuales: Contienen azúcares, alcoholes, levaduras muertas y detergentes, con una alta Demanda Química de Oxígeno (DQO) y Demanda Biológica de Oxígeno (DBO), lo que puede generar impactos severos si se descargan sin tratamiento adecuado (Chen et al., 2008).

4.1.3. Problemáticas ambientales asociadas

La gestión inadecuada de estos residuos puede generar impactos ambientales significativos:

- Emisión de gases de efecto invernadero, como metano (CH_4) y dióxido de carbono (CO_2), en procesos de descomposición aeróbica o anaerobia no controlada (IPCC, 2021).

- Contaminación de suelos y cuerpos de agua debido a la lixiviación de nutrientes, sólidos y materia orgánica, afectando la calidad de los ecosistemas y la biodiversidad local (Chen et al., 2008).

- Proliferación de olores desagradables y vectores sanitarios, como moscas y roedores, que deterioran la calidad de vida de comunidades cercanas y pueden aumentar riesgos sanitarios (López et al., 2017).

En particular, en microcervecerías con acceso limitado a tecnologías de tratamiento, estos impactos se intensifican, especialmente en zonas rurales o con baja fiscalización ambiental, lo que genera un círculo vicioso de contaminación y desaprovechamiento de recursos (Mena et al., 2022).

Adicionalmente, la gestión deficiente tiene consecuencias económicas directas e indirectas para las microcervecerías, debido a multas, costos de limpieza y la pérdida de oportunidades para la valorización energética y de subproductos (García et al., 2019).

Por último, en el contexto normativo, aunque Chile cuenta con reglamentaciones para el manejo de residuos industriales y agroindustriales, la fiscalización y adaptación de estas normas a la realidad descentralizada de las microcervecerías es aún insuficiente, lo que limita la adopción de tecnologías sostenibles (Ministerio del Medio Ambiente Chile, 2021).

4.2. DIGESTIÓN ANAEROBIA COMO ALTERNATIVA DE VALORIZACIÓN

La digestión anaerobia es una tecnología sostenible que permite transformar residuos orgánicos en biogás y digestato. Su aplicación en la valorización de subproductos industriales, como los de la industria cervecera, representa una solución eficiente tanto energética como ambientalmente.

4.2.1. Concepto y proceso básico

La digestión anaerobia (DA) es un proceso biológico mediante el cual microorganismos descomponen materia orgánica en ausencia de oxígeno, produciendo biogás (una mezcla principalmente de metano -CH_4- y dióxido de carbono -CO_2-) y un digestato rico en nutrientes (Demirel & Scherer, 2008). Este proceso consta de cuatro etapas principales: hidrólisis, acidogénesis, acetogénesis y metanogénesis, cada una realizada por comunidades microbianas específicas (Angelidaki et al., 2011).

4.2.2. Aplicación a residuos cerveceros

Los residuos como el bagazo, lodos, levadura residual y aguas residuales son fuentes potenciales para la digestión anaerobia debido a su alta carga orgánica y biodegradabilidad (Mussatto et al., 2006). La DA permite convertir estos residuos en energía renovable (biogás) y biofertilizantes (digestato), favoreciendo un modelo de economía circular y contribuyendo a la reducción del impacto ambiental.

En la Figura 4.1, se presenta un resumen visual del proceso de digestión anaerobia:

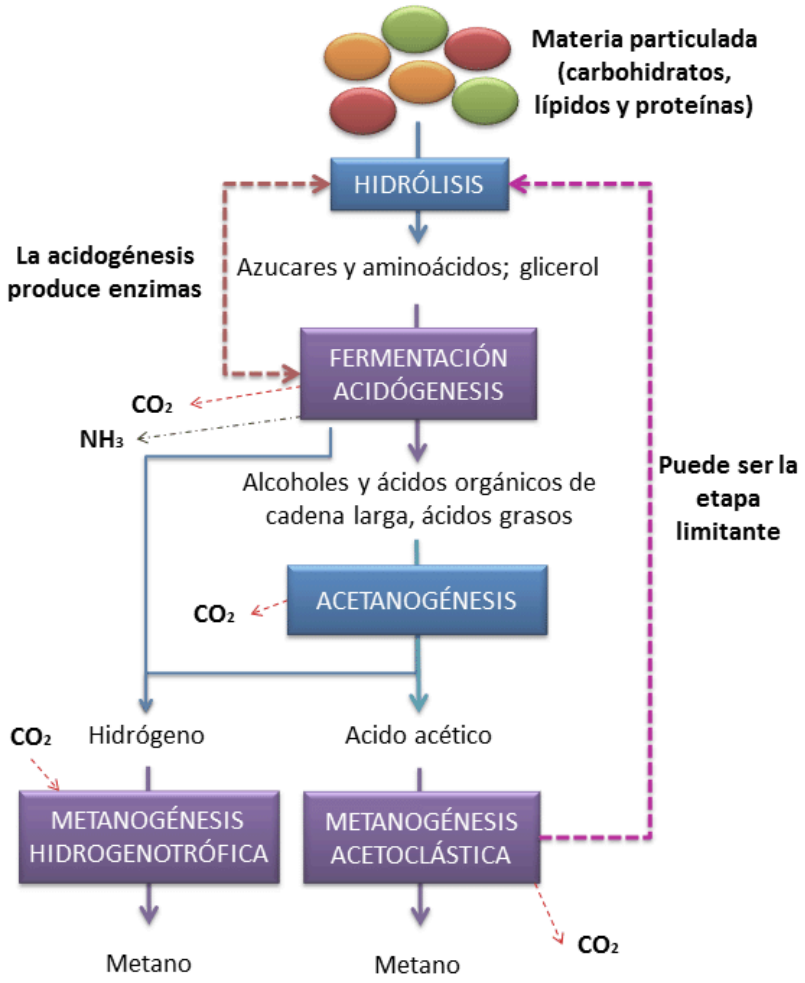

Figura 4.1: Etapas del proceso de digestión anaerobia.
Fuente: Castro, 2016.

4.2.3. Parámetros y condiciones críticas del proceso

La eficiencia del proceso de digestión anaerobia depende en gran medida del control de una serie de parámetros operacionales y ambientales. Estos factores influyen directamente sobre la actividad microbiana, la velocidad de conversión del sustrato y la estabilidad del sistema. A continuación, se describen los principales parámetros críticos identificados en la literatura especializada.

4.2.3.1. pH

El pH es un parámetro fundamental para mantener la actividad metabólica de las comunidades microbianas implicadas en la digestión anaerobia. Su rango óptimo se sitúa entre 6.8 y 7.5, siendo especialmente sensible en la etapa metanogénica, donde un descenso por debajo de 6.5 puede inhibir fuertemente la producción de metano (Kayhanian, 1999; Papirio et al., 2023). La

acumulación de ácidos grasos volátiles (VFA), generada durante la fase acidogénica, puede provocar caídas bruscas de pH si no se compensa con suficiente capacidad tampón, especialmente en sistemas con bajo contenido en carbonatos o pobre alcalinidad (Bano et al., 2022).

4.2.3.2. Temperatura

La temperatura es determinante en la cinética del proceso y en la composición del consorcio microbiano. Los dos regímenes más comunes son el mesofílico (35–40 °C) y el termofílico (50–60 °C), cada uno con ventajas y desafíos propios. El régimen mesofílico presenta mayor estabilidad y tolerancia a variaciones de carga, mientras que el termofílico ofrece mayores tasas de degradación pero requiere control térmico más estricto y presenta mayor sensibilidad a inhibidores (Bi et al., 2019; Wainaina et al., 2021). Diversos estudios reportan que incluso desviaciones de ±2 °C pueden afectar significativamente la producción de metano (Bano et al., 2022).

4.2.3.3. Tiempo de Retención Hidráulico (HRT)

El HRT representa el tiempo promedio que los residuos permanecen en el reactor y condiciona la extensión de las fases metabólicas del proceso. HRTs demasiado cortos pueden generar pérdida de biomasa activa y reducción en la producción de biogás, mientras que tiempos excesivos no implican necesariamente mayor rendimiento y pueden disminuir la eficiencia energética global. En digestión de residuos cerveceros, se han reportado HRT óptimos entre 20 y 30 días, dependiendo de la carga orgánica y el tipo de sustrato (Szaja et al., 2020; Papirio et al., 2023).

4.2.3.4. Velocidad de Carga Orgánica (OLR)

La carga orgánica o Organic Loading Rate (OLR) define la cantidad de materia orgánica (habitualmente en kg DQO/m³·día o VS/m³·día) introducida al sistema por unidad de volumen y tiempo. Su control es esencial para evitar sobrealimentación del sistema y acumulación de metabolitos intermedios (como VFA y amoníaco). Valores excesivos pueden conducir a acidificación, inhibición microbiana y colapso del reactor. Se considera que una OLR entre 1 y 4 kg VS/m³·día es segura para residuos lignocelulósicos como el bagazo cervecero, aunque esto varía según el régimen y el tipo de inóculo (Wainaina et al., 2021; Critical parameters in biogas production, 2023).

4.2.3.5. Relación C/N (Carbono/Nitrógeno)

Una adecuada relación C/N favorece el equilibrio entre la producción de energía y la síntesis de biomasa. Valores óptimos suelen situarse entre 20:1 y 30:1. Desequilibrios pueden derivar en acumulación de amonio (por exceso de nitrógeno) o deficiencias energéticas (por exceso de carbono). El bagazo cervecero presenta una relación C/N baja (~14:1), por lo que frecuentemente

se recomienda su co-digestión con residuos ricos en carbono para evitar inhibición amoniacal (Papirio et al., 2023; Bi et al., 2019).

4.2.3.6. Agitación o mezcla

La agitación mejora el contacto entre microorganismos y sustrato, previene la estratificación y facilita la liberación de gases. No obstante, una agitación excesiva puede desestabilizar las floculaciones microbianas y aumentar el consumo energético. En digestores de tipo continuo o semicontinuo, se recomiendan agitaciones suaves y frecuentes. En los estudios de Szaja et al. (2020), la presencia de bagazo cervecero favorecía la formación de costras, lo que hacía más relevante el uso de mezclado mecánico para mantener la eficiencia del proceso.

4.2.3.7. Tipo y calidad del inóculo

El inóculo es la fuente de comunidades microbianas que inician y sostienen la digestión. Su procedencia (digestato, lodos activos, estiércol) y su adaptación al sustrato determinan en gran medida la cinética inicial del proceso. Inóculos previamente expuestos a materiales similares al sustrato objetivo (por ejemplo, residuos de cervecerías) muestran mejores tiempos de adaptación y mayores rendimientos (Vitanza et al., 2016; Wainaina et al., 2021).

4.2.3.8. Ácidos Grasos Volátiles (VFA) y Alcalinidad

Los VFA son productos intermedios clave durante la fase acidogénica. Su acumulación descontrolada indica sobrecarga o inestabilidad. Una relación VFA/Alcalinidad superior a 0.4 suele ser un signo de alerta en sistemas mesofílicos. La alcalinidad, principalmente aportada por carbonatos, actúa como tampón del sistema. Un equilibrio adecuado entre ambos factores es vital para evitar caídas de pH y proteger la actividad metanogénica (Bano et al., 2022; Papirio et al., 2023).

4.2.3.9. Otros factores

Además de los parámetros principales, variables como la presencia de inhibidores (amoníaco, sulfuro de hidrógeno, metales pesados), el tamaño de partícula, el pretratamiento del sustrato y la disponibilidad de micronutrientes (como Co, Ni, Fe) pueden afectar significativamente el proceso. Aunque su impacto puede ser secundario en ciertas condiciones, su monitoreo es recomendable especialmente en plantas a escala industrial (Wainaina et al., 2021; Critical parameters in biogas production, 2023).

4.2.4. Ventajas

Las principales ventajas que presenta la digestión anaerobia son:

- Reducción significativa de la carga contaminante y de las emisiones de gases de efecto invernadero en comparación con la disposición directa, siempre y cuando el metano (CH_4) generado sea efectivamente capturado y quemado, ya sea para producción de energía o mediante antorchas de seguridad. (IPCC, 2021).

- Producción de biogás, que puede usarse para generación térmica o eléctrica, o como combustible (García-González et al., 2020).

- Generación de digestato con potencial para uso agrícola, cerrando ciclos de nutrientes (Chen et al., 2008).

4.2.5. Desafíos técnicos

Los principales desafíos técnicos de la digestión anaerobia son:

- Complejidad biológica y sensibilidad del proceso, que depende de variables como temperatura, pH, carga orgánica y tiempo de retención (Demirel & Scherer, 2008).

- Variabilidad en la composición de los residuos, lo que dificulta la estabilidad y predicción del rendimiento (Angelidaki et al., 2011).

- Necesidad de monitoreo y control que puede ser inaccesible para microcervecerías con recursos limitados.

4.2.6. Estado actual y brecha en Chile y LATAM

La implementación de la digestión anaerobia a pequeña escala aún es incipiente, con escasos casos documentados y una limitada disponibilidad de tecnologías adaptadas a las condiciones locales. Esta situación se ve agravada por la falta de herramientas predictivas que permitan optimizar los procesos y maximizar la producción de biogás, particularmente en sistemas descentralizados donde los recursos técnicos y operacionales son restringidos (Mena et al., 2022).

4.3. APLICACIONES DE INTELIGENCIA ARTIFICIAL EN PROCESOS BIOTECNOLÓGICOS

La inteligencia artificial (IA) se ha consolidado como una herramienta clave para el modelamiento de procesos biotecnológicos complejos y no lineales, como la digestión anaerobia (DA), en los que la interacción entre variables resulta difícil de predecir mediante métodos tradicionales (García-González et al., 2020). Gracias a su capacidad para identificar patrones en grandes volúmenes de datos, la IA ofrece soluciones robustas para la predicción y optimización del rendimiento en estos sistemas.

Entre los algoritmos más utilizados destacan los métodos de aprendizaje automático como Random Forest, redes neuronales artificiales (ANN) y máquinas de soporte vectorial (SVM), los cuales permiten predecir la producción de biogás y ajustar parámetros operativos para maximizar la eficiencia del proceso (Ghatak & Mahanta, 2021).

El uso de IA posibilita la integración de grandes cantidades de datos experimentales, lo cual mejora la precisión de los modelos predictivos y facilita la toma de decisiones en tiempo real (Wang et al., 2019). En el contexto de la valorización de residuos cerveceros, estas herramientas son especialmente útiles para abordar la variabilidad inherente a la composición del bagazo, lodos, levaduras residuales y aguas residuales. De este modo, la IA mejora la predicción del rendimiento energético y contribuye a estabilizar el proceso de digestión (Zhang et al., 2020).

Además, estas tecnologías permiten implementar sistemas de automatización y control adaptativo, que anticipan desviaciones en el proceso y ajustan dinámicamente las condiciones operativas. Esto no solo maximiza la eficiencia, sino que también reduce riesgos ambientales y operacionales (Lee et al., 2018).

No obstante, en contextos locales y descentralizados (como las microcervecerías en Chile), la aplicación práctica de la IA enfrenta importantes desafíos. Entre ellos destacan las limitaciones técnicas, la escasez de datos confiables y la falta de acceso a infraestructura digital especializada, lo que restringe su implementación y aprovechamiento a escala local (Mena et al., 2022).

4.4. BRECHAS Y DESAFÍOS EN CONTEXTOS DESCENTRALIZADOS

Las principales brechas y desafíos se pueden identificar como:

- La descentralización de la producción cervecera en Chile y Latinoamérica implica que muchas microcervecerías operan con recursos técnicos y económicos limitados, dificultando la implementación de tecnologías avanzadas para la gestión de residuos (Mena et al., 2022; Silva et al., 2021).

- La falta de acceso a bases de datos experimentales específicas y representativas para estos contextos limita la capacidad de entrenar modelos de inteligencia artificial con buen desempeño (García-González et al., 2020; Ramírez et al., 2019).

- La escasa formación técnica y el desconocimiento sobre IA y digestión anaerobia entre los operadores y dueños de microcervecerías generan barreras para la adopción de soluciones digitales (López & Torres, 2021).

- Las inversiones necesarias para implementar sistemas de digestión anaerobia junto con herramientas de IA pueden ser prohibitivas para pequeños productores sin apoyos o subsidios (Fernández et al., 2020).

- La variabilidad inherente en la composición de residuos cerveceros entre distintas microcervecerías agrega dificultad para crear modelos predictivos generalizables y robustos (Zhang et al., 2020).

- La ausencia de políticas públicas específicas que fomenten la valorización energética de residuos cerveceros en microescala dificulta el desarrollo y escalamiento de estas tecnologías (Ministerio de Medio Ambiente Chile, 2019).

- Existen también desafíos regulatorios y normativos relacionados con la disposición de residuos y la producción de biogás en contextos rurales o urbanos descentralizados (Gómez & Sánchez, 2022).

- Se requiere el desarrollo de soluciones tecnológicas accesibles, intuitivas y adaptadas a las condiciones particulares de microcervecerías para promover la sostenibilidad y circularidad en la gestión de residuos (Pérez et al., 2021).

5. MATERIALES Y MÉTODOS

La presente sección describe los métodos utilizados para alcanzar los tres objetivos específicos planteados en esta investigación. Cada apartado detalla el enfoque seguido, las fuentes consultadas y los criterios aplicados en el análisis, organizados según la secuencia lógica de los objetivos del estudio.

5.1. METODOLOGÍA PRIMER OBJETIVO ESPECÍFICO

La metodología para abordar este objetivo consistió en una revisión cualitativa de literatura científica enfocada en identificar y comprender las variables clave que influyen en el proceso de digestión anaerobia aplicada a residuos cerveceros. El análisis se centró exclusivamente en fuentes secundarias, sin aplicación experimental.

5.1.1. Búsqueda y recopilación de bibliografía especializada

Se realizó una búsqueda sistemática de artículos científicos en bases de datos académicas reconocidas como ScienceDirect, SpringerLink, Scopus y Google Scholar, utilizando palabras clave en inglés como: anaerobic digestion, brewery waste, biogas production, organic loading rate, pH, temperature, C/N ratio, entre otras. No se aplicó restricción de antigüedad ni de localización geográfica, ya que el criterio principal fue la calidad del contenido y su aplicabilidad al caso de estudio.

El enfoque cualitativo fue seleccionado porque, más allá de cuantificar valores, el interés radicó en comprender qué variables afectan la digestión anaerobia, cómo lo hacen y por qué lo hacen, considerando tanto la naturaleza fisicoquímica del sistema como su comportamiento microbiológico. Esta aproximación permitió indagar en la lógica interna de cada variable, entender sus interrelaciones y valorar sus impactos teóricos y prácticos en el rendimiento del proceso.

5.1.2. Criterios de inclusión y exclusión de los estudios

Fueron incluidos únicamente los estudios que cumplieran con las siguientes condiciones:

- Presentar información detallada sobre variables que afectan la digestión anaerobia.
- Reportar una producción eficiente de metano como resultado del proceso.
- Incorporar referencias bibliográficas sólidas y respaldo científico confiable.

De esta forma, se excluyeron aquellos estudios que no mostraban resultados claros en producción de metano o que no abordaban las variables de manera específica. Adicionalmente, se descartaron investigaciones que trataban aspectos muy particulares o aislados, como variables cinéticas del proceso, si estas no eran abordadas por otros estudios más representativos. Esto se basó en el criterio de que una variable debía aparecer como importante en más de una fuente para ser considerada dentro del análisis.

5.1.3. Organización y análisis cualitativo de la información

Una vez seleccionados los estudios, se elaboró una plantilla digital en Excel para organizar la información clave de cada uno. Cada registro incluyó los siguientes campos:

- Componente del sustrato (ej: bagazo cervecero, lodo cervecero, agua residual cervecera)
- Tipo (nutriente, inhibidor, variable operativa, etc.)
- Efecto esperado en la digestión anaerobia
- Riesgo de exceso o defecto
- Referencia clave

El análisis fue de tipo cualitativo-comparativo. Se observaron las variables que más se repetían entre los estudios seleccionados y aquellas que, según los propios autores, presentaban un efecto determinante en la eficiencia del proceso. Las variables mencionadas solo por una fuente y que no eran validadas por otros estudios relevantes fueron descartadas, incluso si podían tener algún nivel de impacto, con el fin de enfocar el análisis en factores ampliamente respaldados por la evidencia científica revisada.

5.2. METODOLOGÍA SEGUNDO OBJETIVO ESPECÍFICO

Para cumplir con el segundo objetivo, que consiste en desarrollar un modelo proyectivo de aprendizaje automático basado en el algoritmo Random Forest, se llevaron a cabo una serie de procedimientos orientados a estructurar un modelo capaz de predecir el rendimiento de producción de biogás bajo distintas condiciones del sustrato y del proceso. Este apartado describe el tratamiento de datos, la selección de variables, la configuración del modelo y su entrenamiento, con énfasis en la coherencia entre la información disponible y los criterios técnicos del algoritmo utilizado.

5.2.1. Recolección de datos

La recolección de datos se llevó a cabo a partir de fuentes secundarias, como artículos científicos y bases de datos abiertas que abordan procesos de digestión anaerobia utilizando residuos orgánicos de origen cervecero. En particular, se enfocó en tres tipos de sustratos: bagazo cervecero, lodo cervecero y agua residual cervecera. Estos subproductos presentan composiciones distintas que afectan la biodegradabilidad y, por lo tanto, el rendimiento de biogás, por lo que es relevante incorporarlos de forma diferenciada en el análisis.

Se priorizaron los estudios que entreguen datos detallados sobre:

- Condiciones operativas del proceso (temperatura, pH, tipo de inóculo, tiempo de retención, agitación, carga orgánica, etc.).

- Caracterización fisicoquímica de los sustratos utilizados (sólidos totales –TS–, sólidos volátiles –VS–, relación C/N, contenido de fibra y lignina, ácidos grasos volátiles –VFA–, alcalinidad, SCOD, entre otros).

- Indicadores de rendimiento como volumen de biogás generado, contenido de metano, estabilidad del sistema, entre otros.

En los casos donde los datos no estaban disponibles directamente en bases de datos abiertas, se aplicaron técnicas de extracción manual de información desde artículos científicos, siguiendo criterios de trazabilidad y calidad. Cuando los datos estaban disponibles únicamente en formato gráfico (por ejemplo, curvas o diagramas), se utilizó el software WebPlotDigitizer para digitalizar valores desde imágenes.

No se establecieron restricciones temporales ni geográficas para la selección de estudios, siempre que estos incluyeran información sobre procesos completos de digestión anaerobia, abordando las cuatro etapas clásicas del proceso microbiano: hidrólisis, acidogénesis, acetogénesis y metanogénesis. Tampoco se exigió que el residuo cervecero se utilizara de forma exclusiva, permitiéndose estudios de codigestión, siempre que se especificaran las proporciones y características de cada componente.

Dado que la cantidad de estudios útiles depende directamente de la completitud y calidad de los datos que entregarán, el número final de documentos analizados se definió durante el proceso de revisión. Para asegurar un estándar mínimo, se evaluó la calidad de cada estudio en función de su transparencia metodológica, completitud de variables y consistencia con estudios similares.

Para asegurar la consistencia, comparabilidad y trazabilidad de los datos, se empleó una ficha de extracción por estudio para registrar de forma manual cada variable obtenida, junto con su unidad, fuente y método de recolección. Posteriormente, se aplicó un proceso de normalización y homologación de unidades para integrar los datos en una matriz común, la cual fue desarrollada en formato Excel para su posterior análisis y tratamiento computacional.

5.2.2. Selección y análisis exploratorio de variables

Con el fin de construir un modelo robusto y representativo de la producción de biogás a partir de residuos cerveceros, se llevó a cabo un proceso de selección de variables basado en literatura especializada y en su relevancia comprobada durante el desarrollo del primer objetivo de la investigación. Este análisis preparatorio contempló tres grandes bloques: características del sustrato, condiciones del proceso y variables de salida.

En primer lugar, se identificaron variables físico-químicas asociadas a los distintos subproductos cerveceros (bagazo, lodo y agua residual). Estas variables permitieron caracterizar la biodegradabilidad del sustrato y su aporte al proceso fermentativo, considerando la diversidad en composición orgánica y propiedades de cada residuo.

En segundo lugar, se consideraron variables relacionadas con las condiciones operativas del sistema de digestión anaerobia. Estas condiciones influyeron directamente en la estabilidad del proceso y en la eficiencia de conversión biológica, por lo que su monitoreo y ajuste adecuado fueron claves para garantizar la sostenibilidad del sistema.

Finalmente, se definieron como variables dependientes aquellas asociadas al rendimiento del proceso, tales como la cantidad y calidad del biogás generado, así como indicadores cinéticos y de estabilidad del sistema. Estas salidas sirvieron como referencia para evaluar el comportamiento del sistema y validar la capacidad predictiva del modelo desarrollado.

Este enfoque integral permitió no solo optimizar la mezcla de residuos cerveceros como sustrato, sino también facilitar el entrenamiento de algoritmos de inteligencia artificial mediante un preprocesamiento riguroso y coherente de los datos experimentales.

5.2.3. Preprocesamiento de datos

El preprocesamiento de datos constituyó una etapa crítica dentro de la metodología, ya que permitió asegurar la calidad, consistencia y adecuación de la información antes de su uso en modelos de inteligencia artificial. Su correcta ejecución fue esencial para garantizar que los resultados obtenidos fueran fiables, interpretables y representativos.

En particular, algoritmos como Random Forest requirieron que los datos estuvieran bien estructurados, sin inconsistencias ni vacíos significativos. No fue posible alimentar estos modelos con información incompleta, ruidosa o desordenada sin comprometer su desempeño.

Por ello, se implementaron distintas acciones orientadas a preparar el conjunto de datos, tales como:

- Carga y consolidación de fuentes,
- Limpieza y validación,
- Imputación de valores faltantes,
- Codificación de variables categóricas,
- Normalización o estandarización de variables, según corresponda.

5.2.3.1. Recolección y organización preliminar

Los datos extraídos de artículos científicos fueron registrados y organizados inicialmente en hojas de cálculo utilizando Microsoft Excel, en formato .xlsx. Esta etapa permitió una visualización clara de los valores, facilitando la revisión manual, el ordenamiento por variables y la inclusión de anotaciones complementarias cuando fue necesario. Cada fila del archivo representó un conjunto experimental reportado, mientras que las columnas agruparon las variables independientes (por ejemplo, temperatura, tiempo de retención hidráulica, pH, tipo de sustrato, etc.) y dependientes (por ejemplo, volumen de biogás producido, contenido de metano, etc.).

5.2.3.2. Conversión a formato .csv

Una vez verificados y organizados los datos, estos fueron exportados desde Excel a formato .csv (Comma Separated Values), ampliamente compatible con herramientas de análisis de datos como Python. Este formato, que representa la información en texto plano con valores separados por comas, ofreció una estructura más liviana y facilitó la lectura automatizada desde scripts.

5.2.3.3. Carga en el entorno de trabajo

El archivo .csv fue cargado en Python utilizando la librería pandas, que permite manipular estructuras de datos tabulares de manera eficiente. El proceso de carga se llevó a cabo en un entorno de desarrollo basado en Jupyter Notebook, lo que permitió una interacción secuencial y documentada con el conjunto de datos.

5.2.3.4. Estructura del conjunto de datos

El dataset final cargado estuvo compuesto por n observaciones (filas) y m variables (columnas), incluyendo tanto características del proceso como resultados de la digestión anaerobia. Las variables se clasificaron según su tipo en numéricas continuas, categóricas o binarias, lo que fue considerado en las etapas posteriores de preprocesamiento.

5.2.4. Verificación Inicial

Una vez cargado el conjunto de datos en el entorno de trabajo, se realizó una verificación preliminar destinada a comprender la estructura general del dataset y a identificar posibles problemas que pudieran afectar el análisis posterior o la eficacia del modelo predictivo. Esta revisión fue fundamental para establecer un diagnóstico de la calidad de los datos y definir las acciones necesarias de limpieza y transformación.

En esta etapa se abordaron los siguientes aspectos:

- Dimensión del dataset: Se evaluó el número total de observaciones y variables contenidas en el archivo, lo que permitió tener una idea general del tamaño y alcance de la información disponible.

- Visualización del encabezado y nombres de columnas: Se inspeccionó el contenido de las primeras filas y los nombres de las variables para verificar su coherencia, legibilidad y formato.

- Tipo de dato por variable: Se revisó el tipo de dato asignado a cada columna (por ejemplo, numérico, texto, booleano), con el fin de detectar posibles asignaciones incorrectas que debieran corregirse antes del modelado.

- Existencia de valores faltantes: Se identificó la presencia y el número de datos nulos por variable, para dimensionar la magnitud del problema y preparar estrategias de imputación.

- Estadísticas descriptivas básicas: Se examinaron medidas como la media, la desviación estándar, los valores mínimos y máximos, entre otras, para detectar valores extremos o inconsistentes.

- Presencia de duplicados: Se contabilizaron las filas idénticas que pudieran estar replicadas dentro del dataset, lo cual podría sesgar los resultados si no se corregía.

- Variables categóricas mal codificadas: Se revisaron las variables de tipo texto para identificar posibles errores de escritura, diferencias ortográficas o inconsistencias en el formato (por ejemplo, uso de mayúsculas, espacios innecesarios).

Estas operaciones se llevaron a cabo mediante funciones básicas de exploración proporcionadas por la librería pandas, las cuales permitieron obtener un panorama completo del estado inicial del dataset. Esta revisión general constituyó el primer paso en el proceso de preprocesamiento y

aseguró que los datos estuvieran en condiciones adecuadas para avanzar hacia su limpieza, transformación y modelado.

5.2.5. Unificación y almacenamiento

Una vez completadas la verificación inicial y las etapas de limpieza de datos, se procedió a unificar toda la información relevante en un único archivo consolidado. El propósito de esta etapa fue garantizar que el dataset final se encontrara estructurado de forma coherente, estandarizada y fácilmente accesible para las fases posteriores de análisis y modelado.

En caso de que los datos hubieran sido recolectados desde múltiples fuentes, como artículos científicos, reportes técnicos o bases de datos independientes, se realizó una integración cuidadosa entre los distintos subconjuntos. Esta integración incluyó:

- Estandarización de nombres de variables: Se ajustaron los nombres de las columnas para que tuvieran una denominación uniforme, facilitando su identificación y uso posterior.

- Homogeneización de unidades de medida: Cuando fue necesario, se convirtieron variables a una misma unidad (por ejemplo, temperaturas en grados Celsius a Kelvin), con el fin de asegurar consistencia entre observaciones.

- Reorganización de columnas: Se definió un orden lógico y funcional para las variables, lo que permitió una mejor legibilidad y un manejo más eficiente del dataset.

Finalizada esta consolidación, el dataset fue almacenado en formato .csv, por tratarse de un tipo de archivo ampliamente compatible con diversas plataformas de análisis, ligero en tamaño y óptimo para estructuras tabulares. Este archivo fue guardado dentro de una carpeta organizada del entorno de trabajo, asegurando la trazabilidad y el acceso ágil a futuras versiones.

Además, como medida preventiva, se mantuvo una copia del dataset ya preprocesado, previa a la aplicación de cualquier transformación adicional (por ejemplo, codificación o normalización). Esta copia sirvió como respaldo ante eventuales errores, o para validar resultados intermedios en el proceso de análisis.

5.2.6. Limpieza de datos

La limpieza de datos fue una etapa fundamental dentro del proceso de preprocesamiento, cuyo propósito fue garantizar que la información utilizada por el modelo de predicción fuera coherente, precisa y representativa del fenómeno estudiado. Esta fase permitió reducir errores,

inconsistencias y distorsiones que podrían haber comprometido la calidad de los resultados, afectando negativamente la capacidad predictiva del modelo.

En el contexto de esta investigación, se aplicaron diversos procedimientos de depuración sobre el conjunto de datos recopilados, orientados a optimizar su estructura y fiabilidad. Cada una de estas acciones fue seleccionada estratégicamente según la naturaleza del dato, el contexto experimental y la literatura técnica relacionada con el proceso de digestión anaerobia.

5.2.6.1. Eliminación de datos duplicados

Como primer paso en la limpieza del dataset, se realizó la detección y eliminación de registros duplicados. La existencia de filas idénticas pudo generar sesgos en el análisis, ya que ciertas condiciones experimentales o configuraciones de proceso podrían haber quedado sobrerrepresentadas, afectando la objetividad de los resultados.

Para esto, se aplicó una función automatizada que identificó todas las entradas duplicadas considerando todas las columnas del dataset. Una vez detectadas, estas filas fueron removidas, dejando únicamente una ocurrencia de cada registro único. De este modo, se aseguró que cada muestra aportara información distinta, evitando redundancias que pudieran distorsionar la inferencia del modelo predictivo.

Esta limpieza garantizó una base de datos más limpia, precisa y representativa para las etapas posteriores de análisis.

5.2.6.2. Detección y tratamiento de valores extremos (outliers)

En esta etapa se identificaron y trataron los valores extremos presentes en las variables numéricas del dataset. Estos valores atípicos pudieron corresponder a errores de digitación, mediciones incorrectas o condiciones experimentales poco comunes que, si no se controlaban, podrían haber afectado negativamente tanto el análisis estadístico como el rendimiento del modelo predictivo.

Para su detección, se utilizaron estadísticas descriptivas, tales como percentiles, valores mínimos y máximos, y el rango intercuartílico (IQR), que permitió delimitar el rango esperado para los datos. Además, se recurrió a representaciones gráficas como los boxplots, que visualizaron la distribución de cada variable y facilitaron la identificación rápida de anomalías.

Una vez detectados, los valores extremos fueron evaluados caso a caso para decidir si se eliminarían o conservarían. Se eliminaron aquellos claramente erróneos o que no representaban condiciones reales del proceso de digestión anaerobia, asegurando la coherencia y calidad del dataset.

5.2.6.3. Corrección de errores de formato y codificación

Durante el preprocesamiento, se corrigieron errores relacionados con el formato y la codificación de los datos, en especial en variables categóricas. Estos errores solían originarse por diferencias ortográficas, uso inconsistente de mayúsculas o espacios extra, lo que podía hacer que una misma categoría fuera interpretada como varias distintas.

Para garantizar la coherencia y uniformidad en la representación de estas variables, se aplicó un proceso de estandarización de los textos relevantes. Esto incluyó transformar todos los valores a minúsculas y eliminar espacios innecesarios al inicio o al final de cada cadena. Así, se aseguró una codificación limpia y confiable, facilitando el análisis y evitando confusiones durante la modelación.

5.2.6.4. Verificación de inconsistencias internas

Como paso final en la etapa de limpieza, se llevó a cabo una verificación de la coherencia interna del dataset, revisando que los valores numéricos de variables clave se encontraran dentro de rangos aceptables basados en la literatura especializada sobre digestión anaerobia.

Se definieron umbrales lógicos para variables fundamentales del proceso, tales como el pH, la temperatura y el tiempo de retención hidráulica (HRT). Cualquier registro que se encontró fuera de estos límites fue considerado potencialmente erróneo y fue eliminado del conjunto de datos. Esta depuración fue clave para evitar que datos atípicos o inválidos introdujeran ruido o distorsionaran el desempeño del modelo predictivo.

Los criterios que se establecieron fueron:

- El pH debió estar entre 5.5 y 8.5, que corresponde al rango típico para un funcionamiento estable del sistema biológico.

- La temperatura se encontró entre 25 °C y 60 °C, considerando las condiciones mesofílicas y termofílicas habituales en digestión anaerobia.

- El tiempo de retención hidráulica debió ser mayor que cero, ya que valores nulos o negativos no representaron condiciones reales del proceso.

Para implementar esta limpieza, se aplicaron filtros específicos que excluyeron automáticamente las observaciones que no cumplieron con estos rangos establecidos.

5.2.7. Imputación de datos faltantes

Durante el desarrollo del conjunto de datos, se identificaron valores faltantes en algunas variables relevantes del proceso de digestión anaerobia. Dado que los algoritmos de aprendizaje automático no admiten la presencia de valores nulos, se implementó una estrategia de imputación, es decir, un relleno sistemático y justificado de estos vacíos de información.
Esta etapa permitió conservar el mayor volumen posible de datos sin comprometer la calidad del análisis. A continuación, se describieron las acciones que se aplicaron para la detección, análisis y tratamiento de los datos faltantes.

5.2.7.1. Identificación de datos faltantes

En primera instancia, se realizó un diagnóstico para detectar la presencia de valores faltantes en el dataset. Este análisis permitió identificar cuántos datos se encontraban ausentes por variable, así como calcular el porcentaje que representaban respecto del total de registros.

Para ello, se aplicaron funciones que entregaron tanto el conteo absoluto de valores nulos como su proporción relativa. Esta información fue clave para dimensionar la magnitud del problema y priorizar el tratamiento de las columnas más afectadas.

Este paso resultó esencial para determinar si fue viable realizar una imputación o si, por el contrario, fue necesario eliminar variables o registros que presentaran una cantidad excesiva de información ausente.

5.2.7.2. Análisis del patrón de faltantes

Una vez identificadas las variables que contenían valores nulos, se procedió a analizar visualmente su distribución dentro del conjunto de datos. Este análisis gráfico permitió determinar si los datos ausentes se encontraban dispersos de manera aleatoria o si estaban concentrados en ciertas observaciones o columnas, lo que podría revelar patrones sistemáticos o errores durante la recolección.

Comprender esta distribución fue clave para tomar decisiones informadas respecto al tratamiento de los valores faltantes. Por ejemplo, si los nulos se concentraban en un subconjunto específico del dataset, se consideró la eliminación de esas filas o columnas. En cambio, si la ausencia de datos era más bien aleatoria y marginal, se optó por métodos de imputación.

Para llevar a cabo esta evaluación, se generaron visualizaciones gráficas mediante bibliotecas especializadas, las cuales permitieron representar las celdas faltantes en un mapa de calor. Esta herramienta facilitó la identificación de patrones ocultos y contribuyó a definir la estrategia de limpieza más adecuada.

5.2.7.3. Estrategias de imputación utilizadas

Una vez caracterizado el patrón de los valores faltantes, se aplicaron técnicas de imputación con el fin de completar los vacíos en el conjunto de datos. Estas estrategias buscaron preservar la distribución estadística original de cada variable y minimizar la introducción de sesgos que pudieran afectar el desempeño del modelo.

Para las variables numéricas, se optó por utilizar la mediana como medida de tendencia central. Esta elección se fundamentó en su robustez frente a la presencia de valores atípicos, a diferencia de la media, que podría distorsionar los resultados en presencia de outliers.

En el caso de las variables categóricas, se imputaron los valores faltantes utilizando la moda, es decir, el valor más frecuente dentro de cada columna. Esta decisión permitió mantener la coherencia con las categorías predominantes en el conjunto de datos y evitar la generación de nuevas clases artificiales.

Estas técnicas se aplicaron individualmente a cada variable con valores ausentes, completando así el dataset de forma coherente con su estructura original. Gracias a esta etapa, se aseguró la integridad del conjunto de datos antes de su utilización en el entrenamiento de modelos predictivos.

5.2.7.4. Documentación de las imputaciones

Con el propósito de asegurar la trazabilidad y transparencia del proceso de preprocesamiento, se documentaron de manera explícita todas las imputaciones que se aplicaron al conjunto de datos. Para ello, se adoptaron dos acciones complementarias y fundamentales:

- En primer lugar, se generó una copia de seguridad del dataset original antes de efectuar cualquier modificación. Esta acción permitió conservar un respaldo que pudo ser utilizado para auditorías, comparaciones o, si fuese necesario, para revertir los cambios realizados durante esta etapa.

- En segundo lugar, se elaboró un registro auxiliar que detalló todas las imputaciones efectuadas. Este documento incluyó información sobre las columnas afectadas, los métodos estadísticos que se utilizaron (como mediana o moda) y los valores específicos aplicados en cada caso. Esta planilla funcionó como una bitácora técnica del proceso,

asegurando la transparencia metodológica y facilitando la reproducción del análisis en futuras etapas.

Gracias a estas medidas, se garantizó que las imputaciones fueran trazables, reversibles y justificadas, sentando una base sólida para continuar con el modelado predictivo sobre datos limpios y correctamente tratados.

5.2.8. Codificación de variables categóricas

Dado que los algoritmos de aprendizaje automático, como Random Forest, no pueden procesar directamente variables categóricas representadas como texto (por ejemplo, Tipo_reactor o Inóculo), fue necesario transformarlas en una representación numérica válida. Este procedimiento se denominó codificación de variables categóricas.

Para este estudio, se aplicó la técnica de One-Hot Encoding, la cual consistió en crear una nueva columna por cada categoría única presente en las variables seleccionadas. A cada observación se le asignó un valor de 1 si pertenecía a dicha categoría, y 0 en caso contrario. Esta estrategia evitó introducir un orden artificial entre las categorías y permitió que el modelo aprendiera sin asumir relaciones inexistentes entre ellas.

Previo a la transformación, se verificó que todas las categorías faltantes hubieran sido correctamente imputadas. De este modo, se evitó la generación de columnas inconsistentes o vacías durante el proceso de codificación.

Además, como parte de las buenas prácticas de trazabilidad, se generó una copia del conjunto de datos antes de aplicar cualquier transformación. Esto permitió conservar una versión íntegra del dataset original, útil para auditorías, comparación de resultados o eventuales retrocesos.

Con estas acciones, se garantizó que las variables categóricas estuvieran debidamente representadas en formato numérico, permitiendo su incorporación adecuada al modelo predictivo y asegurando un tratamiento metodológico riguroso.

5.2.9. Normalización o estandarización

La normalización o estandarización constituyó una etapa complementaria dentro del preprocesamiento de datos, orientada a ajustar la escala de las variables numéricas para facilitar su comparación. Aunque el algoritmo Random Forest no requirió que los datos se encontraran en una misma escala para funcionar correctamente, se aplicó esta transformación como buena práctica metodológica. Su inclusión permitió facilitar la visualización de los datos y asegurar la

compatibilidad con otros modelos de aprendizaje automático que sí resultan sensibles a las diferencias de escala.

En esta investigación, se optó por la técnica de normalización Min-Max, la cual ajustó los valores de cada variable numérica a un rango común entre 0 y 1, manteniendo sus proporciones relativas. Este método permitió que el valor mínimo de cada variable se transformara en 0, y el valor máximo en 1, generando así un rango uniforme que favoreció la comparación directa entre variables de distinta magnitud.

La fórmula que se utilizó para aplicar esta transformación fue la siguiente:

X_normalizado = (X - X.min) / (X.max - X.min)

Donde:

- X: valor original.
- Xmin: valor mínimo de la variable.
- Xmax: valor máximo de la variable.

Previo a la aplicación de esta transformación, se generó una copia del conjunto de datos original con el fin de conservar la trazabilidad del proceso y permitir su reversión en caso de ser necesario.

Luego, se seleccionaron específicamente las variables numéricas relevantes para este análisis, como por ejemplo la temperatura del proceso, el tiempo de retención y la producción de biogás. Estas fueron transformadas utilizando un objeto escalador basado en la técnica Min-Max, el cual ajustó sus valores al rango definido.

Esta estrategia proporcionó un conjunto de datos numéricos escalados de manera coherente, listos para ser incorporados en modelos o gráficos que requirieran comparabilidad entre magnitudes.

5.2.10. Construcción de la inteligencia artificial

En esta sección se abordó el proceso completo de construcción del modelo de inteligencia artificial que fue utilizado para predecir la producción de biogás a partir de diversas variables del proceso de digestión anaerobia. Esta etapa representó el núcleo del enfoque predictivo del presente estudio, y contempló desde la elección del algoritmo hasta la evaluación de su aplicabilidad en contextos similares.

Para ello, se implementó un enfoque basado en aprendizaje supervisado, utilizando como insumo el conjunto de datos previamente preprocesado. Las decisiones metodológicas que se adoptaron estuvieron orientadas a garantizar la robustez, interpretabilidad y aplicabilidad del modelo desarrollado.

Se empleó la biblioteca scikit-learn, ampliamente utilizada en el ámbito del aprendizaje automático por su versatilidad y eficiencia. En particular, se utilizaron herramientas de su submódulo ensemble, que permitió construir modelos basados en la combinación de múltiples estimadores para mejorar la precisión de las predicciones.

A continuación, se detallaron los pasos involucrados en la construcción del modelo, incluyendo la elección del algoritmo, la división del conjunto de datos, el entrenamiento, evaluación, interpretación y validación comparativa con estudios previos.

5.2.10.1. Elección del algoritmo

Considerando la elevada variabilidad y complejidad composicional de los residuos cerveceros utilizados como sustrato (bagazo, lodo y agua residual), se seleccionó el algoritmo Random Forest como modelo predictivo principal. Esta decisión se basó en su capacidad para abordar relaciones no lineales, adaptarse a datos heterogéneos y proporcionar interpretabilidad mediante la identificación de variables relevantes.
Random Forest, perteneciente a la familia de los métodos de ensamble, construye múltiples árboles de decisión a partir de subconjuntos aleatorios del conjunto de datos y de las variables disponibles, promediando sus resultados para obtener una predicción final. Esta arquitectura le otorga una serie de ventajas que lo hacen especialmente adecuado para este tipo de aplicaciones:

- Manejo de alta variabilidad del sustrato
  Random Forest tolera la heterogeneidad natural presente en los residuos cerveceros, permitiendo modelar de manera robusta distintos escenarios de composición sin requerir una homogenización previa de los datos.

- Modelación de relaciones no lineales y complejas:
  A diferencia de modelos lineales tradicionales, Random Forest es capaz de capturar interacciones no evidentes entre variables, lo cual resulta particularmente útil para representar dinámicas complejas en procesos biológicos como la digestión anaerobia.

- Resistencia al sobreajuste (overfitting)
  Al combinar los resultados de múltiples árboles construidos de manera aleatoria, el modelo reduce significativamente el riesgo de sobreajuste, mejorando su capacidad de generalización frente a nuevos conjuntos de datos.

- Identificación de variables relevantes
  El algoritmo entrega métricas de importancia para cada variable, lo cual permite identificar qué características del sustrato (como contenido de materia orgánica, sólidos, nutrientes o proporción de agua) tienen mayor impacto sobre la producción de biogás, optimizando así la toma de decisiones técnicas.

- Robustez ante valores atípicos y datos faltantes
  Random Forest presenta una alta tolerancia frente a valores anómalos o incompletos, una propiedad especialmente valiosa en contextos donde el análisis de residuos puede presentar inconsistencias o limitaciones analíticas.

Estas propiedades convirtieron a Random Forest en una herramienta robusta, versátil y confiable para predecir la producción de biogás a partir de residuos cerveceros complejos, alineándose con los objetivos planteados en este estudio.

5.2.10.2. Importación de herramientas de la librería

Para la construcción del modelo de inteligencia artificial se utilizaron herramientas provistas por librerías de Python especializadas en ciencia de datos y aprendizaje automático. Estas bibliotecas contienen funciones optimizadas que permitieron desarrollar, entrenar y evaluar modelos de forma eficiente y reproducible.

Entre las principales librerías a utilizar se encuentran:

- Pandas
  Se utilizó para la manipulación y análisis de datos tabulares. Esta herramienta permitió cargar el dataset, seleccionar variables, filtrar muestras y preparar el conjunto de datos antes de alimentar el modelo.

- NumPy
  Esta biblioteca facilitó la gestión de arreglos numéricos y operaciones matemáticas de base, necesarias para realizar cálculos durante las etapas de preprocesamiento y evaluación del modelo.

- Scikit-learn (sklearn)
  Fue la biblioteca principal para la implementación del modelo de aprendizaje automático. En particular, se utilizaron funciones de la sublibrería ensemble, donde se encuentra el algoritmo Random Forest Regressor, así como herramientas para dividir el conjunto de datos (train_test_split), aplicar validación cruzada (KFold), calcular métricas de evaluación (r2_score, mean_absolute_error, mean_squared_error, etc.) y realizar transformaciones como normalización (MinMaxScaler) o codificación de variables categóricas (get_dummies).

- SHAP (SHapley Additive exPlanations)
  Para interpretar las predicciones del modelo y comprender el impacto individual de cada variable en la producción de biogás, se empleó esta biblioteca basada en teoría de juegos. SHAP permitió construir gráficos explicativos y asignar un valor de contribución a cada característica por observación.

- Matplotlib y Seaborn (cuando fue necesario)
  En etapas posteriores de visualización, se recurrió a estas librerías para generar gráficos de correlación, análisis exploratorio o interpretación de los resultados del modelo.

La utilización combinada de estas herramientas permitió estructurar un flujo de trabajo robusto, desde el tratamiento inicial de los datos hasta la evaluación y explicación final del modelo de predicción. Cada una de estas bibliotecas fue importada y utilizada de forma modular, asegurando la trazabilidad y transparencia del proceso.

5.2.10.3. División del conjunto de datos

Para evaluar la capacidad predictiva del modelo desarrollado, se empleó una estrategia de validación que combinó dos enfoques complementarios. En primer lugar, se utilizó la técnica de hold-out, la cual permite contar con un conjunto de datos independiente para verificar el desempeño general del modelo frente a datos no vistos durante el entrenamiento.

Posteriormente, se aplicó la validación cruzada mediante k-fold sobre el conjunto de entrenamiento, con el objetivo de obtener una estimación más robusta del rendimiento del

modelo. Esta técnica facilitó una evaluación interna más confiable y redujo el riesgo de sesgo derivado de una única partición de los datos.

Este enfoque combinado proporcionó un equilibrio adecuado entre evaluación externa e interna, asegurando tanto la generalización del modelo como la consistencia de sus resultados.

5.2.10.3.1. Carga de datos

Como primer paso en la estrategia de validación, se separó un porcentaje del conjunto total de datos para destinarlo exclusivamente a la evaluación final del modelo. Esta técnica, conocida como Hold Out, consistió en reservar un subconjunto independiente que no se utilizó durante el entrenamiento ni la validación interna.

El resto de los datos se empleó para entrenar y validar el modelo mediante técnicas complementarias, buscando asegurar una evaluación robusta y confiable.
Esta combinación de métodos permitió valorar tanto el desempeño interno del modelo como su capacidad para generalizar frente a datos nuevos.

5.2.10.3.2. Hold Out del 20%

Como primer paso en la estrategia de validación, se separó el 20% del conjunto total de datos para ser utilizado exclusivamente en la etapa final de evaluación del modelo. Esta técnica, conocida como Hold Out, permitió disponer de un subconjunto completamente independiente que no fue expuesto durante el entrenamiento ni la validación interna del algoritmo.

La elección del 20% se justificó como una proporción equilibrada que permitió conservar una cantidad representativa de datos para evaluar la capacidad predictiva del modelo en situaciones nuevas. Esta división se realizó de manera aleatoria, pero controlada mediante una semilla fija, asegurando así la reproducibilidad del proceso.

Esta reserva de datos cumplió un rol clave en la validación externa, ya que permitió comprobar si el modelo aprendió patrones generales o simplemente se ajustó a las particularidades del entrenamiento.

5.2.10.3.3. K-fold del 80%

Con el objetivo de optimizar el rendimiento del modelo y evitar el sobreajuste, se aplicó validación cruzada tipo K-Fold sobre el 80% del conjunto de datos destinado al entrenamiento. Esta técnica dividió el conjunto en k particiones de igual tamaño. En cada iteración, una partición se utilizó como conjunto de validación y las restantes para entrenar el modelo, repitiendo el proceso hasta que cada partición fue usada una vez como validadora.

Esta metodología permitió evaluar el modelo en diferentes subconjuntos, reduciendo el sesgo de una única división y entregando una estimación más robusta del rendimiento.

Uno de los principales aportes del K-Fold fue la optimización de los hiperparámetros del algoritmo Random Forest, buscando la combinación que maximizara el rendimiento promedio. Los hiperparámetros ajustados incluyeron:

- n_estimators: cantidad de árboles del bosque.
- max_depth: profundidad máxima de cada árbol.
- min_samples_split: número mínimo de muestras para dividir un nodo.
- min_samples_leaf: número mínimo de muestras en una hoja terminal.
- max_features: número de variables consideradas al buscar la mejor división.

Estos ajustes permitieron construir un modelo más preciso, evitando el sobreajuste y mejorando su capacidad de generalización. Además, la comparación de métricas entre los distintos pliegues facilitó la identificación de la configuración con mejor desempeño general.
Esta etapa resultó esencial para asegurar que el modelo desarrollado fuera aplicable en contextos reales, caracterizados por la variabilidad natural de los residuos cerveceros.

5.2.10.4. Prueba del modelo sobre Hold Out

Una vez finalizado el proceso de validación cruzada y seleccionada la configuración óptima del modelo, se procedió a evaluarlo utilizando el 20% de los datos reservados previamente para este propósito (fase Hold Out). Esta etapa simuló un escenario real, enfrentando al modelo a datos completamente nuevos, no utilizados durante su entrenamiento ni validación interna.

El objetivo principal de esta prueba fue verificar la capacidad de generalización del modelo, es decir, su habilidad para predecir con precisión en contextos desconocidos. Para ello, se

calcularon métricas de rendimiento que permitieron comparar los resultados obtenidos en esta fase con los registrados durante la validación cruzada.

Si los resultados fueron similares en ambas etapas, se consideró que el modelo había aprendido patrones genuinos. En cambio, si se observó una caída significativa en el desempeño, se interpretó como una señal de sobreajuste. En ese caso, fue necesario realizar ajustes adicionales en el entrenamiento, tales como:

- Regularización del modelo: se ajustaron parámetros que controlaban la complejidad, como limitar la profundidad máxima de los árboles o el número mínimo de muestras por hoja.

- Aumento del tamaño del conjunto de datos: se incorporaron más muestras para que el modelo generalizara mejor, cuando fue posible.

- Simplificación del modelo: se redujo la cantidad de variables o se seleccionaron solo las más relevantes para evitar ruido que complicara el aprendizaje.

- Optimización de hiperparámetros: se realizó una búsqueda más exhaustiva de los mejores parámetros mediante técnicas como Grid Search o Random Search.

- Aplicación de técnicas de reducción de dimensionalidad: se eliminaron variables redundantes y se mejoró la eficiencia del modelo.

Estos pasos buscaron mejorar la capacidad del modelo para capturar patrones generales y evitar que memorizara detalles específicos del conjunto de entrenamiento.

Esta prueba marcó una instancia clave de validación externa, previa a la evaluación detallada del modelo y su interpretación.

5.3. METODOLOGÍA TERCER OBJETIVO ESPECÍFICO

La metodología aplicada para el tercer objetivo específico se centró en la evaluación de la sensibilidad del modelo predictivo desarrollado, con el fin de identificar las variables que más influyeron en el rendimiento de producción de biogás bajo distintos escenarios. Para ello, se utilizaron herramientas de explicabilidad del modelo que permitieron interpretar y jerarquizar la importancia relativa de cada variable utilizada en el algoritmo.

5.3.1. Evaluación del modelo

Tras aplicar el modelo sobre el conjunto de datos reservado para la prueba (el 20% Hold Out), se procedió a evaluar su rendimiento mediante diversas métricas de regresión. El propósito principal de esta etapa fue cuantificar con precisión la capacidad predictiva del modelo, evaluando qué tan bien generalizaba frente a datos que no fueron vistos durante el entrenamiento.

Esta evaluación entregó una visión integral del comportamiento del modelo, revelando tanto la magnitud de los errores cometidos como el grado en que logró explicar la variabilidad observada en la producción de biogás.

Para esta evaluación se analizaron los indicadores estadísticos de la tabla 5.1, calculados sobre el conjunto de prueba:

Tabla 5.1: Métricas utilizadas para la evaluación del modelo.
Fuente: Elaboración propia.

Métrica	**Descripción**	**Interpretación clave**
Coeficiente de determinación (R^2)	Mide la proporción de la variabilidad en los datos reales que el modelo logra explicar.	Valores cercanos a 1 indican alta capacidad predictiva; valores cerca de 0 indican bajo poder explicativo.
Error absoluto medio (MAE)	Representa el error promedio absoluto entre predicciones y valores reales, sin distinguir sobre- o subestimaciones.	Un MAE bajo implica que las predicciones están muy cerca de los valores reales en promedio.
Error porcentual medio (MAPE)	Expresa el error promedio relativo como porcentaje del valor real, normalizando según la magnitud de los datos.	Útil para comparar precisión en datos con diferentes escalas; valores bajos indican alta precisión.
Raíz del error cuadrático medio (RMSE)	Calcula la desviación estándar de los errores, ponderando más fuertemente los errores grandes.	Un RMSE bajo sugiere poca dispersión y pocas predicciones con errores graves.

Las métricas R^2, MAE y RMSE fueron importadas desde la biblioteca Scikit-learn, específicamente desde su módulo metrics, que ofrecía funciones optimizadas y ampliamente utilizadas para estos cálculos.

Por otro lado, dado que el MAPE no estaba disponible universalmente en todas las versiones de Scikit-learn ni en NumPy, se implementó como una función personalizada que calculaba el error porcentual medio, asegurando su correcta incorporación en el análisis.

5.3.2. Explicación del modelo

Una vez que el modelo estuvo entrenado y evaluado, se pasó a una etapa crucial: entender cómo funcionaba por dentro y qué lo hacía tomar las decisiones que tomaba. Esto resultó necesario para validar que las predicciones fueran coherentes y para aportar transparencia a todo el proceso, sobre todo considerando la complejidad y heterogeneidad de los residuos cerveceros que se estudiaron.

Para lograr esto, se usaron herramientas específicas que permitieron interpretar modelos tipo caja negra, como fue el caso del Random Forest. Estas herramientas ayudaron a desentrañar qué variables tuvieron más peso en la predicción y cómo influyeron en los resultados.
En particular, se implementaron dos enfoques complementarios:

5.3.2.1. Análisis de importancia de características (Feature Importance)

Para entender qué variables tuvieron más peso a la hora de hacer predicciones, se utilizó la técnica de Feature Importance. Básicamente, esta herramienta midió la relevancia relativa de cada variable que alimentó al modelo, analizando con qué frecuencia y qué tan eficazmente se utilizaron para construir los árboles de decisión dentro del Random Forest.

En la práctica, lo que hizo fue revisar cuántas veces cada variable fue usada para dividir los datos en los distintos árboles, y cuánto mejoró la precisión cada vez que se tomó esa decisión. Así, se pudo asignar un “puntaje” que reflejó la importancia de cada característica.

Los resultados se visualizaron con un gráfico de barras que mostró de manera intuitiva qué variables tuvieron mayor influencia en la predicción de la producción de biogás.

Este análisis no solo aportó transparencia al modelo, sino que también fue clave para identificar cuáles componentes específicos del residuo (por ejemplo, ciertos nutrientes, compuestos orgánicos o parámetros fisicoquímicos) realmente movieron la aguja en el desempeño del sistema.

5.3.2.2. SHAP (SHapley Additive exPlanations)

Para profundizar aún más en cómo el modelo tomó sus decisiones, se utilizó SHAP, una técnica que descompone la predicción total en aportes individuales de cada variable. Esto permitió ver con claridad no sólo cuáles características influyeron más en general (a nivel global), sino también cómo afectaron las predicciones en casos específicos.

En otras palabras, SHAP ayudó a "abrir" la caja negra del Random Forest para entender mejor el impacto que tuvo cada factor en cada resultado particular. Esta transparencia facilitó considerablemente la interpretación, validación y confianza en los resultados que entregó el modelo.

Con SHAP se generaron gráficos explicativos que mostraron, por ejemplo, si un valor alto o bajo de una variable aumentaba o disminuía la producción de biogás, ayudando así a tomar decisiones técnicas más informadas y certeras.

Estas metodologías permitieron profundizar en la lógica interna del modelo y aportar información valiosa para tomar decisiones técnicas con fundamento, maximizando el aprovechamiento de los residuos cerveceros.

6. DESARROLLO DEL MODELO PREDICTIVO Y ANÁLISIS DE VARIABLES

Con el fin de cumplir con el primer objetivo específico del presente estudio, se identificaron las variables más relevantes que influyen en la producción de metano a partir de residuos cerveceros mediante digestión anaerobia. Esta sección no presenta resultados experimentales propios, sino que corresponde a un análisis técnico de la literatura científica disponible. El enfoque adoptado es de carácter cualitativo, orientado a interpretar y sistematizar información existente con el fin de identificar las variables que serán utilizadas como entradas para el modelo de inteligencia artificial desarrollado en esta investigación.

6.1. RELACIÓN GENERAL ENTRE VARIABLES Y LA PRODUCCIÓN DE BIOGÁS

La producción de biogás a partir de residuos cerveceros (como bagazo de cerveza, lodos y aguas residuales) depende de múltiples variables de entrada, tanto de la composición del sustrato como de las condiciones operativas del proceso (Sganzerla et al., 2023; Szaja et al., 2020). Estudios previos destacan que el rendimiento del biogás está fuertemente influenciado por factores como la temperatura de operación, el pH, la carga orgánica aplicada y el tiempo de retención, entre otros (Szaja et al., 2020; Miller et al., 2021). Estas variables interactúan de forma compleja y no lineal, por lo que resulta adecuado emplear un modelo de Random Forest Regressor para capturar dichas relaciones (Vitanza et al., 2016). Un Random Forest puede aprender patrones y relaciones complejas entre las variables independientes y la producción de biogás sin asumir una forma funcional fija, identificando incluso interacciones entre variables que serían difíciles de modelar de manera tradicional (Vitanza et al., 2016). De esta manera, la IA podrá aprender cómo cada variable afecta al resultado, y mediante técnicas como la importancia de variables o los valores SHAP es posible cuantificar la contribución de cada factor a la predicción (Vitanza et al., 2016). A continuación, se detalla la relación esperada de cada variable con la producción final de biogás, basada en literatura especializada y resultados experimentales.

6.2. VARIABLES DE COMPOSICIÓN DEL SUSTRATO

Las características del sustrato determinan en gran medida el rendimiento del proceso de digestión anaerobia. En esta sección se analizan los principales componentes generados por la industria cervecera y su influencia sobre la producción de metano.

6.2.1. Bagazo Cervecero (Bagazo de Cerveza, BSG) – Residuos de Grano

El bagazo cervecero es el residuo sólido principal de la industria cervecera (granos agotados de cebada malteada). Su influencia en la producción de biogás es compleja debido a su composición rica en fibra. El bagazo contiene alta fracción de lignocelulosa (celulosa 12–25%, hemicelulosa 20–35% y lignina 10–28%) y también una proporción notable de proteínas (19–30%) (Vitanza et al., 2016; Szaja et al., 2020).

- Biodegradabilidad limitada: La lignina y las fibras en el bagazo dificultan su degradación anaerobia, actuando como una barrera física para la acción microbiana. En ausencia de pretratamientos, solo una parte del bagazo es accesible a los microorganismos, por lo que una mayor proporción de bagazo en la mezcla puede reducir la producción específica de biogás. De hecho, se ha observado que la adición de bagazo sin pretratar puede inhibir el proceso digestivo y disminuir significativamente la generación de metano (Szaja et al., 2020; Sillero et al., 2024). En pruebas BMP (Potencial Bioquímico de Metano), al co-digerir agua residual cervecera con bagazo, la producción de metano cayó a apenas ~20–23 mL CH_4/g VS, comparado con rendimientos de 104–170 mL CH_4/g VS cuando se digiere solo el agua residual sin bagazo (Sillero et al., 2024). Esto indica que un exceso de bagazo en el sustrato puede resultar en menor biogás, debido a su fracción no degradable e incluso a posibles inhibiciones por compuestos liberados (por ejemplo, acumulación de ácidos grasos volátiles o amoníaco a partir de las proteínas del bagazo) (Szaja et al., 2020; Vitanza et al., 2016).

- Efecto de cantidades moderadas y co-digestión: Aunque proporciones altas de bagazo reducen la eficiencia, cantidades moderadas de bagazo mezcladas con otros sustratos pueden tener un efecto beneficioso en ciertos contextos al aportar materia orgánica adicional y nutrientes. Por ejemplo, un estudio reciente mezcló agua residual cervecera con lodos de planta de tratamiento y agregó un 12,5% de bagazo (BSG); esa condición alcanzó la mayor producción de metano (~88 mL CH_4/g VS), la cual fue 20 veces superior al experimento control sin bagazo (solo agua residual + lodo, ~4,26 mL CH_4/g VS) (Sganzerla et al., 2023). Esto sugiere que pequeñas adiciones de bagazo, en conjunto con co-sustratos adecuados y bajo condiciones controladas (pH neutralizado, inóculo adaptado, etc.), pueden mejorar la producción al balancear nutrientes. El bagazo aporta carbono estructural y algunos micronutrientes, mientras que otros sustratos (p. ej., lodos o residuos líquidos) aportan compuestos más fácilmente biodegradables y alcalinidad para amortiguar la acidez (Miller et al., 2021; Szaja et al., 2020). En resumen, incrementar la fracción de bagazo en el sustrato tiende a disminuir el rendimiento de biogás si supera cierta proporción o si no se trata, pero una dosificación óptima baja (o de bagazo pretratado) podría integrarse para valorizar este residuo sin afectar severamente la

producción. Identificar ese punto óptimo es clave; por ello, la IA analizará los datos de co-digestión para aprender el impacto no lineal de esta variable (Vitanza et al., 2016).

- Relación C/N y nutrientes: El bagazo cervecero típicamente tiene una relación Carbono/Nitrógeno alta (>30:1), debido a su contenido mayoritario de carbono orgánico comparado con nitrógeno. Por sí solo, un C/N muy elevado puede implicar déficit de nitrógeno para las bacterias (limitando su crecimiento). Sin embargo, el bagazo también contiene proteínas (fuente de N); de hecho, si se acumula mucha proteína degradada, puede liberar amoníaco y elevar el pH en exceso (Szaja et al., 2020). En co-digestión, el bagazo debe combinarse con sustratos nitrogenados (ej. lodos) para alcanzar un balance C/N óptimo ~20–30:1 que favorezca la metanogénesis (Miller et al., 2021; Sganzerla et al., 2023). La IA podrá identificar cómo la presencia de bagazo alterando el C/N influye en la producción: un bagazo sin suficiente nitrógeno puede ralentizar la digestión, mientras que bagazo junto a fuentes de nitrógeno adecuadas permite un rendimiento mayor de biogás.

En síntesis, la variable "porcentaje de bagazo en la mezcla" afecta negativamente al biogás cuando es alta (debido a baja degradabilidad e inhibición potencial), pero en niveles bajos a moderados, con buen equilibrio de nutrientes, puede integrarse sin grandes penalizaciones e incluso mejorar el aprovechamiento energético total de los residuos. Un modelo Random Forest puede aprender este efecto no lineal, identificando que inicialmente pequeñas cantidades de bagazo podrían aumentar la producción (aportando material orgánico adicional), pero cantidades mayores la reducen drásticamente (Vitanza et al., 2016).

6.2.2. Lodo Cervecero (Biosólidos/Levadura Residual)

El lodo cervecero se refiere a los residuos semisólidos generados en la industria cervecera, que pueden incluir levadura residual de la fermentación, sedimentos del proceso y/o lodos provenientes del tratamiento de aguas cerveceras. Este material es rico en biomasa microbiana y compuestos orgánicos digeridos parcialmente (Szaja et al., 2020; Sganzerla et al., 2023).

- Fuente de microorganismos e inóculo: El lodo cervecero a menudo contiene una alta densidad de microorganismos (por ejemplo, levaduras o bacterias muertas y vivas). Al incorporarlo en la digestión anaerobia, actúa en parte como inóculo adicional, aportando poblaciones microbianas que pueden facilitar la degradación. También aporta alcalinidad y micronutrientes, ya que los lodos suelen contener carbonatos y nutrientes celulares (Szaja et al., 2020).

- Contenido orgánico moderadamente biodegradable: En términos de composición, el lodo cervecero (especialmente si proviene de tratamiento aeróbico de efluentes o de levadura residual) tiene fracción orgánica ya parcialmente estabilizada. La levadura residual está

compuesta de proteínas y lípidos celulares que son biodegradables, aunque las paredes celulares pueden resistir algo la digestión. Los lodos biológicos suelen tener un porcentaje de sólidos volátiles que aún pueden degradarse anaeróbicamente, aunque más lentamente que azúcares simples (Miller et al., 2021; Sganzerla et al., 2023). Por ello, aumentar la proporción de lodo en la mezcla añade carga orgánica susceptible de convertirse en metano, pero típicamente con una tasa de producción moderada. No genera tanto biogás rápidamente como la fracción soluble de un residuo líquido, pero provee una base estable de degradación más lenta.

- Balance de nutrientes (C/N) y amoníaco: A diferencia del bagazo, el lodo cervecero (especialmente si incluye levadura) es rico en nitrógeno (proteínas celulares). Esto ayuda a balancear el C/N cuando se co-digiere con residuos muy carbonosos como el bagazo (Szaja et al., 2020; Sillero et al., 2024). Sin embargo, si la cantidad de lodo (y por ende de proteínas) es muy alta respecto al carbono, puede producirse una concentración elevada de amoníaco al degradarse las proteínas. Un exceso de amoníaco libre elevará el pH por encima del óptimo e inhibirá a las arqueas metanogénicas (Miller et al., 2021; Vitanza et al., 2016). Por tanto, existe un punto óptimo en el que el lodo aporta nitrógeno suficiente para los microbios sin causar toxicidad por amoníaco. La IA deberá capturar cómo variaciones en la dosis de lodo afectan el rendimiento: cantidades moderadas mejoran el rendimiento al corregir C/N, pero un exceso podría eventualmente reducirlo por inhibición amoniacal.

- Dilución y sólidos totales: El lodo cervecero suele venir con humedad alta (contenido acuoso). Al mezclarlo, puede ayudar a mantener los sólidos totales (TS) de la mezcla en rangos manejables. Se recomienda en general trabajar con ~5–15% de sólidos totales en el digerido; el lodo, al ser más líquido que el bagazo, ayuda a diluir la mezcla si fuera muy densa, mejorando la mezclabilidad y contacto (Sganzerla et al., 2023). Esto puede aumentar la eficiencia de digestión. Por otro lado, demasiada agua (si el lodo es muy diluido) bajaría la concentración de sólidos volátiles totales, reduciendo la tasa de producción volumétrica de biogás. Así, el lodo aporta un equilibrio hídrico a la mezcla.

En resumen, el lodo cervecero como variable contribuye positivamente al proceso al aportar microorganismos, alcalinidad y nitrógeno, lo que puede incrementar la producción de biogás cuando equilibra al bagazo. Su materia orgánica es menos fácilmente convertible que la de un residuo soluble, pero más que la lignocelulosa pura, por lo que tiene un efecto intermedio en la producción. Una mayor proporción de lodo tiende a aumentar la producción de biogás hasta cierto punto (por mayor VS disponible y mejor balance nutrimental), pero excesos pueden causar inhibición por amoníaco si no hay suficiente carbono disponible. El Random Forest podrá aprender este balance, identificando que el lodo generalmente mejora el rendimiento

(especialmente cuando acompaña al bagazo), pero con rendimientos marginales decrecientes si se usa en demasía o sin suficiente co-sustrato carbonoso (Vitanza et al., 2016; Szaja et al., 2020).

6.2.3. Agua Residual Cervecera (Aguamiel Cervecera)

El agua residual de cervecería es un efluente líquido con alta carga orgánica soluble (azúcares, alcoholes, ácidos orgánicos, proteínas solubles) procedente de la limpieza, enfriamiento de mosto, lavado de equipos y otros procesos cerveceros (Szaja et al., 2020; Miller et al., 2021). Su impacto en la producción de biogás es generalmente muy positivo, debido a que:

- Alto contenido orgánico fácilmente degradable: La cerveza y sus residuos líquidos contienen muchos compuestos fácilmente biodegradables (azúcares residuales, etanol, ácidos volátiles). Esto se refleja en una Demanda Química de Oxígeno elevada (por ejemplo, en cervecerías grandes se reportan ~50 g O_2/L de DQO en el agua residual). Al ser rápidamente convertibles en ácidos grasos volátiles y luego en metano, incrementar la fracción de agua residual en el sustrato suele aumentar la producción de biogás de forma notable, al menos hasta cierto punto (Sillero et al., 2024; Miller et al., 2021). En pruebas de digestión, la monodigestión de agua residual cervecera ha logrado rendimientos de metano elevados (por ejemplo, ~0,76 g CH_4/g VS·día en condiciones mesofílicas en un estudio continuo, o alrededor de 0,17 m^3 CH_4/kg VS en BMP mesofílico) (Szaja et al., 2020). Estos valores muestran que el potencial metanogénico del agua cervecera es alto. En el estudio de Sillero et al. (2024), las muestras con solo agua residual alcanzaron ~104 mL CH_4/g VS (mesófilo) y ~171 mL CH_4/g VS (termófilo), muy superiores a las mezclas con bagazo. Esto confirma que la mayor disponibilidad de sustratos solubles produce más biogás rápidamente.

- Efecto de la fracción (mezcla óptima): Aunque más agua residual aporta más carbohidratos fermentables (lo que acelera y eleva la producción), existe un límite práctico. Estudios de co-digestión con lodos indican que añadir agua residual hasta cierto porcentaje mejora el rendimiento, pero más allá puede desequilibrar el proceso. Por ejemplo, Zhang et al. (2023) encontraron que una proporción de mezcla de ~20% de agua cervecera (v/v) con lodo de alcantarillado maximizó la producción de biogás a 34 °C (Miller et al., 2021). Incrementar la fracción líquida por encima de ese 20% no resultó en más biogás, posiblemente debido a problemas de pH y sobrecarga ácida. Esto se debe a que el agua cervecera tiene a veces un pH bajo (~4–5) por su contenido ácido. Demasiado volumen de agua residual puede provocar acidificación: la rápida producción de ácidos grasos volátiles, si supera la capacidad tampón del sistema, lleva el pH fuera del rango óptimo de metanogénesis (Szaja et al., 2020; Vitanza et al., 2016). En consecuencia, la

eficiencia metanogénica decae si no se controla. Mantener una proporción moderada y un pH adecuado permite aprovechar la alta biodegradabilidad de este efluente sin acidificar el digestor.

- Alcalinidad y necesidad de ajuste de pH: A diferencia de muchos residuos industriales, el agua cervecera contiene algo de alcalinidad natural (p. ej., ~6 g/L $CaCO_3$), pero no siempre suficiente (Sganzerla et al., 2023). Antes de ingresarla al digestor, es común verificar y ajustar el pH inicial del sustrato si está fuera de ~6.5–7.5. En la co-digestión, el lodo aporta amortiguación (alcalinidad) que ayuda a contrarrestar la acidez de la fracción líquida. La IA aprenderá que cuando la variable "porcentaje de agua residual" aumenta, la producción de biogás sube rápidamente al principio (por mayor DQO disponible), pero podría requerir la presencia de suficiente alcalinidad (proveniente de lodo u aditivos) para sostener ese aumento. Si la capacidad tampón del sistema (alcalinidad) no crece a la par, entonces más agua residual eventualmente causa inhibición por caída de pH. Por tanto, la relación no es simplemente "más agua = más biogás" linealmente, sino que muestra un óptimo de mezcla (Vitanza et al., 2016).

En resumen, la variable “fracción de agua residual cervecera” tiene una influencia positiva importante en la producción de biogás debido a su alta carga orgánica rápidamente digerible, tal como se puede apreciar en la Tabla 6.1. Dentro de un rango seguro, incrementar esta fracción eleva el rendimiento de metano significativamente. Sin embargo, la IA también deberá capturar que más allá de cierta proporción crítica, el beneficio se estanca o revierte por efectos de inhibición ácida, a menos que se mitiguen con control de pH y nutrientes. En la práctica, combinar aproximadamente un 10–20% de agua residual con sustratos más sólidos brinda un efecto sinérgico: se mejora la degradación del material sólido al aportar compuestos de fácil consumo y humedad, y se maximiza el uso de la capacidad metanogénica del sistema antes de llegar a límites operativos (Sillero et al., 2024; Miller et al., 2021).

Tabla 6.1: Resumen general de variables del sustrato.
Fuente: Elaboración propia

Componente del sustrato	**Tipo**	**Efecto esperado en la digestión anaerobia**	**Riesgo en exceso o defecto**	**Referencias clave**
Bagazo cervecero (BSG)	Fibroso-carbonoso	Aporta materia orgánica estructural (VS), carbono y algo de proteína.	Alta lignina = baja biodegradabilidad. Exceso → inhibición por acumulación de AGV o amoníaco.	Szaja et al., 2020; Sillero et al., 2024

Lodo cervecero (levadura, sedimentos, biosólidos)	Nitrogenado -orgánico	Aporta microorganismos, nitrógeno y alcalinidad. Mejora el equilibrio C/N.	Exceso de N → acumulación de amoníaco libre, inhibición metanogénica.	Sganzerla et al., 2023; Miller et al., 2021
Agua residual cervecera (aguamiel)	Líquido-soluble	Alta carga orgánica soluble (azúcares, alcoholes). Favorece rápida generación de biogás.	Exceso → acidificación del sistema. Requiere control de pH y alcalinidad suficiente.	Szaja et al., 2020; Vitanza et al., 2016

6.3. PARÁMETROS FÍSICOS Y QUÍMICOS DEL SUSTRATO

Además de la identidad de cada subproducto (bagazo, lodo, agua), hay propiedades del sustrato en conjunto que influyen en la producción de biogás y que el modelo incluirá:

6.3.1. Sólidos Totales (TS%)

Indican la concentración total de materia (sólidos) en la mezcla. Un TS muy elevado (>15%) implica un medio más denso, tipo digestión seca, que puede dificultar la mezcla y el contacto microorganismo-sustrato; esto suele reducir la velocidad de producción de biogás. Por otro lado, un TS muy bajo (<5%) significa mucha dilución (digestión muy húmeda), lo cual aunque facilita la mezcla, disminuye la productividad volumétrica (poco sustrato por volumen de reactor). Se recomienda típicamente mantener los sólidos totales de la mezcla en un rango de 5–15% para balancear manejabilidad y concentración (Szaja et al., 2020; Miller et al., 2021). Por tanto, la IA reconocerá que ajustar TS dentro de ese rango favorece la producción: si TS sube de ~15%, la producción específica (m^3 biogás por kg VS) podría no bajar mucho pero la producción volumétrica y la estabilidad sí pueden verse afectadas (acumulación local de ácidos, zonas secas); si TS está por debajo de ~5%, el reactor está infrautilizado en términos de carga.

6.3.2. Sólidos Volátiles (VS% de TS)

Representan la fracción orgánica biodegradable. Un contenido de VS alto en el sustrato (porcentaje de los sólidos que es orgánico) significa que hay más material convertible en biogás (Sganzerla et al., 2023). El modelo verá que, en general, mayor VS cargado produce mayor

biogás total. Sin embargo, diferentes VS tienen distinta biodegradabilidad: aquí es donde importan las variables de tipo de sustrato. No todo el VS del bagazo es fácilmente aprovechable (por la lignina), mientras que casi todo el VS del agua residual sí lo es (Sillero et al., 2024). Entonces, no solo la cantidad de VS importa, sino su calidad. La IA utilizará las variables de composición para matizar el efecto de VS: por ejemplo, 1 kg VS de agua residual produce más biogás que 1 kg VS de bagazo sin tratar. En cualquier caso, incrementar la carga de VS hasta el nivel óptimo de operación (ver OLR más adelante) aumenta la producción total, pero la producción específica por kg VS podría variar según la fuente.

6.3.3. Relación C/N del sustrato mixto

Como ya se mencionó, este indicador surge de las proporciones de bagazo (rico en C) vs lodo/levadura (rico en N) vs otros. Mantener el C/N alrededor de 20–30 es ideal para la actividad metanogénica. Si el modelo ve un C/N muy por encima (exceso de carbono, poco N), seguramente identificará menor producción (los microbios carecen de proteínas para crecer, digestión más lenta). Si el C/N está muy por debajo (exceso de nitrógeno/proteínas), es indicativo de posible estrés por amoníaco y el rendimiento también puede caer (Vitanza et al., 2016; Miller et al., 2021). Por ello, esta relación subyace a los efectos combinados de bagazo, lodo y agua: el Random Forest podría inferir, por ejemplo, que combinaciones con relaciones C/N elevadas (asociadas a una mayor proporción de bagazo respecto al lodo) resultan en menor producción de biogás, mientras que mezclas con C/N dentro del rango óptimo (20–30) presentan un mejor desempeño, incluso si el total de VS es el mismo.

6.3.4. Contenido de lignina y fibra

Cuanto mayor es la fracción de lignina, celulosa cristalina y hemicelulosa en el VS total, menor es la fracción realmente convertible en el tiempo típico de retención. El bagazo aporta la mayor parte de esta variable (Sillero et al., 2024; Szaja et al., 2020). Por tanto, un aumento en el contenido fibroso del sustrato (variable correlacionada con la proporción de bagazo en la mezcla, expresada como "% de bagazo") tendrá un efecto negativo en la producción final alcanzable de biogás. Esto se manifiesta en que las curvas de producción no logran convertir el 100% de los VS cargados en biogás incluso tras largos periodos. El modelo de IA, apoyado por suficientes datos experimentales, podría captar que altos valores de lignocelulosa están asociados a menores rendimientos específicos (m^3/kg VS). En la práctica, este efecto se mitiga con pretratamientos (no considerados aquí) o con co-digestión (diluir la lignina con otros sustratos).

6.3.5. pH inicial del sustrato

Cada componente puede tener un pH distinto (el bagazo fresco puede ser neutro-ligeramente ácido, la levadura puede generar compuestos básicos al degradarse, el agua residual suele ser

ácida). Antes de la digestión, es importante el pH de la mezcla inicial, ya que un pH muy lejos del neutro afectará la fase inicial de la digestión (Sganzerla et al., 2023; Vitanza et al., 2016). Si el pH inicial está fuera de ~6.5–7.5, a menudo se ajusta (por ejemplo, con cal o buffer). El modelo puede incluir esta variable para reflejar que mezclas con pH inicial ajustado adecuadamente tienden a rendir más biogás que aquellas donde el pH inicial era extremo (que podrían necesitar tiempo para autocorregirse o sufrir inhibición en la fase de arranque).

En conjunto, las propiedades físico-químicas del sustrato determinan la calidad del material alimentado al digestor. El Random Forest considerará estas variables para aprender, por ejemplo, que "X% de sólidos totales con Y% de volátiles y C/N=Z conduce a Q m³/kg VS". En general, un sustrato con VS elevado, C/N balanceado, baja lignina, TS moderado y pH neutro será óptimo para generar mucho biogás. Cualquier desviación de esos rangos (por exceso de sólidos, desequilibrio C/N, mucha lignina, etc.) afecta negativamente la producción (Miller et al., 2021; Sillero et al., 2024).

La Tabla 6.2 resume la información recopilada en este capítulo.

Tabla 6.2: Resumen general parámetros físico-químicos del sustrato.
Fuente: Elaboración propia

Variable	**Tipo**	**Efecto esperado**	**Riesgo en exceso o defecto**	**Referencias clave**
Sólidos Totales (TS%)	Físico-química	Ideal entre 5–15%. A mayor TS, mayor concentración de sustrato.	>15%: mezcla densa, riesgo de zonas secas, acumulación de ácidos. <5%: baja carga útil.	Szaja et al., 2020; Miller et al., 2021
Sólidos Volátiles (VS% de TS)	Físico-química	A mayor VS, más materia biodegradable → mayor producción potencial de biogás.	VS de baja calidad (lignina) reduce la producción. No todo el VS es igualmente aprovechable.	Sganzerla et al., 2023; Sillero et al., 2024

Relación C/N del sustrato mixto	Nutricional	Óptimo entre 20–30:1. Buen equilibrio para el crecimiento microbiano.	>35: déficit de N, digestión lenta. <15: exceso de N → acumulación de amoníaco → inhibición.	Vitanza et al., 2016; Miller et al., 2021
Contenido de lignina y fibra	Composición	Alta lignina = baja biodegradabilidad. Afecta negativamente la producción de biogás.	Dificulta la hidrólisis. Exceso de bagazo sin pretratamiento reduce notablemente el rendimiento.	Sillero et al., 2024; Szaja et al., 2020
pH inicial del sustrato	Físico-química	Ideal entre 6.5–7.5. Permite arranque estable del proceso anaerobio.	pH <6.5: inhibición ácida. pH >8.0: inhibición por amoníaco libre.	Sganzerla et al., 2023; Vitanza et al., 2016

6.4. VARIABLES DE LAS CONDICIONES DEL PROCESO

Las condiciones operativas bajo las cuales se desarrolla la digestión anaerobia influyen directamente en la actividad microbiana y, por ende, en la eficiencia del sistema. A continuación, se presentan las principales variables de proceso que afectan la producción de metano a partir de residuos cerveceros.

6.4.1. Temperatura de Operación (Mesofílico vs Termofílico)

La temperatura es uno de los parámetros operativos más influyentes en la digestión anaerobia. Dos rangos son comunes: mesofílico (~30–40 °C) y termofílico (~45–60 °C). La relación de la temperatura con la producción de biogás es la siguiente:

- Cinética más rápida a mayor temperatura: En general, elevar la temperatura dentro del rango biológico acelera las reacciones metabólicas. Bajo condiciones termofílicas (~55 °C), la actividad microbiana (especialmente de las bacterias hidrolíticas y acidogénicas) es más rápida, lo que puede llevar a tasas de producción de biogás más

altas y a una digestión más completa en menor tiempo (Szaja et al., 2020). De hecho, se suele observar un incremento en el rendimiento de metano al pasar de mesofílico a termofílico, si el sustrato no sufre inhibiciones adicionales. Por ejemplo, con agua residual cervecera como sustrato, se registró un aumento del rendimiento desde ~104 mL CH_4/g VS en 35 °C a ~170 mL CH_4/g VS en 55 °C (Sillero et al., 2024). Este ~60% más de biogás en termofílico muestra la ventaja potencial de temperatura alta en sustratos fácilmente degradables.

- Estabilidad y degradación de componentes recalcitrantes: Temperaturas más altas también ayudan a romper componentes complejos hasta cierto punto y pueden reducir la viscosidad, mejorando el contacto. Sin embargo, con sustratos recalcitrantes (como el bagazo rico en lignina), simplemente subir la temperatura no siempre aumenta el rendimiento, porque la limitación es química (lignina) más que cinética. Por ejemplo, en co-digestión de agua cervecera con bagazo, las pruebas mesofílicas vs termofílicas dieron rendimientos muy bajos en ambos casos (~20–23 mL/g VS); el calor extra no logró compensar la inhibición/falta de degradación del bagazo (Miller et al., 2021; Vitanza et al., 2016). Esto indica que la efectividad de la temperatura depende del tipo de sustrato: para materiales fácilmente biodegradables, termofílico saca más provecho; para materiales limitantes, puede no haber gran diferencia si la hidrólisis sigue trabada.

- Riesgos y control: Operar en condiciones termofílicas puede suponer desafíos: las arqueas metanogénicas termofílicas son más sensibles a cambios súbitos y al estrés químico. También, temperaturas altas favorecen mayor liberación de amoníaco de compuestos nitrogenados (mayor volatilización y desamonificación), lo que puede elevar el pH y causar inhibición si el sustrato es muy proteico (Sganzerla et al., 2023). Así, aunque la temperatura alta suele aumentar la producción, también puede conllevar mayor riesgo de inestabilidad del sistema si no se controlan otros factores (pH, sobrecarga). Por el contrario, temperaturas mesofílicas son más estables y las comunidades microbianas más resilientes a fluctuaciones (Miller et al., 2021).

- Fluctuaciones de temperatura: Es importante mantener la temperatura constante; variaciones diarias mayores a 2–3 °C pueden estresar la biota. Si la variable temperatura es inestable, la producción puede caer temporalmente. El modelo aprenderá que no solo importa el nivel de temperatura sino su constancia: una ejecución a 37 °C estable suele rendir mejor que una donde 37±5 °C oscilan, por ejemplo (Szaja et al., 2020).

En resumen, aumentar la temperatura de mesofílico a termofílico tiende a aumentar la producción de biogás (más metano en menos tiempo), siempre que el sistema se mantenga estable y el sustrato no tenga otros factores limitantes. Un Random Forest captará, por ejemplo, un efecto positivo de unos +X m^3/kg VS al pasar de ~35 °C a ~55 °C en condiciones de

operación estables y dentro de rangos adecuados de pH, carga orgánica y composición del sustrato (Sillero et al., 2024). Sin embargo, también puede identificar interacciones: por ejemplo, quizá a alta temperatura el modelo note mayor impacto negativo del amoníaco (si lodo/bagazo son altos en proteína) o de la acumulación de ácidos (si la carga es alta), modulando así la respuesta neta. La elección óptima a veces es una compensación entre mayor velocidad (termofílico) y robustez del proceso (mesofílico). Es por eso que muchos digestores operan en mesofilia a menos que se busque maximizar la tasa y se pueda manejar la complejidad termofílica (Vitanza et al., 2016; Sganzerla et al., 2023).

6.4.2. pH del Sistema y Alcalinidad

El pH dentro del digestor es crítico para la microbiología anaerobia. La metanogénesis eficaz ocurre en un rango aproximadamente neutro: pH 6,5–8,0 (ideal ~7.0). La relación entre pH y producción de biogás es esencialmente que un pH fuera del rango óptimo reduce la producción.

- Consecuencia de pH inapropiado: Si el pH cae por debajo de ~6.5, las arqueas metanogénicas se inhiben fuertemente y prácticamente cesa la producción de metano (Sganzerla et al., 2023; Szaja et al., 2020), aunque las bacterias acidogénicas pueden seguir activas generando ácidos. Un pH excesivamente bajo indica acidificación por acumulación de ácidos grasos volátiles (AGV), situación de “acidosis” que bloquea la fase metanogénica. Por ende, un descenso de pH se refleja en una caída abrupta de producción de biogás. Por otro lado, si el pH sube por encima de ~8.0–8.2, suele deberse a exceso de amoníaco; a pH altos, el amoníaco libre es tóxico para las bacterias metanogénicas, también reduciendo la producción (Miller et al., 2021). En resumen, el modelo deberá mostrar que pH óptimo ≈7 maximiza la producción, mientras que alejándose de ese valor (hacia muy ácido o muy básico) la producción disminuye notablemente.

- Alcalinidad y estabilidad: La alcalinidad es la capacidad de la mezcla para resistir cambios de pH (amortiguación). Un sistema con suficiente alcalinidad (por ejemplo, de bicarbonatos, carbonatos, amonio, etc.) puede neutralizar ácidos producidos y mantener el pH estable (Sillero et al., 2024). Variables como la relación AGV/Alcalinidad (VFA/TIC) se usan para diagnosticar estabilidad; valores VFA/TIC < 0,4 se consideran seguros. En la práctica, mantener alcalinidad adecuada permite que se puedan cargar más sustratos fácilmente degradables sin que baje el pH. El lodo aporta alcalinidad, y también la adición controlada de bases (como bicarbonato de sodio) si es necesario. El Random Forest podría no usar directamente "alcalinidad" si no está como entrada, pero inferirá sus efectos a través de variables como el tipo de sustrato y pH observado. Un sistema bien amortiguado mostrará una producción sostenida aun con cargas altas de AGV; uno con baja alcalinidad exhibirá una producción que cae más allá de cierto punto de carga (lo que

el modelo internalizará como interacciones entre carga y tipo de sustrato) (Vitanza et al., 2016).

- Necesidad de corrección de pH inicial: Cómo se indicó anteriormente, ajustar el pH del influente antes de alimentarlo (si está muy extremo) es una práctica. Por ejemplo, el agua residual cervecera ácida debe neutralizarse parcialmente o mezclarse con lodo para evitar shock (Sillero et al., 2024). Esto se refleja en mejores rendimientos. Un pH inicial corregido significa que el digestor opera siempre en rango óptimo desde el comienzo, optimizando la producción. Si no se corrigiera, la producción inicial sería baja hasta que el sistema consuma ácidos y suba el pH por sí mismo (perdiendo tiempo y rendimiento).

En resumen, mantener el pH del digestor dentro de ~6.5–7.5 maximiza la producción de biogás, mientras que desviaciones hacia acidez o basicidad la disminuyen drásticamente. El modelo de IA aprenderá que variables que tienden a empujar el pH fuera de rango (ej: mucha agua residual sin buffer → acidez; mucha proteína → amoníaco básico) conllevan menor producción a igualdad de otras condiciones. Por tanto, controlando el pH (o incluyendo suficientes agentes buffer en la mezcla), se logra una relación positiva entre carga orgánica y producción, que de otro modo se vería truncada por desequilibrios de pH.

6.4.3. Velocidad de Carga Orgánica (OLR) y Tiempo de Retención (HRT)

La velocidad de carga orgánica aplicada y el tiempo de retención hidráulica (TRH o HRT) son variables operativas ligadas: la OLR (Organic Loading Rate) indica cuánta materia orgánica (generalmente en kg VS) se alimenta por volumen de reactor por día, mientras que el HRT es el tiempo promedio que el sustrato permanece en el digestor. Ambos afectan cuánto biogás se produce y en qué condiciones:

- Velocidad de Carga orgánica (OLR): Aumentar la carga orgánica (más alimento por día) inicialmente incrementa la producción diaria de biogás, ya que hay más materia para convertir. Sin embargo, cada sistema tiene una capacidad máxima de procesamiento biológico. Si la OLR supera lo que la población microbiana puede degradar de manera estable, comienzan a acumularse ácidos (los acidógenos producen más rápido de lo que los metanógenos consumen). Esto lleva a caída de pH y a la inhibición mencionada, con la consiguiente disminución del rendimiento de metano por unidad de VS añadida (Sillero et al., 2024; Miller et al., 2021). En otras palabras, existe una OLR óptima donde se logra la máxima producción de metano sin inestabilidad. Por ejemplo, en la digestión de bagazo cervecero se reportó que una carga de ~4,9 g VS/L·día produjo un gas máximo de ~0,596 L CH4/g VS degradado bajo condiciones mesofílicas (Vitanza et al., 2016). Cargas menores a 4,9 g/L·d desaprovechaban capacidad (el rendimiento por VS podía ser alto pero el flujo total diario era menor), y cargas mayores probablemente ocasionaron menor rendimiento por VS (por inhibición). Generalmente, para mezclas de residuos cerveceros

se sugiere operar en 1–4 kg VS/m³·día como rango típico seguro. El Random Forest aprenderá que aumentar la carga orgánica tiene un efecto positivo en la producción total hasta cierto punto, a partir del cual la producción total puede no seguir aumentando linealmente e incluso descender si el sistema colapsa. Notará por ejemplo que pasar de 1 a 3 kg VS/m³·d puede duplicar la producción diaria, pero pasar de 3 a 6 kg VS/m³·d quizá no la duplica sino que la reduce por shock ácido. Optimizar la OLR significa encontrar ese punto dulce de máxima producción estable (Szaja et al., 2020).

- Tiempo de Retención Hidráulica (HRT): El HRT determina cuánto tiempo disponen los microorganismos para digerir el sustrato. HRT largos (p.ej. 30 días) permiten que incluso componentes más lentos se degraden en mayor medida, acercando la producción al potencial máximo de biogás del sustrato. Un HRT suficiente asegura que se alcance una conversión alta de VS a biogás (alta reducción de sólidos). Si el HRT es demasiado corto, el riesgo es que una fracción significativa del sustrato salga sin digerir (baja conversión) y además las arqueas de crecimiento lento sean expulsadas, desequilibrando la biota. Por tanto, HRT muy bajos disminuyen la producción específica por kg de sustrato (no se extrae todo el metano posible) (Sganzerla et al., 2023). Un rango común para digestión mesofílica de residuos medianamente complejos es 15–30 días de HRT. En ese margen, usualmente se alcanza 60–90% del potencial. Acortar por debajo de 15 días suele bajar rendimientos, y alargar por encima de 30 días da rendimientos marginales adicionales pequeños (ya casi todo lo degradable fue consumido antes). El modelo reconocerá que aumentar el HRT mejora la producción de biogás hasta un límite, pero con retornos decrecientes: por ejemplo, pasar de 5 a 15 días HRT aumenta fuertemente el % de VS destruido y biogás producido, mientras que pasar de 30 a 60 días quizá aporte poco biogás extra porque ya se extrajo la mayoría en 30 días. También hay un trade-off con la productividad volumétrica: HRT alto (reactor grande o lento) significa menos alimento por día (baja OLR), lo cual si bien maximiza la extracción por kg, disminuye el caudal de biogás diario por volumen de reactor (Miller et al., 2021).

En conjunto, OLR y HRT están inversamente relacionados (a un HRT dado corresponde cierta OLR para una conversión objetivo). El Random Forest, teniendo posiblemente ambas variables, puede inferir, por ejemplo, que ciertas combinaciones de OLR alta + HRT suficiente logran alta producción, mientras que OLR alta + HRT baja resultan en menor eficiencia. Idealmente, el sistema se operará en un punto donde la OLR sea lo más alta posible manteniendo un HRT mínimo que garantice estabilidad. Empíricamente, los estudios sugieren que mantener HRT ≥ 15 días y OLR ≤ ~4 kg VS/m³·d es una receta segura. Desviarse de eso (más carga o menos retención) afectará negativamente la producción. Por lo tanto, el efecto de cada una: incrementar OLR sin cambiar HRT eventualmente disminuye rendimiento por kg; incrementar HRT (disminuyendo OLR) aumenta rendimiento por kg pero hasta saturar el potencial. La IA ayudará

a encontrar el equilibrio, aprendiendo de los datos cuándo el incremento de carga empieza a ser perjudicial y cuándo un HRT extra deja de ser beneficioso.

6.4.4. Agitación (Mixing) del Reactor

La agitación del digestor (mezcla mecánica o recirculación de biogás líquido) es considerada como una variable categórica (presencia o ausencia de mezcla, o intensidad de la misma). Su impacto en la producción de biogás es:

- Mejor contacto y homogeneidad: Con agitación, el sustrato se distribuye uniformemente, evitando la formación de capas (estratificación). Esto es especialmente importante cuando hay sólidos como el bagazo; sin mezcla, el bagazo puede flotar o sedimentar formando costras, dejando parte del volumen del reactor no disponible para reacción. La agitación aumenta el contacto entre microorganismos y sustratos, lo que suele traducirse en mayor tasa de digestión. Un sistema agitado típicamente mostrará más biogás y más rápida producción que uno no agitado, para sustratos heterogéneos (Miller et al., 2021; Vitanza et al., 2016).

- Prevención de inhibiciones locales: Mezclar ayuda a distribuir los ácidos producidos y el álcali amortiguador de manera uniforme. Esto previene zonas localmente ácidas (pH bajo en alguna parte porque ahí se acumularon AGV) o zonas con alta concentración de inhibidores. También facilita la liberación del biogás retenido en el medio (desprende las burbujas de metano atrapadas). Todo esto contribuye a un mejor rendimiento global. Por tanto, la IA probablemente aprenderá que la condición "Agitación = Sí" se asocia a mayor producción de biogás y más estabilidad, en comparación con "Agitación = No" (Sillero et al., 2024).

- Consumo energético vs beneficio: Cabe mencionar que una agitación excesiva puede romper flóculos microbianos o consumir mucha energía, pero a nivel de producción de biogás per se, usualmente algo de agitación mejora la generación neta (Szaja et al., 2020). La optimización está en cuánto agitar (velocidad, frecuencia) – variable continua que aquí simplificamos a presencia/ausencia. En los datos, se podría ver por ejemplo que experimentos sin mezcla logran menor porcentaje de VS destruido y menor biogás, confirmando la importancia de la agitación (Sganzerla et al., 2023).

En resumen, la variable “agitación del reactor” influye positivamente, como se aprecia en la Tabla 6.3: con agitación se logra más biogás (y de forma más rápida) gracias a la mejor homogeneización y transferencia de masa, mientras que sin agitación pueden ocurrir gradientes que limitan la digestión. Si el Random Forest incluye esta variable, es de esperar que tenga una

importancia significativa, pues marca diferencias claras en el rendimiento en escenarios comparables.

Tabla 6.3: Resumen general condiciones del proceso.
Fuente: Elaboración propia.

Variable	**Tipo**	**Efecto esperado**	**Riesgo en exceso o defecto**	**Referencias clave**
Temperatura de operación(Mesofílica vs Termofílica)	Condición de proceso	Mayor temperatura (45–55 °C) → cinética más rápida, mayor producción potencial.	Termofilia: más producción pero menos estabilidad; riesgo de estrés térmico y mayor sensibilidad a inhibidores.	Szaja et al., 2020; Sillero et al., 2024
pH del sistema y alcalinidad	Química-operativa	pH ideal: 6.8–7.2. Alcalinidad adecuada permite amortiguar ácidos y estabilizar pH.	pH <6.5 → acidosis, bloqueo metanogénesis. pH >8.0 → toxicidad por amoníaco. Baja alcalinidad = riesgo inestabilidad.	Miller et al., 2021; Vitanza et al., 2016
Carga Orgánica (OLR)	Operativa	Aumentar OLR eleva producción hasta un punto óptimo.	Cargas altas sin control → acumulación de AGV, caída de pH y colapso del sistema.	Sganzerla et al., 2023; Szaja et al., 2020
Tiempo de Retención Hidráulico (HRT)	Operativa	HRT suficiente (15–30 días) permite conversión completa del sustrato.	HRT muy corto: sustrato sale sin degradarse. HRT muy largo: menor eficiencia volumétrica.	Demirel & Scherer, 2008; Miller et al., 2021

Agitación del reactor (Mixing)	Mecánica-operativa	Mejora contacto microbios-sustrato, evita estratificación y zonas muertas.	Agitación excesiva: dispersa microorganismos y AGV, generando inestabilidad. Falta de mezcla: sedimentación, zonas anaerobias ineficientes.	Vitanza et al., 2016; Szaja et al., 2020

Además de las variables detalladas, el modelo podría considerar otras (por ejemplo, tipo de inóculo, presencia de inhibidores específicos, tamaño de partícula del bagazo, etc.), pero las mencionadas son las principales con efecto conocido en la producción de biogás. La interacción entre todas ellas determina el resultado final. Por ejemplo, una temperatura termofílica combinada con alta OLR y poco alcalinidad sería problemática (aunque cada variable por separado pudiera sugerir aumento de producción, juntas causan fallo). Justamente la fortaleza del Random Forest es capturar esas interacciones: no asumirá que el efecto de temperatura es igual en todos los casos, sino que podrá, por ejemplo, reducir la predicción de biogás si detecta temperatura alta + alto N (amoníaco) simultáneamente. Nuestra tarea será interpretar las importancias de variables y posiblemente usar gráficos de dependencia parcial para ver cómo afecta cada variable aislada y en conjunto.

Como resultado del análisis bibliográfico, se identificaron las variables más influyentes sobre la producción de metano en la digestión anaerobia de residuos cerveceros. Estas variables no solo guiarán la construcción del modelo predictivo mediante Random Forest, sino que además permitirán evaluar la sensibilidad del sistema frente a distintos escenarios operativos. La selección de estas variables constituye un insumo crítico para la siguiente etapa del trabajo.

6.5. SELECCIÓN DE VARIABLES OBJETIVO (OUTPUTS) PARA EL MODELO PREDICTIVO

Para evaluar el rendimiento del proceso de digestión anaerobia del bagazo cervecero, se han definido como variables objetivo (outputs) aquellas que permiten cuantificar la eficiencia energética, la estabilidad del sistema y la dinámica cinética del proceso. La selección se basó en su relevancia técnico-operacional, su capacidad para describir el comportamiento del sistema bajo distintas condiciones de operación y su disponibilidad (total o parcial) en la literatura técnica revisada. A continuación, se detallan los principales outputs seleccionados:

6.5.1. Producción total de biogás (m^3/kg VS)

Esta métrica expresa el volumen acumulado de biogás producido por unidad de sólidos volátiles (VS) alimentados al sistema. Es uno de los indicadores más representativos de la eficiencia global del proceso. Aunque no todos los estudios presentan esta variable directamente en unidades estandarizadas, puede calcularse a partir de datos como el volumen de biogás, el contenido de VS del sustrato, o por conversiones desde valores expresados en función del DQO o la COD. Por ejemplo, Szaja et al. (2020) reportan rendimientos de hasta 421 mL/g VS en co-digestión de lodos y bagazo cervecero, con tiempos de retención de 24 días. De igual manera, Vitanza et al. (2016) informan rendimientos específicos de hasta 0,284 L CH_4/g COD, equivalentes a valores comparables por gVS.

6.5.2. Producción acumulada de metano (mL CH_4/g VS)

El metano es el componente energético clave del biogás, por lo que su cuantificación directa es esencial para estimar el potencial bioenergético del proceso. Este valor es particularmente útil para estudios de balance energético y modelado de escalamiento. Vitanza et al. (2016) reportan una producción específica de metano (SMP) de 0,255–0,284 L CH_4/g COD para levadura agotada y bagazo cervecero respectivamente, mientras que Bi et al. (2019) también destacan la producción de metano como variable principal en su estudio sobre co-sustratos alimentarios.

6.5.3. Contenido de metano en el biogás (% CH_4)

Este parámetro determina la calidad del biogás. Un contenido elevado de CH_4 (>55 %) implica mayor poder calorífico y menor necesidad de purificación. La mayoría de los estudios revisados informan este valor como parte de sus caracterizaciones estándar. Por ejemplo, Szaja et al. (2020) reportan valores del 21 al 29 % de CH_4 en digestiones con bagazo, y Papirio et al. (2023) mencionan concentraciones que alcanzan hasta el 65 % en condiciones óptimas. Este parámetro también se ve influenciado por factores como la relación C/N, carga orgánica y presencia de inhibidores.

6.5.4. Tasa de producción de metano (mL/g VS·día)

Esta tasa refleja la velocidad de transformación del sustrato en metano, siendo clave para el dimensionamiento de reactores y la planificación del tiempo de residencia. Si bien algunos artículos no la expresan de forma directa, puede derivarse del análisis de las curvas de producción acumulada. En particular, Szaja et al. (2020) modelan cinéticamente la producción mediante curvas sigmoides y parámetros como el tiempo de latencia y la velocidad máxima de producción, lo que permite estimar la tasa en función del tiempo y la carga de sustrato.

6.5.5. Tiempo hasta el pico de producción

Este parámetro es útil para describir la cinética del proceso. Define el momento en que se alcanza la máxima tasa de producción de biogás o metano, y suele estar relacionado con la degradabilidad del sustrato y la adaptación de la microbiota. En estudios como el de Szaja et al. (2020), se observa que la adición de bagazo cervecero retrasa ligeramente el pico de producción pero incrementa el volumen acumulado. Este comportamiento es relevante para optimizar el tiempo de operación en sistemas semicontinuos o por lotes.

6.5.6. Reducción de sólidos volátiles (VS)

La degradación de VS es un indicador de la fracción orgánica efectivamente convertida en biogás. Valores elevados indican una buena eficiencia del proceso. Bi et al. (2019) y Papirio et al. (2023) incluyen esta variable en sus balances, señalando reducciones del orden del 60–70 %, dependiendo del tipo de sustrato y el tiempo de residencia. La medición directa de VS en entrada y salida permite también inferir el potencial remanente de los residuos digeridos.

6.5.7. Estabilidad del sistema (pH, VFA, alcalinidad)

La estabilidad del proceso es esencial para asegurar la continuidad de la digestión y evitar paros técnicos. Las variables más relevantes en este sentido son el pH (idealmente entre 6.8 y 7.5), la concentración de ácidos grasos volátiles (VFA), y la relación VFA/alcalinidad. Un exceso de VFA sin adecuada alcalinidad puede causar descensos de pH, inhibiendo las arqueas metanogénicas. Estudios como Papirio et al. (2023) y Vitanza et al. (2016) enfatizan la importancia de monitorear estos parámetros como señales de alarma para inestabilidades metabólicas. En sistemas con alto contenido de proteína, la acumulación de amoníaco también puede afectar este equilibrio.

Estas variables objetivo, por su relación directa con la eficiencia del proceso y su disponibilidad parcial en los estudios, constituyen un conjunto robusto para entrenar un modelo predictivo. La combinación de métricas de producción, calidad del biogás, cinética y estabilidad permitirá generar un modelo integral, capaz de anticipar el comportamiento del sistema ante diferentes condiciones de operación y características del sustrato.

La Tabla 6.4 representa un resumen la de información recopilada de las variables objetivo.

Tabla 6.4: Resumen general de variables objetivos.
Fuente: Elaboración propia.

Variable	**Tipo**	**Significado e importancia para el modelo**	**Consideraciones técnicas y operativas**	**Referencias clave**
Producción total de biogás(m^3/kg VS)	Output energético	Medida directa del volumen total de biogás generado por unidad de sólidos volátiles alimentados.	Influenciada por composición del sustrato, temperatura, pH y tiempo de retención.	Szaja et al., 2020; Miller et al., 2021
Producción acumulada de metano(mL CH_4/g VS)	Output energético	Indica el volumen de CH_4 producido por cada gramo de VS. Es un indicador clave del rendimiento.	Variable fundamental para evaluar la eficiencia metanogénica. Alta correlación con la biodegradabilidad del sustrato.	Sillero et al., 2024; Sganzerla et al., 2023
Contenido de metano en el biogás(% CH_4)	Calidad energética	Representa la fracción de metano en el gas generado.	Biogás con >55% CH_4 se considera de buena calidad. Puede variar según sustrato y etapa de operación.	Vitanza et al., 2016; Miller et al., 2021
Tasa de producción de metano(mL/g VS·día)	Velocidad de proceso	Mide la velocidad a la que se genera metano por unidad de VS.	Determina la viabilidad operativa. Tasa alta = digestión rápida, ideal para sistemas de bajo HRT.	Szaja et al., 2020; Sganzerla et al., 2023

Tiempo hasta el pico de producción	Dinámica temporal	Tiempo necesario para alcanzar la máxima tasa de producción diaria.	Relacionado con la adaptación microbiana y degradabilidad del sustrato. Un retardo puede indicar inhibición o desequilibrio.	Sillero et al., 2024; Miller et al., 2021
Reducción de sólidos volátiles (VS)	Eficiencia de proceso	Refleja cuánto de la materia orgánica inicial fue convertida en biogás.	Valores >50% indican buena conversión. Valores bajos pueden reflejar baja biodegradabilidad o fallas operativas.	Sganzerla et al., 2023; Demirel & Scherer, 2008
Estabilidad del sistema(pH, VFA, alcalinidad)	Indicador de salud del proceso	Conjunto de parámetros que reflejan el equilibrio del reactor.	Estabilidad óptima permite operación continua. VFA/Alcalinidad <0.4 y pH cercano a 7 indican buen estado del sistema.	Vitanza et al., 2016; Sillero et al., 2024

6.6. Justificación del uso de aprendizaje automático en el presente estudio

El proceso de digestión anaerobia presenta un comportamiento altamente complejo, debido a la interacción no lineal entre variables físico-químicas, microbiológicas y operacionales, tales como la temperatura, la composición del sustrato, la relación carbono/nitrógeno (C/N), el pH y la concentración de sólidos volátiles. Esta complejidad limita la aplicabilidad de modelos mecanísticos tradicionales para predecir el comportamiento del sistema bajo distintas condiciones.

En este contexto, en el presente estudio se optó por utilizar modelos de aprendizaje automático como herramienta para modelar la relación entre las variables del proceso y las variables objetivo definidas. Este enfoque permitió trabajar directamente con datos experimentales recopilados desde la literatura, capturando patrones no lineales sin necesidad de establecer explícitamente las relaciones funcionales entre las variables.

Para el desarrollo del modelo predictivo se seleccionó el algoritmo Random Forest, debido a su capacidad para manejar múltiples variables de entrada, su robustez frente a datos ruidosos y su buen desempeño en conjuntos de datos de tamaño moderado. En este trabajo, el modelo fue utilizado para predecir la producción total de biogás, la remoción de sólidos volátiles y el contenido de metano, a partir de variables asociadas al sustrato y a las condiciones operacionales del proceso.

La utilización de este enfoque permitió no solo generar estimaciones del comportamiento del sistema, sino también analizar la influencia de las variables de entrada sobre los resultados obtenidos, facilitando la interpretación del modelo y su aplicación en la evaluación de distintos escenarios de digestión anaerobia de residuos cerveceros.

6.7. Implementación del modelo Random Forest en el presente estudio

6.7.1. Estructura del modelo aplicado

En el presente estudio, el modelo Random Forest fue implementado como herramienta de aprendizaje supervisado para modelar la relación entre las variables del proceso de digestión anaerobia y las variables objetivo definidas. El modelo se construyó a partir de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios del dataset mediante muestreo bootstrap, utilizando las variables de entrada previamente seleccionadas.

Durante el entrenamiento, cada árbol dividió el espacio de datos en función de las variables del proceso, permitiendo representar relaciones no lineales entre las condiciones operacionales, la composición del sustrato y las variables de salida. Con el fin de mejorar la capacidad de

generalización del modelo, en cada nodo se evaluó un subconjunto aleatorio de variables predictoras, lo que permitió reducir la correlación entre los árboles y aumentar la robustez del modelo frente a la variabilidad de los datos.

La predicción final del modelo se obtuvo mediante el promedio de las predicciones individuales de todos los árboles del bosque. Esta configuración permitió generar estimaciones más estables y menos sensibles a variaciones específicas del dataset, lo que resulta relevante considerando la heterogeneidad de los datos experimentales utilizados en este estudio.

El modelo fue aplicado para predecir variables clave del proceso, tales como la producción total de biogás, la remoción de sólidos volátiles y el contenido de metano, utilizando como variables de entrada las características del sustrato y las condiciones operacionales definidas previamente.

6.7.2. Justificación de la elección del modelo Random Forest

En el desarrollo del modelo predictivo de este estudio, la elección del algoritmo Random Forest respondió a la necesidad de trabajar con un sistema altamente no lineal y con múltiples variables interdependientes, como es el caso de la digestión anaerobia de residuos cerveceros.

Dado que las variables del proceso presentan alta variabilidad y relaciones complejas entre sí, se priorizó el uso de un modelo capaz de capturar estas interacciones sin requerir la formulación explícita de ecuaciones mecanísticas. En este contexto, Random Forest permitió modelar de manera directa la relación entre las variables de entrada definidas y las variables objetivo del sistema.

Adicionalmente, se consideró la robustez del modelo frente a datos ruidosos y su buen desempeño en conjuntos de datos de tamaño moderado, características relevantes considerando la naturaleza experimental del dataset utilizado en este trabajo.

Finalmente, la capacidad del modelo para estimar la importancia relativa de las variables fue un criterio clave en su selección, ya que permitió no solo generar predicciones, sino también analizar la influencia de los distintos factores del proceso sobre el rendimiento de la digestión anaerobia.

6.8. Descripción del dataset y selección de variables

En este apartado se definen las variables de entrada (predictoras) y la variable de salida (objetivo) empleadas en el modelo predictivo basado en Random Forest para estimar el rendimiento de producción de biogás. La elección de estas variables se fundamentó en criterios de relevancia biológica, respaldo en la literatura sobre digestión anaerobia, disponibilidad de datos en el conjunto utilizado y alineación con los objetivos prácticos del modelo. A continuación, se

explican dichas consideraciones en detalle, distinguiendo entre la selección de la variable objetivo y las variables predictoras.

Variable de salida (objetivo): La variable objetivo seleccionada para el modelo es el rendimiento de biogás, típicamente expresado como la cantidad de biogás producida por unidad de sustrato (por ejemplo, en metros cúbicos de biogás por kilogramo de material orgánico volátil). Se optó por esta variable de salida porque constituye el indicador clave de desempeño en procesos de digestión anaerobia, al reflejar directamente la eficacia de conversión de residuos orgánicos en energía utilizable (Weiland, 2010). Además, predecir el rendimiento de biogás tiene un valor práctico evidente: permite estimar la producción energética potencial de diferentes sustratos o bajo distintas condiciones operativas, lo cual es esencial para el dimensionamiento y la optimización de plantas de biogás. La literatura respalda el enfoque en esta métrica, ya que numerosos estudios de digestión anaerobia la utilizan para evaluar y comparar el efecto de variables de operación y características del sustrato en la eficiencia del proceso (Mao et al., 2015). Por lo tanto, centrar el modelo en la predicción de este rendimiento asegura su pertinencia tanto científica como aplicada.

Variables de entrada (predictoras): Para las variables de entrada, se incluyeron aquellas con base en criterios biológicos y de ingeniería que las identifican como factores determinantes en la producción de biogás, siempre y cuando estuvieran disponibles en el conjunto de datos empleado. En la literatura especializada se ha documentado extensamente qué parámetros influyen de forma significativa en la tasa y el rendimiento de la digestión anaerobia (Appels et al., 2008; Ward et al., 2008). Tomando en cuenta estos antecedentes, así como la información efectivamente recopilada en el dataset, se seleccionó un grupo de variables predictoras que abarcan tanto las características del sustrato alimentado al digestor como las condiciones operativas del proceso. A continuación, se listan las principales variables de entrada elegidas y los fundamentos de su inclusión:

1. Tipo y composición del sustrato: La naturaleza del material orgánico y su composición química son críticas para el potencial metanogénico. Se incluyeron indicadores como la fracción de sólidos volátiles (SV) o contenido orgánico, sólidos totales (ST) y la relación carbono/nitrógeno (C/N) del sustrato. Estos parámetros reflejan la disponibilidad de materia biodegradable y el balance de nutrientes. Por ejemplo, una relación C/N adecuada (usualmente en el rango 20:1–30:1) favorece la actividad microbiana balanceada, evitando acumulación de amoníaco por exceso de nitrógeno o ácidos orgánicos por exceso de carbono (Yadvika et al., 2004). Asimismo, un mayor contenido de SV indica más material orgánico susceptible de convertir en biogás, por lo que es un predictor directo del rendimiento potencial (Mao et al., 2015).

2. Parámetros operativos del digestor: Se consideraron las variables de operación conocidas por afectar la actividad metabólica de los consorcios microbianos en el digestor. Entre ellas destacan:

   2.1. Temperatura de operación: Factor fundamental que determina la velocidad de las reacciones bioquímicas. Los digestores pueden operar en régimen mesofílico (~35 °C) o termofílico (~55 °C), y pequeñas desviaciones pueden inhibir ciertas arqueas metanogénicas. La literatura reporta que la temperatura es uno de los factores más influyentes en la producción de biogás, debiendo mantenerse dentro de rangos óptimos para maximizar el rendimiento (Weiland, 2010; Appels et al., 2008).

   2.2. Tiempo de retención hidráulica (TRH): Representa el período promedio que el sustrato permanece en el digestor. Un TRH suficiente permite la conversión completa de la materia orgánica; valores muy bajos pueden conllevar a una digestión incompleta. Se incluyó este parámetro dado que una mayor permanencia suele aumentar el gas producido por unidad de sustrato, hasta un punto óptimo de saturación (Ward et al., 2008).

   2.3. Tasa de carga orgánica (OLR, por sus siglas en inglés): Corresponde a la cantidad de materia orgánica alimentada por volumen de reactor y por día. Es un indicador de la intensidad de alimentación del sistema. Incluir la OLR como variable permite al modelo captar cómo cambios en la dosis de alimentación pueden afectar el rendimiento; en general, cargas orgánicas muy elevadas pueden provocar estrés en el sistema (acidificación por acumulación de ácidos grasos volátiles) y disminuir la eficiencia de conversión (Mao et al., 2015).

   2.4. pH del medio: El pH influye directamente en la actividad enzimática y en la solubilidad de compuestos, afectando las poblaciones bacterianas y arqueales. Se sabe que el proceso metanogénico opera de forma óptima cerca de la neutralidad (pH ~7) (Ward et al., 2008). Por tanto, si el conjunto de datos disponía de registros de pH durante el proceso, estos fueron incluidos. Fluctuaciones de pH pueden señalar episodios de inestabilidad o inhibición (por ejemplo, por acumulación de ácidos volátiles), factores que el modelo debería considerar para predecir correctamente el rendimiento de biogás bajo distintas condiciones.

   2.5. Presencia de inhibidores o indicadores de estrés: En la medida de lo posible, se incorporaron variables como la concentración de ácidos grasos volátiles (AGV/VFA) o de amoníaco libre, siempre que hubiesen sido medidas en los ensayos del dataset. Altos niveles de AGV o de amoníaco son conocidos por

inhibir la metanogénesis, reduciendo la producción de metano (Mao et al., 2015). Incluir estos indicadores permite al modelo ajustar sus predicciones cuando las condiciones internas del digestor no son las ideales, aunque su disponibilidad depende de los datos experimentales originales.

3. Características del inoculo y del proceso: Adicionalmente, se contemplaron variables relacionadas con el inoculo microbiano (por ejemplo, porcentaje de inóculo en la mezcla) o con la configuración del proceso (modo de operación por lotes o continuo, presencia de recirculación de lixiviados, etc.), en caso de que el dataset las incluyera. La carga microbiana inicial y ciertas estrategias de operación pueden influir en la cinética de arranque y en la estabilidad a largo plazo de la digestión (Mao et al., 2015). No obstante, en muchos conjuntos de datos estos factores suelen mantenerse constantes o no registrarse de forma detallada; por consiguiente, su inclusión quedó supeditada a la información disponible.

El conjunto definitivo de variables de entrada fue resultado, entonces, de equilibrar la importancia teórica de cada variable con su disponibilidad y calidad en el conjunto de datos. Antes de entrenar el modelo, se realizó además una verificación de colinearidad y relevancia estadística preliminar. Por ejemplo, si dos variables estaban altamente correlacionadas entre sí (redundantes desde el punto de vista informativo), se evaluó conservar aquella de interpretación más directa o de medición más confiable, con el fin de simplificar el modelo sin perder capacidad predictiva. Esta depuración apoyada en criterios estadísticos básicos y conocimiento experto es consistente con las buenas prácticas en la preparación de datos para modelos de machine learning (Hastie et al., 2009). En el caso particular de los algoritmos de tipo Random Forest, si bien son robustos al incluir múltiples variables y pueden identificar internamente la importancia de cada predictor, una selección cuidadosa previa puede mejorar la interpretabilidad del modelo y evitar el uso de variables irrelevantes o ruidosas (Breiman, 2001). De hecho, estudios previos en predicción de biogás han empleado métodos de selección de características (como algoritmos genéticos o colonias de hormigas) para identificar las variables de mayor influencia y con ello mejorar la precisión de los modelos de aprendizaje automático (Beltramo et al., 2019).

6.9. Preprocesamiento de datos: normalización, codificación y manejo de variables categóricas

En este proyecto, el conjunto de datos se construyó a partir de ensayos de digestión anaerobia realizados en laboratorio, registrando tanto variables operacionales (por ejemplo, tipo y composición del sustrato, relación C/N, carga orgánica, temperatura, pH, tiempo de retención hidráulico, agitación, concentración de amonio, alcalinidad) como variables de respuesta asociadas al desempeño del proceso (producción total de biogás, porcentaje de remoción de

sólidos volátiles, fracción de metano en el biogás). Una vez recopilada la base de datos, se llevó a cabo un proceso sistemático de depuración y preprocesamiento, con el objetivo de garantizar que la información utilizada por los modelos de aprendizaje automático fuera consistente, trazable y de la mayor calidad posible, dado que la calidad de los datos condiciona directamente la calidad de las predicciones (Hastie et al., 2009).

En primer lugar, se realizó una revisión exploratoria para identificar errores evidentes, registros duplicados, inconsistencias de formato y valores fuera de rango físicamente plausible. Este proceso incluyó la verificación de unidades (por ejemplo, coherencia entre g/L, %, mg/L), la detección de duplicados y la corrección de pequeños errores tipográficos en los nombres de variables o categorías. También se evaluó la presencia de valores atípicos extremos que pudieran deberse a errores de medición o digitación. Siguiendo recomendaciones generales de limpieza de datos, los registros claramente erróneos o incompletos fueron descartados, mientras que se conservaron aquellos outliers que, aun siendo extremos, resultaban físicamente explicables (Côté et al., 2024).

En segundo lugar, se analizaron las columnas del dataset para identificar variables irrelevantes o con muy baja capacidad informativa. Se eliminaron columnas puramente identificatorias (por ejemplo, códigos internos de ensayo) y variables con variabilidad prácticamente nula, ya que su aporte al modelo predictivo es marginal y pueden introducir ruido o redundancia (Brownlee, 2020). Asimismo, se descartaron aquellas variables con un porcentaje muy elevado de datos faltantes, cuando su imputación no era razonable o podía introducir sesgos significativos. Esta depuración permitió concentrar el modelo en un conjunto de variables con respaldo físico y suficiente variabilidad.

Un aspecto relevante del preprocesamiento fue el tratamiento de las variables categóricas. El dataset original incluía descripciones muy específicas de sustratos e inóculos (por ejemplo, diferentes formulaciones de mezclas, condiciones de procedencia o tratamientos previos), lo que generaba una alta cantidad de categorías con pocos registros cada una. Para evitar una explosión de dimensionalidad al aplicar técnicas de codificación como one-hot encoding, se agruparon estas categorías en clases más generales basadas en criterios técnicos, como por ejemplo: bagazo cervecero puro, mezclas de bagazo con otros co-sustratos, lodos de control, levaduras residuales y categorías “otros” para combinaciones poco frecuentes. Se siguió una lógica similar para el tipo y origen del inóculo, distinguiendo grupos como digestatos, lodos granulares tipo UASB, lodos de plantas municipales y fuentes industriales o agrícolas. Esta reducción de cardinalidad es una práctica habitual en problemas reales de modelado, pues mejora la estabilidad del entrenamiento sin perder información relevante (Kuhn & Johnson, 2013).

Luego se definió el conjunto final de variables de entrada (X) y de salida (Y). Como variables objetivo se seleccionaron tres indicadores clave del proceso: producción total de biogás

normalizada (mL/g VS), porcentaje de remoción de sólidos volátiles (% Remoción TVS) y porcentaje de metano en el biogás (% CH_4). Estas tres salidas sintetizan, respectivamente, la eficiencia energética del proceso, la estabilización del sustrato y la calidad del gas producido. Las variables de entrada incluían, entre otras, el tipo de sustrato agrupado, el tipo y origen del inóculo, la carga de sólidos y volátiles (TS, VS), la relación C/N, el contenido de lignina y fibra, la concentración de amonio (NH_3), la temperatura de operación, el HRT, la alcalinidad, la velocidad de carga orgánica (OLR) y la agitación. Esta selección se hizo considerando la literatura previa sobre digestión anaerobia de residuos lignocelulósicos y su influencia en la producción de biogás (Appels et al., 2011; Wainaina et al., 2021).

En cuanto al tratamiento cuantitativo, las variables numéricas se mantuvieron en sus unidades originales, cuidando la coherencia interna del dataset. Dado que los modelos tipo Random Forest no requieren normalización o estandarización estricta de las variables para funcionar correctamente, no fue necesario escalar todas las características, aunque sí se comprobó la ausencia de errores de orden de magnitud. Las variables categóricas agrupadas se prepararon para su transformación mediante one-hot encoding dentro de un pipeline de preprocesamiento, de modo que el modelo pudiera trabajar con una matriz exclusivamente numérica sin perder la información contenida en las categorías (Lantz, 2019).

En el desarrollo del modelo predictivo de este estudio, el dataset fue dividido en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %), con el objetivo de evaluar de manera independiente el desempeño del modelo. El conjunto de entrenamiento fue utilizado para ajustar el modelo Random Forest y optimizar sus hiperparámetros mediante validación cruzada, mientras que el conjunto de prueba se empleó exclusivamente para evaluar la capacidad predictiva final del modelo.

Esta estrategia permitió simular el comportamiento del modelo frente a nuevas combinaciones de variables del proceso de digestión anaerobia no utilizadas durante su entrenamiento, evaluando así su capacidad de generalización en escenarios distintos a los observados en los datos originales.

6.10. Entrenamiento de modelos individuales por variable objetivo

Una vez que el conjunto de datos fue depurado y preprocesado, se procedió a la construcción del modelo de aprendizaje automático. El objetivo fue desarrollar un sistema predictivo capaz de estimar tres variables clave del desempeño en digestión anaerobia: (1) la producción total de biogás normalizada (mL/g VS), (2) el porcentaje de remoción de sólidos volátiles (% Remoción TVS) y (3) el porcentaje de metano en el biogás. Para ello se seleccionó el algoritmo Random Forest Regressor, dada su capacidad demostrada para manejar datos heterogéneos, capturar

relaciones no lineales y ofrecer modelos robustos frente a ruido y sobreajuste (Breiman, 2001; Kuhn & Johnson, 2013).

El proceso comenzó con la construcción de un pipeline de preprocesamiento, que permite integrar en un único flujo tanto la codificación de variables categóricas como el entrenamiento del modelo. Las categorías resultantes de las agrupaciones técnicas realizadas previamente (por ejemplo, Sustrato_cat, TipoInoculo_cat, FuenteInoculo_cat) fueron convertidas en variables binarias mediante one-hot encoding, mientras que las variables numéricas ingresaron directamente al modelo. La inclusión del preprocesador dentro del pipeline asegura que cualquier nueva muestra ingresada por el usuario sea transformada de forma idéntica al conjunto de entrenamiento, evitando errores o inconsistencias estructurales.

Posteriormente, se definió un modelo base de Random Forest, configurado inicialmente con 300 árboles, selección aleatoria de atributos (max_features="sqrt") y profundidad ilimitada. Esta configuración se seleccionó como punto de partida debido a que los bosques aleatorios tienden a mejorar su desempeño al aumentar el número de árboles, siempre que no se incurra en sobreajuste, situación que es poco frecuente en este tipo de algoritmos (Breiman, 2001). Además, la selección aleatoria de características en cada división del árbol ayuda a incrementar la diversidad del bosque, lo que a su vez contribuye a disminuir la varianza global del modelo (Hastie et al., 2009).

El modelo fue entrenado utilizando el conjunto de entrenamiento (train set) correspondiente al 80 % de los datos, empleando un enfoque supervisado estándar. Durante el entrenamiento, cada árbol del bosque se construyó empleando muestras “bootstrap”, es decir, subconjuntos aleatorios con reemplazo del dataset original. Este mecanismo introduce variabilidad entre los árboles, lo que mejora la estabilidad y capacidad de generalización del modelo (Dietterich, 2000). Adicionalmente, como parte del proceso interno de Random Forest, cada árbol fue ajustado buscando puntos de división que minimizaran el error cuadrático medio (MSE), criterio comúnmente utilizado para problemas de regresión.

Una vez entrenado el modelo base, se procedió a evaluar su desempeño mediante el conjunto de prueba (test set), utilizando métricas ampliamente aceptadas en la literatura: MAE (Mean Absolute Error), RMSE (Root Mean Squared Error) y R^2 (coeficiente de determinación). Estas métricas permiten evaluar, respectivamente, el error medio absoluto de las predicciones, el error cuadrático penalizado y el porcentaje de varianza explicada por el modelo. Los resultados iniciales mostraron un desempeño satisfactorio, lo que confirmó que los patrones presentes en los datos son suficientemente informativos para permitir la predicción de las tres variables objetivo.
Sin embargo, con el fin de maximizar la capacidad predictiva del sistema, se implementó posteriormente un proceso de optimización por búsqueda en malla (GridSearchCV). Esta herramienta permite explorar sistemáticamente diferentes combinaciones de hiperparámetros,

tales como el número de árboles, la profundidad máxima, el número mínimo de muestras por hoja y el número mínimo de muestras para realizar una división. GridSearchCV evalúa cada combinación mediante validación cruzada (k-fold), lo que reduce el riesgo de sobreajuste al estimar la capacidad de generalización del modelo sobre particiones no utilizadas durante el entrenamiento (Bergstra & Bengio, 2012).

El proceso de optimización permitió obtener configuraciones específicas para cada una de las tres variables objetivo, mejorando los valores de MAE, RMSE y R^2 con respecto al modelo base. Estas mejoras evidencian la necesidad de ajustar de manera independiente los modelos para cada salida, ya que cada variable presenta distribuciones, rangos y comportamientos distintos, lo que se traduce en diferentes configuraciones óptimas del algoritmo.

Finalmente, los tres modelos optimizados fueron almacenados en formato .pkl junto con un archivo de metadatos que contiene el orden y tipo de las variables de entrada, con el fin de permitir su reutilización posterior en herramientas externas como la interfaz de usuario implementada en Gradio. De esta forma, el sistema completo queda preparado para recibir nuevos datos y generar predicciones consistentes con el entrenamiento original.

6.11. Optimización de hiperparámetros mediante GridSearchCV

La optimización de hiperparámetros es una etapa fundamental para mejorar el desempeño de cualquier modelo de machine learning, especialmente en algoritmos de ensamble como Random Forest. Aunque este método es reconocido por su robustez y estabilidad aun sin una calibración exhaustiva, ajustar adecuadamente sus parámetros internos permite encontrar configuraciones que mejoran la capacidad predictiva, reducen el error y aumentan la generalización del modelo (Breiman, 2001; Kuhn & Johnson, 2013).
En el caso del Random Forest aplicado en este estudio, se utilizaron cinco hiperparámetros clave, seleccionados por su influencia directa en la complejidad de los árboles, su estabilidad y la reducción del sobreajuste:

- Número de árboles (n_estimators): controla cuántos modelos individuales componen el bosque. Un mayor número tiende a reducir la varianza y mejorar la estabilidad del modelo, aunque incrementa el tiempo computacional.

- Profundidad máxima de los árboles (max_depth): regula el tamaño de los árboles de decisión. Profundidades muy grandes pueden llevar al sobreajuste; profundidades moderadas generan modelos más generalizables.

- Número de variables disponibles por división (max_features): introduce aleatoriedad y fomenta la diversidad entre árboles, lo que reduce la correlación interna del bosque y

mejora la precisión global.

- Tamaño mínimo de muestras por división (min_samples_split) y por hoja (min_samples_leaf): evitan que el modelo genere ramas demasiado específicas y ruidosas, estabilizando la estructura de los árboles.

Para la optimización se utilizó GridSearchCV, una herramienta que realiza una búsqueda exhaustiva sobre un conjunto predefinido de combinaciones posibles de hiperparámetros. La validación cruzada de cinco particiones (cv=5) garantiza una evaluación robusta del desempeño, disminuyendo el riesgo de seleccionar configuraciones que funcionen bien solo para un subconjunto de los datos (James et al., 2021). El criterio utilizado para seleccionar el mejor modelo fue la maximización del coeficiente de determinación R^2, al ser la métrica más adecuada para comparar el nivel de ajuste entre modelos de regresión.

El proceso se ejecutó de manera independiente para cada una de las tres variables de salida del estudio: Producción total de biogás, % de remoción de TVS y Porcentaje de CH_4 en el biogás. En los tres casos, la optimización condujo a mejoras significativas respecto a los modelos sin calibrar, particularmente en la reducción del error cuadrático medio (RMSE) y en el incremento del R^2. Estos resultados refuerzan la evidencia de que la calibración fina del Random Forest permite capturar de mejor manera las relaciones no lineales entre los parámetros del proceso y el rendimiento de la digestión anaerobia.

6.12. Evaluación del desempeño de los modelos: métricas de error y coeficiente R^2

La evaluación del desempeño es una etapa fundamental dentro del desarrollo de modelos predictivos, ya que permite determinar en qué medida las predicciones generadas se ajustan a los valores reales y si el modelo es adecuado para su uso en contexto operativo. En este estudio, la evaluación se realizó de manera independiente para las tres variables objetivo del proceso de digestión anaerobia: Producción total de biogás, Porcentaje de remoción de sólidos volátiles (TVS) y Porcentaje de metano en el biogás (CH_4). Para ello, se utilizaron métricas ampliamente validadas en el ámbito de la regresión y recomendadas en la literatura en ciencia de datos (Hastie et al., 2009; James et al., 2021).

Las métricas seleccionadas fueron:

a) Error Absoluto Medio (MAE)

El MAE cuantifica el error promedio entre las predicciones del modelo y los valores observados, expresado en las mismas unidades de la variable objetivo. Es una métrica

especialmente útil porque su interpretación es directa: indica cuántas unidades, en promedio, se equivoca el modelo. A diferencia de métricas que elevan el error al cuadrado, el MAE no penaliza de manera desproporcionada los errores grandes, por lo que resulta adecuado cuando se busca evaluar la precisión promedio sin sensibilidad excesiva a valores atípicos (Willmott & Matsuura, 2005).

b) Error Cuadrático Medio (RMSE)

El RMSE indica la magnitud promedio del error pero penalizando con mayor fuerza los desvíos grandes. Es una métrica recomendada cuando se desea detectar si el modelo está cometiendo errores severos que el MAE podría enmascarar (Hyndman & Koehler, 2006). Un RMSE significativamente mayor que el MAE suele indicar la presencia de errores aislados de gran magnitud. En procesos biológicos como la digestión anaerobia, donde ciertas combinaciones de pH, carga orgánica o amonio pueden generar respuestas inesperadas, esta métrica permite identificar desviaciones estructurales del modelo.

c) Coeficiente de Determinación (R^2)

El coeficiente R^2 expresa la proporción de la variabilidad total de la variable objetivo que es explicada por el modelo. Su valor va desde 0 (el modelo no explica nada) hasta 1 (explicación perfecta). En estudios ambientales y biotecnológicos, valores de R^2 entre 0.6 y 0.8 se consideran adecuados cuando existen fuertes no linealidades y variabilidad inherente en los datos experimentales (Montgomery et al., 2012). Además, el R^2 es una métrica estándar en investigaciones donde se comparan modelos predictivos entre sí o frente a estudios previos.

6.12.1. Métricas obtenidas

El desempeño final de los modelos optimizados mostró comportamientos diferenciados según la variable objetivo:

- **Producción total de biogás**: obtuvo valores satisfactorios de R^2 y reducciones notables en RMSE tras la optimización, lo que indica que el modelo fue capaz de capturar relaciones no lineales clave entre composición del sustrato, condiciones operacionales y rendimiento del reactor.

- % Remoción de TVS: presentó el menor desempeño relativo entre las variables analizadas, lo cual puede asociarse a la mayor complejidad del proceso de degradación de la materia orgánica y a la heterogeneidad presente en los datos experimentales, donde influyen múltiples factores simultáneamente.

- Porcentaje de CH_4 en el biogás: presentó el mejor desempeño predictivo, evidenciado en los mayores valores de R^2 y menores errores asociados, lo que sugiere que el modelo logró capturar de manera más precisa las relaciones entre las variables de entrada y esta variable de salida.

En conjunto, los valores de MAE, RMSE y R^2 obtenidos evidencian que los modelos son suficientemente precisos para propósitos de estimación, comparación de escenarios y apoyo en la toma de decisiones sobre operación de reactores anaerobios. No obstante, como cualquier sistema basado en datos experimentales heterogéneos, su uso debe complementarse con criterio técnico, especialmente en condiciones extremas o fuera del rango observado en el dataset.

6.13. Interpretabilidad del modelo mediante SHAP

La interpretabilidad es un componente clave en modelos aplicados a sistemas ambientales y biotecnológicos, especialmente cuando se busca que los resultados sean utilizados por profesionales del área, operadores de plantas o investigadores. En este sentido, el uso de técnicas explicativas permite comprender cómo cada variable de entrada influye en las predicciones del modelo. Para este estudio se utilizó SHAP (SHapley Additive exPlanations), una metodología derivada de la teoría de juegos cooperativos que asigna a cada característica una contribución cuantificable a la predicción del modelo (Lundberg & Lee, 2017).

SHAP se basa en la idea de que una predicción puede descomponerse en el aporte marginal de cada variable, comparado con un valor base. A diferencia de otros métodos de interpretabilidad, SHAP garantiza propiedades de consistencia y equidad: si una variable adquiere mayor influencia en un modelo nuevo, su valor SHAP no disminuirá, lo que lo convierte en uno de los estándares más robustos para interpretabilidad en aprendizaje automático (Molnar, 2022).

6.13.1. Visualizaciones SHAP utilizadas

Para cada uno de los tres modelos entrenados —Producción total de biogás, % Remoción TVS y Porcentaje de CH_4 en el biogás— se generaron las siguientes visualizaciones:

- Summary Plot (beeswarm plot)

Este gráfico permite observar, de manera global, la importancia de todas las variables y su efecto positivo o negativo en las predicciones. Cada punto representa una muestra del dataset y su posición en el eje horizontal corresponde al valor SHAP (influencia en la predicción). La coloración indica si el valor de la variable era alto o bajo.
Este gráfico resulta especialmente útil para identificar patrones no lineales, interacciones y dominancia de ciertas variables en el modelo. En contextos de digestión anaerobia, donde las relaciones entre pH, carga orgánica, temperatura y composición lignocelulósica no son lineales,

estas visualizaciones ofrecen una comprensión profunda del comportamiento del sistema (Ma et al., 2021).

- Bar Plot (importancia media absoluta)

El bar plot de SHAP resume la importancia promedio de cada variable en términos absolutos. A diferencia del summary plot, no muestra la dirección del efecto, pero permite clasificar claramente cuáles son las variables más influyentes.

Este gráfico fue clave para identificar que variables como TS inicial, contenido de lignina, NH_3, Temperatura, OLR, y la categoría del inóculo aparecen repetidamente entre las más determinantes según el modelo y la variable objetivo evaluada. Esta información facilita la toma de decisiones respecto a qué parámetros deben priorizarse en la operación del reactor.

- Waterfall Plot (análisis local para una muestra)

El waterfall plot explica en detalle cómo cada variable contribuyó a la predicción de una muestra específica. Permite analizar individualmente un experimento o un escenario simulado, lo cual es especialmente útil para evaluar el funcionamiento del modelo en casos aislados.
En bioprocesos, esta capacidad de interpretar una observación puntual ayuda a comprender situaciones anómalas, optimizar condiciones operacionales y justificar predicciones ante terceros (operadores, académicos, evaluadores).

6.13.2. Principales hallazgos del análisis SHAP

A partir del análisis conjunto de los tres modelos, se observaron patrones consistentes:

- La composición del sustrato (especialmente lignina y contenido de fibra) mostró gran influencia en la predicción de la producción total de biogás, lo cual coincide con la literatura que destaca la fracción lignocelulósica como factor limitante en la digestión anaerobia (Triolo et al., 2011).

- La temperatura fue una de las variables con mayor importancia global, reflejando su rol fundamental en la actividad metabólica y en la estabilidad del consorcio microbiano.

- El nitrógeno amoniacal (NH_3) influyó tanto positiva como negativamente según los rangos, fenómeno documentado en estudios sobre inhibición amoniacal (Chen et al., 2008).

- Parámetros operacionales como OLR y HRT demostraron ser altamente explicativos del rendimiento del proceso.

- El tipo y origen del inóculo también generaron diferencias relevantes, enfatizando la importancia de la estabilidad microbiológica inicial.

Estos resultados muestran que el modelo no solo predice con precisión aceptable, sino que además revela relaciones coherentes con la teoría y la literatura experimental.

6.13.3. Relevancia de SHAP en el uso real del modelo

La inclusión de SHAP otorga confianza y transparencia al uso del modelo predictivo. Permite justificar por qué un escenario simulado aumenta o disminuye el biogás, entregar recomendaciones prácticas (como ajustar el pH o la carga), y detectar valores fuera de rango o inconsistencias en datos de entrada.
En el ámbito de ingeniería ambiental, donde los modelos suelen ser observados con cautela por su carácter "caja negra", SHAP facilita su adopción operativa, proporcionando interpretaciones comprensibles, defendibles y respaldadas matemáticamente.

6.14. Implementación de una interfaz de usuario para el uso práctico del modelo

Uno de los principales desafíos en la aplicación de modelos de aprendizaje automático en contextos ingenieriles y ambientales es la brecha existente entre el desarrollo técnico del modelo y su utilización práctica por parte de usuarios no expertos en programación. En muchos casos, modelos con buen desempeño predictivo quedan restringidos al ámbito académico debido a la falta de herramientas accesibles que permitan su uso operativo. Por esta razón, en el presente trabajo se desarrolló una interfaz de usuario que permite interactuar directamente con los modelos predictivos entrenados, facilitando su aplicación práctica en escenarios reales de evaluación de procesos de digestión anaerobia.

La interfaz fue implementada utilizando la biblioteca Gradio, una herramienta diseñada para crear interfaces gráficas simples y funcionales directamente desde entornos de Python, sin necesidad de desarrollar aplicaciones web complejas. Gradio permite construir formularios interactivos donde el usuario puede ingresar valores de entrada mediante menús desplegables y campos numéricos, y recibir como salida las predicciones del modelo de forma inmediata y visualmente clara. Esta aproximación resulta especialmente adecuada para entornos académicos y de prototipado, como Google Colab, donde el objetivo principal es la validación funcional del modelo más que su despliegue productivo (Abid et al., 2019).

En la interfaz desarrollada, el usuario debe ingresar todas las variables de entrada definidas durante la construcción del dataset, las cuales incluyen tanto variables numéricas del proceso como variables categóricas previamente agrupadas. Las variables categóricas —correspondientes al tipo de sustrato, tipo de inóculo y fuente del inóculo— se presentan mediante menús

desplegables que contienen únicamente las categorías utilizadas durante el entrenamiento del modelo. Esto asegura la coherencia entre los datos ingresados por el usuario y el espacio de características aprendido por el modelo, evitando inconsistencias asociadas a categorías desconocidas.

Por su parte, las variables numéricas (como volumen del reactor, carga orgánica, temperatura, pH inicial, concentración de sólidos y relación C/N, entre otras) se ingresan mediante campos numéricos continuos. Estos valores son procesados internamente por el mismo pipeline de preprocesamiento utilizado durante el entrenamiento, garantizando que la transformación de los datos sea idéntica tanto en la fase de entrenamiento como en la fase de predicción. Este enfoque es consistente con las buenas prácticas en machine learning, donde se recomienda encapsular el preprocesamiento y el modelo en una única estructura para evitar errores de implementación y fugas de información (Kuhn & Johnson, 2013).

La interfaz fue diseñada para entregar como salida las predicciones de las tres variables objetivo del estudio: producción total de biogás, porcentaje de remoción de sólidos volátiles totales (TVS) y porcentaje de metano en el biogás. Cada una de estas salidas es estimada mediante un modelo Random Forest independiente, entrenado y optimizado específicamente para cada variable. Esta decisión metodológica permite maximizar el desempeño predictivo de cada modelo y simplifica la interpretación de los resultados, evitando las complejidades asociadas a modelos multisalida.
Desde el punto de vista del usuario, el funcionamiento del sistema es directo: una vez ingresados los valores de las variables de entrada, la interfaz ejecuta los modelos entrenados y entrega las predicciones numéricas correspondientes, redondeadas a dos decimales para facilitar su interpretación. Este enfoque transforma el modelo predictivo en una herramienta de apoyo a la toma de decisiones, permitiendo explorar escenarios hipotéticos y evaluar cómo cambios en las condiciones del sustrato o del proceso podrían afectar el rendimiento de la digestión anaerobia.

Finalmente, la implementación de esta interfaz demuestra la aplicabilidad práctica del modelo desarrollado y refuerza su potencial como herramienta de apoyo en estudios de diseño, optimización y evaluación de procesos de producción de biogás. Aunque en este trabajo la interfaz se limita al entorno de Google Colab, la estructura desarrollada es fácilmente extensible a aplicaciones web o sistemas de apoyo a la decisión más avanzados, lo que abre posibilidades futuras para la transferencia tecnológica del modelo a contextos industriales o institucionales.

6.15. Limitaciones del modelo y consideraciones finales

Si bien el modelo predictivo desarrollado mediante el algoritmo Random Forest mostró un desempeño satisfactorio en la estimación de la producción total de biogás, la remoción de sólidos volátiles totales (% TVS) y el porcentaje de metano en el biogás, es fundamental reconocer una serie de limitaciones inherentes tanto a la metodología empleada como a la naturaleza de los datos utilizados. La identificación explícita de estas limitaciones permite delimitar el alcance del

modelo, evitar interpretaciones erróneas de sus resultados y orientar adecuadamente su aplicación práctica.

6.15.1. Dependencia del modelo respecto al dataset disponible

Una de las principales limitaciones del modelo radica en su fuerte dependencia del conjunto de datos utilizado para el entrenamiento. El Random Forest, al igual que otros algoritmos de aprendizaje supervisado, aprende patrones estadísticos a partir de la información histórica disponible, por lo que su capacidad de generalización está condicionada por la diversidad, representatividad y calidad del dataset (Hastie et al., 2009; Kuhn & Johnson, 2013).

En este estudio, el dataset estuvo compuesto por experimentos provenientes mayoritariamente de literatura científica, realizados bajo condiciones controladas de laboratorio o a escala piloto. Esto implica que el modelo podría presentar un desempeño reducido al ser aplicado directamente a sistemas industriales de mayor escala, donde existen perturbaciones operacionales, heterogeneidad del sustrato y variabilidad ambiental más pronunciada. Por tanto, los resultados del modelo deben interpretarse como estimaciones orientativas y no como valores absolutos garantizados para todos los escenarios posibles.

6.15.2. Limitaciones asociadas a la extrapolación de resultados

Otra limitación relevante es la capacidad limitada del modelo para extrapolar fuera del rango de valores observados durante el entrenamiento. Los modelos basados en árboles, como Random Forest, son particularmente eficaces interpolando dentro del espacio de datos conocido, pero carecen de un mecanismo robusto para extrapolar correctamente cuando se les presentan condiciones extremas o no representadas en el dataset original (Breiman, 2001; Molnar, 2022).

Esto significa que, si el usuario introduce combinaciones de variables de entrada que difieren sustancialmente de las condiciones experimentales presentes en el dataset (por ejemplo, valores de carga orgánica, temperatura o volumen de inóculo fuera de los rangos históricos), las predicciones generadas pueden ser poco confiables. En consecuencia, se recomienda utilizar el modelo únicamente dentro de los rangos de operación cubiertos por los datos de entrenamiento.

6.15.3. Simplificación de variables categóricas mediante agrupación

Con el fin de reducir la dimensionalidad del problema y evitar una explosión del número de variables tras la codificación categórica, se optó por agrupar categorías como el tipo de sustrato, el tipo de inóculo y la fuente del inóculo en clases más generales. Si bien esta decisión permitió construir modelos más estables y computacionalmente eficientes, también implica una pérdida parcial de información específica (Kuhn & Johnson, 2013).

Por ejemplo, distintos tipos de bagazo cervecero o digestatos pueden presentar composiciones fisicoquímicas significativamente diferentes, las cuales quedan parcialmente ocultas al ser agrupadas bajo una misma categoría. Esta simplificación constituye una limitación estructural del modelo y debe ser considerada al analizar los resultados obtenidos.

6.15.4. Naturaleza empírica del modelo frente a modelos mecanísticos

El modelo desarrollado es de naturaleza empírica y estadística, lo que implica que no incorpora explícitamente las ecuaciones cinéticas ni los balances de masa y energía que gobiernan los procesos bioquímicos de la digestión anaerobia. A diferencia de los modelos mecanísticos, como el ADM1, el Random Forest no representa directamente las etapas metabólicas ni las interacciones microbianas subyacentes (Batstone et al., 2002).

Si bien esta aproximación empírica ofrece ventajas en términos de flexibilidad y capacidad predictiva cuando los mecanismos son complejos o parcialmente desconocidos, también limita la interpretabilidad físico-química de las predicciones. Por ello, el modelo debe entenderse como una herramienta complementaria a los enfoques mecanísticos tradicionales, y no como un reemplazo de estos.

6.15.5. Sensibilidad a la calidad de los datos de entrada

El desempeño del modelo está directamente condicionado por la calidad de los datos ingresados por el usuario. Errores en la medición de variables clave como sólidos totales, relación C/N, concentración de amoníaco o pH inicial pueden propagarse a través del modelo y generar predicciones erróneas. Este fenómeno es ampliamente reconocido en sistemas de aprendizaje automático, donde la calidad de los datos de entrada es un factor crítico para la confiabilidad de los resultados (Hastie et al., 2009).

En este contexto, se enfatiza la necesidad de contar con datos experimentales bien caracterizados, obtenidos mediante metodologías analíticas confiables y comparables con aquellas empleadas en los estudios que conforman el dataset original.

6.15.6. Consideraciones finales sobre la aplicabilidad del modelo

A pesar de las limitaciones señaladas, el modelo predictivo desarrollado constituye una herramienta valiosa para el análisis preliminar del rendimiento de producción de biogás bajo distintas condiciones de sustrato y operación. Su capacidad para integrar múltiples variables simultáneamente, identificar patrones no lineales y proporcionar explicaciones mediante técnicas de interpretabilidad como SHAP refuerza su utilidad como apoyo a la toma de decisiones (Lundberg & Lee, 2017; Molnar, 2022).

En aplicaciones prácticas, el modelo puede ser empleado como una herramienta exploratoria para evaluar escenarios operacionales, comparar alternativas de sustrato o estimar tendencias de desempeño, siempre que se utilice dentro de sus límites de validez. Futuros trabajos podrían mejorar su robustez mediante la incorporación de datos a escala industrial, la actualización continua del dataset y la combinación con modelos mecanísticos híbridos, ampliando así su aplicabilidad y precisión.

7. RESULTADOS Y DISCUSIÓN

El presente capítulo expone y analiza los principales resultados obtenidos a partir del desarrollo y aplicación del modelo predictivo basado en Random Forest para la estimación de la producción de biogás, la remoción de sólidos volátiles totales (% Remoción TVS) y el porcentaje de metano en el biogás generado a partir de residuos cerveceros bajo digestión anaerobia. A diferencia de los capítulos anteriores, enfocados en la fundamentación metodológica y en la construcción del modelo, esta sección se centra exclusivamente en la interpretación de los resultados, su significado técnico y su relevancia para la comprensión del proceso anaerobio.

El análisis de resultados se aborda desde una perspectiva integrada que combina métricas cuantitativas de desempeño predictivo (MAE, RMSE y coeficiente de determinación R^2) con herramientas avanzadas de interpretabilidad del modelo, particularmente el análisis SHAP (SHapley Additive exPlanations). Esta aproximación permite no solo evaluar la capacidad del modelo para reproducir adecuadamente el comportamiento observado en los datos experimentales, sino también identificar patrones subyacentes, relaciones no lineales y jerarquías de importancia entre las variables operacionales y composicionales del sistema (Breiman, 2001; Lundberg & Lee, 2017).

Asimismo, los resultados se discuten en el contexto de la digestión anaerobia de residuos cerveceros, considerando la complejidad inherente de este proceso biológico, caracterizado por interacciones microbianas múltiples, sensibilidad a las condiciones de operación y una fuerte dependencia de las propiedades del sustrato. En este sentido, los hallazgos obtenidos a partir del modelo se contrastan con la literatura especializada, evaluando su coherencia con conocimientos previos y destacando aquellos aspectos en los que el enfoque basado en aprendizaje automático aporta información complementaria o novedosa respecto a los modelos empíricos y mecanísticos tradicionales (Batstone et al., 2002; Hastie et al., 2009).

7.1. Evaluación del desempeño predictivo del modelo Random Forest

7.1.1. Producción total de biogás [mL/g VS]

El modelo Random Forest optimizado presentó un alto desempeño predictivo para la variable producción total de biogás, evidenciado por un coeficiente de determinación $R^2 = 0{,}749$, lo que indica que el modelo es capaz de explicar aproximadamente el 75 % de la variabilidad observada en los datos experimentales. Este nivel de ajuste resulta significativo considerando la elevada complejidad y variabilidad inherente a los procesos de digestión anaerobia, en los cuales intervienen múltiples interacciones no lineales entre las características del sustrato, el inóculo y las condiciones operacionales.

En términos de error, el modelo alcanzó un error absoluto medio (MAE) de 61,046 mL/g VS y una raíz del error cuadrático medio (RMSE) de 98,677 mL/g VS. El valor de MAE indica que, en

promedio, las predicciones del modelo difieren en aproximadamente 61 mL/g VS respecto a los valores experimentales observados, mientras que el RMSE, al penalizar con mayor peso los errores de mayor magnitud, refleja la capacidad del modelo para manejar adecuadamente observaciones extremas dentro del rango de producción analizado, como se puede ver en la Tabla 7.1. Considerando que el conjunto de datos incluye valores de producción total de biogás con una amplitud considerable, estos errores pueden considerarse relativamente acotados y coherentes con la dispersión experimental típica reportada en estudios de digestión anaerobia a escala de laboratorio.

Tabla 7.1: Métricas Modelo Optimizado - Producción total biogás.
Fuente: Elaboración propia.

Métrica	Valor
MAE	61.046
RMSE	98.677
R^2	0.749

Este comportamiento concuerda con estudios previos que han demostrado la efectividad de los modelos basados en Random Forest para predecir la producción de biogás en procesos de digestión anaerobia, particularmente en contextos donde existen relaciones no lineales y efectos de interacción entre las variables del sustrato y las condiciones del proceso (Breiman, 2001; Hassan et al., 2025). En este sentido, la producción total de biogás, al tratarse de una variable acumulativa, integra el resultado global de múltiples procesos bioquímicos a lo largo del tiempo, lo que tiende a generar una señal más estable y menos ruidosa en comparación con variables instantáneas o intermedias del proceso.

Los resultados obtenidos confirman que el modelo desarrollado es adecuado para estimar el rendimiento global de producción de biogás bajo distintas combinaciones de características del sustrato y parámetros operacionales. El nivel de ajuste alcanzado, junto con errores predictivos moderados en relación con el rango de la variable, valida el cumplimiento del objetivo específico asociado a esta variable y respalda el uso del modelo como una herramienta predictiva confiable para el análisis y evaluación de escenarios de digestión anaerobia de residuos cerveceros.

7.1.2. Porcentaje de remoción de sólidos volátiles totales (% Remoción TVS)

En el caso del porcentaje de remoción de sólidos volátiles totales, el modelo Random Forest optimizado mostró un desempeño predictivo moderado, alcanzando un coeficiente de determinación $R^2 = 0{,}669$, como lo indica la Tabla 7.2, lo que indica que aproximadamente el 67

% de la variabilidad observada en los datos experimentales es explicada por el modelo. Si bien este valor es inferior al obtenido para la producción total de biogás, sigue siendo representativo de una capacidad predictiva relevante, considerando la complejidad del fenómeno que se busca modelar.

En términos de error, el modelo presentó un error absoluto medio (MAE) de 6,237 %, Tabla 7.2, lo que implica que, en promedio, las predicciones difieren en poco más de seis puntos porcentuales respecto a los valores reales de remoción de TVS. Asimismo, el RMSE alcanzó un valor de 10,074 %, reflejando una mayor penalización de los errores de mayor magnitud y evidenciando una dispersión más elevada en ciertos casos particulares. Estos resultados sugieren que, si bien el modelo captura adecuadamente las tendencias generales de remoción de sólidos volátiles, existen condiciones experimentales específicas que introducen variabilidad adicional difícil de reproducir con precisión absoluta.

Tabla 7.2: Métricas Modelo Optimizado - Porcentaje de remoción TVS.
Fuente: Elaboración propia.

Métrica	Valor
MAE	6.237
RMSE	10.074
R^2	0.669

Este comportamiento es coherente con la naturaleza multifactorial de la remoción de TVS, la cual depende no solo de la composición del sustrato, sino también de la actividad metabólica del consorcio microbiano, el tipo y origen del inóculo, el tiempo de retención hidráulica y las condiciones fisicoquímicas del reactor, como pH, temperatura y alcalinidad (Hastie et al., 2009). A diferencia de la producción total de biogás, la remoción de sólidos volátiles representa un indicador más sensible a variaciones locales del proceso y a la fracción no biodegradable del sustrato, lo que introduce un mayor grado de incertidumbre experimental.

Diversos estudios han señalado que, si bien los modelos basados en Random Forest son particularmente eficaces para capturar relaciones no lineales asociadas a la degradación de materia orgánica, la heterogeneidad intrínseca de los residuos orgánicos y las diferencias en metodologías experimentales pueden limitar la precisión máxima alcanzable en la predicción de la remoción de sólidos volátiles (Guo et al., 2021). En este contexto, los valores de error obtenidos en el presente estudio se encuentran dentro de rangos comparables a los reportados en la literatura para sistemas de digestión anaerobia a escala de laboratorio.

No obstante, los resultados indican que el modelo desarrollado es capaz de reproducir adecuadamente las tendencias generales de eficiencia del proceso, permitiendo distinguir

escenarios de alta y baja remoción de TVS bajo distintas combinaciones de sustrato y condiciones operacionales. En consecuencia, el modelo se consolida como una herramienta útil para análisis comparativos, evaluación preliminar de estrategias de operación y apoyo a la toma de decisiones, validando el cumplimiento del objetivo específico asociado a la predicción de la remoción de sólidos volátiles totales.

7.1.3. Porcentaje de metano en el biogás (% CH_4)

Para la variable porcentaje de metano en el biogás, el modelo Random Forest optimizado alcanzó el mejor desempeño predictivo entre las tres variables analizadas, con un coeficiente de determinación $R^2 = 0,856$, lo que indica que el modelo es capaz de explicar aproximadamente el 86 % de la variabilidad observada en los datos experimentales. Este resultado evidencia una alta capacidad del modelo para capturar los patrones que gobiernan la composición del biogás bajo distintas condiciones del sustrato y del proceso.

En términos de error, el modelo presentó un MAE de 2,922 %, como se aprecia en la Tabla 7.3, lo que refleja una desviación promedio inferior a tres puntos porcentuales respecto a los valores reales de contenido de metano. Asimismo, el RMSE alcanzó un valor de 5,111 %, confirmando que incluso los errores de mayor magnitud se mantienen dentro de rangos relativamente acotados. Considerando que el porcentaje de CH_4 suele variar en intervalos limitados (típicamente entre 45 % y 70 % en digestión anaerobia de residuos orgánicos), estos valores representan una precisión elevada desde el punto de vista operativo y experimental.

Tabla 7.3: Métricas Modelo Optimizado - Porcentaje de metano en el biogás.
Fuente: Elaboración propia.

Métrica	Valor
MAE	2.922
RMSE	5.111
R^2	0.856

El alto desempeño observado para esta variable puede explicarse por el hecho de que el contenido de metano en el biogás está fuertemente controlado por variables fisicoquímicas relativamente estables, como la relación C/N, la concentración de amonio, la alcalinidad y el pH del sistema, las cuales influyen directamente en el equilibrio entre las poblaciones acetogénicas y metanogénicas (Angelidaki et al., 2011). Estas relaciones, aunque no lineales, presentan patrones consistentes que pueden ser capturados eficazmente por algoritmos basados en árboles de decisión como Random Forest.

Adicionalmente, a diferencia de la producción total de biogás o de la remoción de sólidos volátiles, el porcentaje de CH_4 es una variable normalizada, lo que reduce la influencia de errores de medición asociados al volumen total de gas producido y atenúa el efecto de variaciones experimentales extremas. Esta característica favorece una señal más limpia y menos ruidosa, facilitando el aprendizaje del modelo y contribuyendo a una mayor capacidad de generalización (Breiman, 2001).

Los resultados obtenidos concuerdan con estudios previos que han reportado un desempeño superior de modelos de aprendizaje automático en la predicción de la composición del biogás en comparación con variables de rendimiento global del proceso, particularmente cuando se dispone de información detallada sobre las condiciones operacionales y la composición del sustrato (Zhang et al., 2022). En este sentido, el modelo desarrollado demuestra una alta confiabilidad para estimar la calidad energética del biogás, lo que resulta especialmente relevante para aplicaciones orientadas a valorización energética y evaluación de escenarios de optimización del proceso.

En conjunto, el elevado valor de R^2 y los bajos errores obtenidos validan el uso del modelo Random Forest como una herramienta robusta para la predicción del porcentaje de metano en el biogás, confirmando el cumplimiento del objetivo específico asociado a esta variable y reforzando el potencial del enfoque propuesto para apoyar el diseño y la operación de sistemas de digestión anaerobia de residuos cerveceros.

7.1.4. Comparación global entre las tres variables de salida

La comparación entre los modelos desarrollados para las tres variables de salida revela diferencias claras en su desempeño predictivo, las cuales pueden explicarse tanto por la naturaleza del proceso de digestión anaerobia como por las características estadísticas de cada variable. En términos generales, el modelo asociado al porcentaje de metano en el biogás presentó el mejor ajuste predictivo, seguido por la producción total de biogás, mientras que la remoción de sólidos volátiles totales (TVS) exhibió el desempeño más bajo entre las variables analizadas.

El porcentaje de metano (CH_4) corresponde a una variable acotada dentro de un rango relativamente estrecho, lo que reduce su variabilidad global en comparación con otras variables del proceso. Esta característica favorece su modelación mediante algoritmos de aprendizaje automático, lo que se refleja en el mayor coeficiente de determinación obtenido ($R^2 = 0{,}856$). Desde el punto de vista del modelo, esta menor dispersión relativa facilita la identificación de patrones y relaciones entre variables de entrada y salida, permitiendo un ajuste más preciso.

Por su parte, la producción total de biogás corresponde a una variable acumulativa e integradora del proceso, ya que refleja el resultado global de múltiples etapas bioquímicas (hidrólisis,

acidogénesis, acetogénesis y metanogénesis). Esta condición contribuye a suavizar la variabilidad experimental, aunque no elimina completamente la influencia de factores operacionales y composicionales, lo que se traduce en un desempeño predictivo intermedio (R^2 = 0,749). A pesar de esta mayor complejidad, el modelo logró capturar adecuadamente los patrones generales del proceso.

En el caso de la remoción de TVS, el modelo presentó el menor desempeño predictivo (R^2 = 0,669), lo cual es consistente con la naturaleza de esta variable. La remoción de sólidos volátiles depende de múltiples factores simultáneos, incluyendo la fracción biodegradable efectiva del sustrato, la presencia de compuestos recalcitrantes y la eficiencia de las distintas rutas microbianas. Estas interacciones introducen una mayor heterogeneidad entre experimentos, incrementando la dispersión de los datos y dificultando la capacidad de predicción del modelo.

En conjunto, los resultados obtenidos muestran que el modelo Random Forest presenta un mejor desempeño en variables con menor variabilidad relativa o acotadas, como el porcentaje de metano, mientras que su desempeño disminuye en variables más complejas o altamente dependientes de múltiples interacciones del sistema, como la remoción de TVS. Esta diferencia es coherente con el comportamiento esperado de modelos de aprendizaje automático aplicados a sistemas biológicos complejos y refuerza la validez del enfoque adoptado en este estudio.

7.2. Análisis de importancia de variables mediante SHAP

Con el fin de interpretar el comportamiento interno del modelo Random Forest desarrollado para la predicción de la producción total de biogás, se aplicó el método SHAP (SHapley Additive exPlanations). Esta técnica permite cuantificar la contribución individual de cada variable de entrada a las predicciones del modelo, tanto a nivel global como local, proporcionando una interpretación coherente y consistente con la teoría de juegos cooperativos (Lundberg & Lee, 2017).

En esta sección se analizan en detalle los resultados obtenidos a partir de tres visualizaciones complementarias: el summary plot, el bar plot y el waterfall plot, las cuales permiten comprender no solo la relevancia relativa de las variables, sino también la dirección y magnitud de su efecto sobre la producción total de biogás.

7.2.1. Interpretabilidad del modelo de producción total de biogás

7.2.1.1. Interpretación del SHAP Summary Plot

El SHAP summary plot entrega una visión global del impacto de cada variable sobre la predicción de la producción total de biogás, combinando información de importancia y dirección del efecto. En este gráfico, Figura 7.1, las variables se ordenan de acuerdo con su contribución promedio absoluta, mientras que el color de los puntos representa el valor de la variable (bajo en azul, alto en rojo)

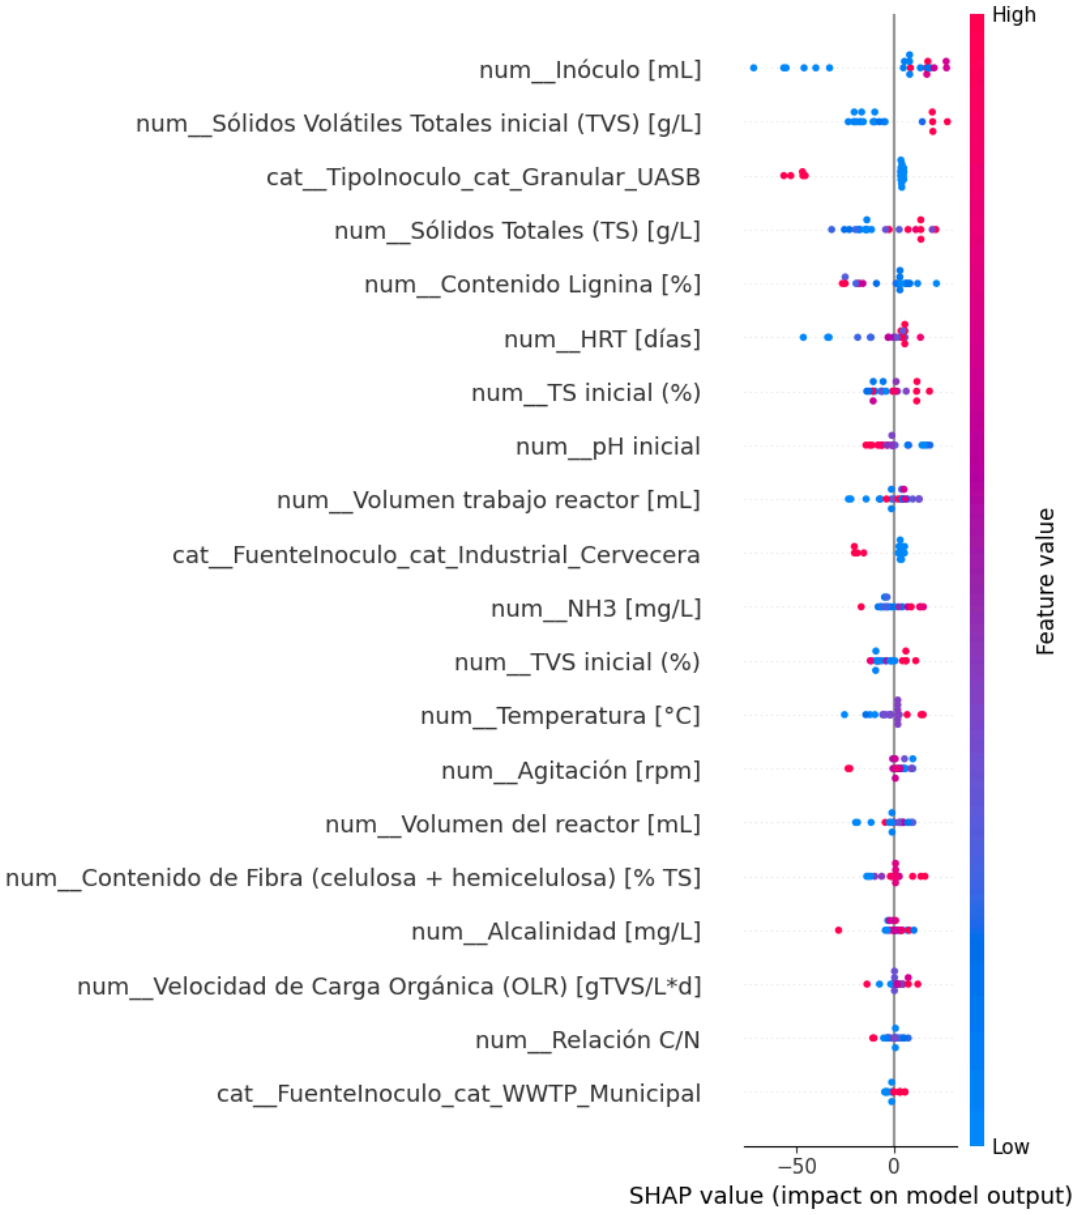

Figura 7.1: Summary Plot Producción total de Biogás.
Fuente: Elaboración propia.

Los resultados del modelo actualizado muestran que los sólidos totales (TS) [g/L] y los sólidos volátiles totales iniciales (TVS) [g/L] se posicionan como las variables con mayor impacto sobre la producción total de biogás. Valores elevados de TS y TVS inicial se asocian mayoritariamente a contribuciones positivas en la predicción, lo que resulta coherente con la base del proceso de digestión anaerobia, dado que estas variables representan la fracción biodegradable disponible para la conversión microbiana a biogás. No obstante, la dispersión observada en el gráfico sugiere la presencia de efectos no lineales y posibles interacciones con otras variables operacionales, como el tiempo de retención hidráulica y la agitación del sistema.

A diferencia del modelo previo, el volumen de inóculo [mL] presenta un impacto relativo menor en el modelo actualizado, lo que sugiere que, una vez superado un umbral mínimo de biomasa activa, la disponibilidad y características del sustrato pasan a ser los factores dominantes en la producción total de biogás. Este comportamiento es consistente con estudios que indican que, en condiciones batch o semicontinuas bien inoculadas, el efecto del inóculo se atenúa frente a variables asociadas a la carga orgánica y su biodegradabilidad (Angelidaki et al., 2018).

La aparición destacada de variables categóricas asociadas al tipo de inóculo, en particular Granular UASB, indica que ciertos inóculos continúan aportando ventajas relevantes al proceso. Esto puede atribuirse a una mayor densidad microbiana, mejor retención de biomasa y mayor resistencia a variaciones operacionales, características ampliamente documentadas en sistemas anaerobios de tratamiento de residuos industriales y aguas residuales (De Clercq et al., 2019).

Asimismo, variables estructurales del sustrato, como el contenido de lignina [%] y el contenido de fibra (celulosa + hemicelulosa), muestran contribuciones negativas cuando presentan valores elevados. Este patrón refleja la menor biodegradabilidad de fracciones lignocelulósicas complejas, que dificultan el acceso microbiano y limitan la tasa de conversión a biogás, en concordancia con lo reportado en la literatura sobre digestión anaerobia de residuos ricos en fibras estructurales (Triolo et al., 2011).

7.2.1.2. Interpretación del SHAP Bar Plot

El SHAP bar plot, Figura 7.2, presenta la importancia media absoluta de cada variable, permitiendo identificar cuáles explican una mayor proporción de la variabilidad del modelo, independientemente del signo del efecto.

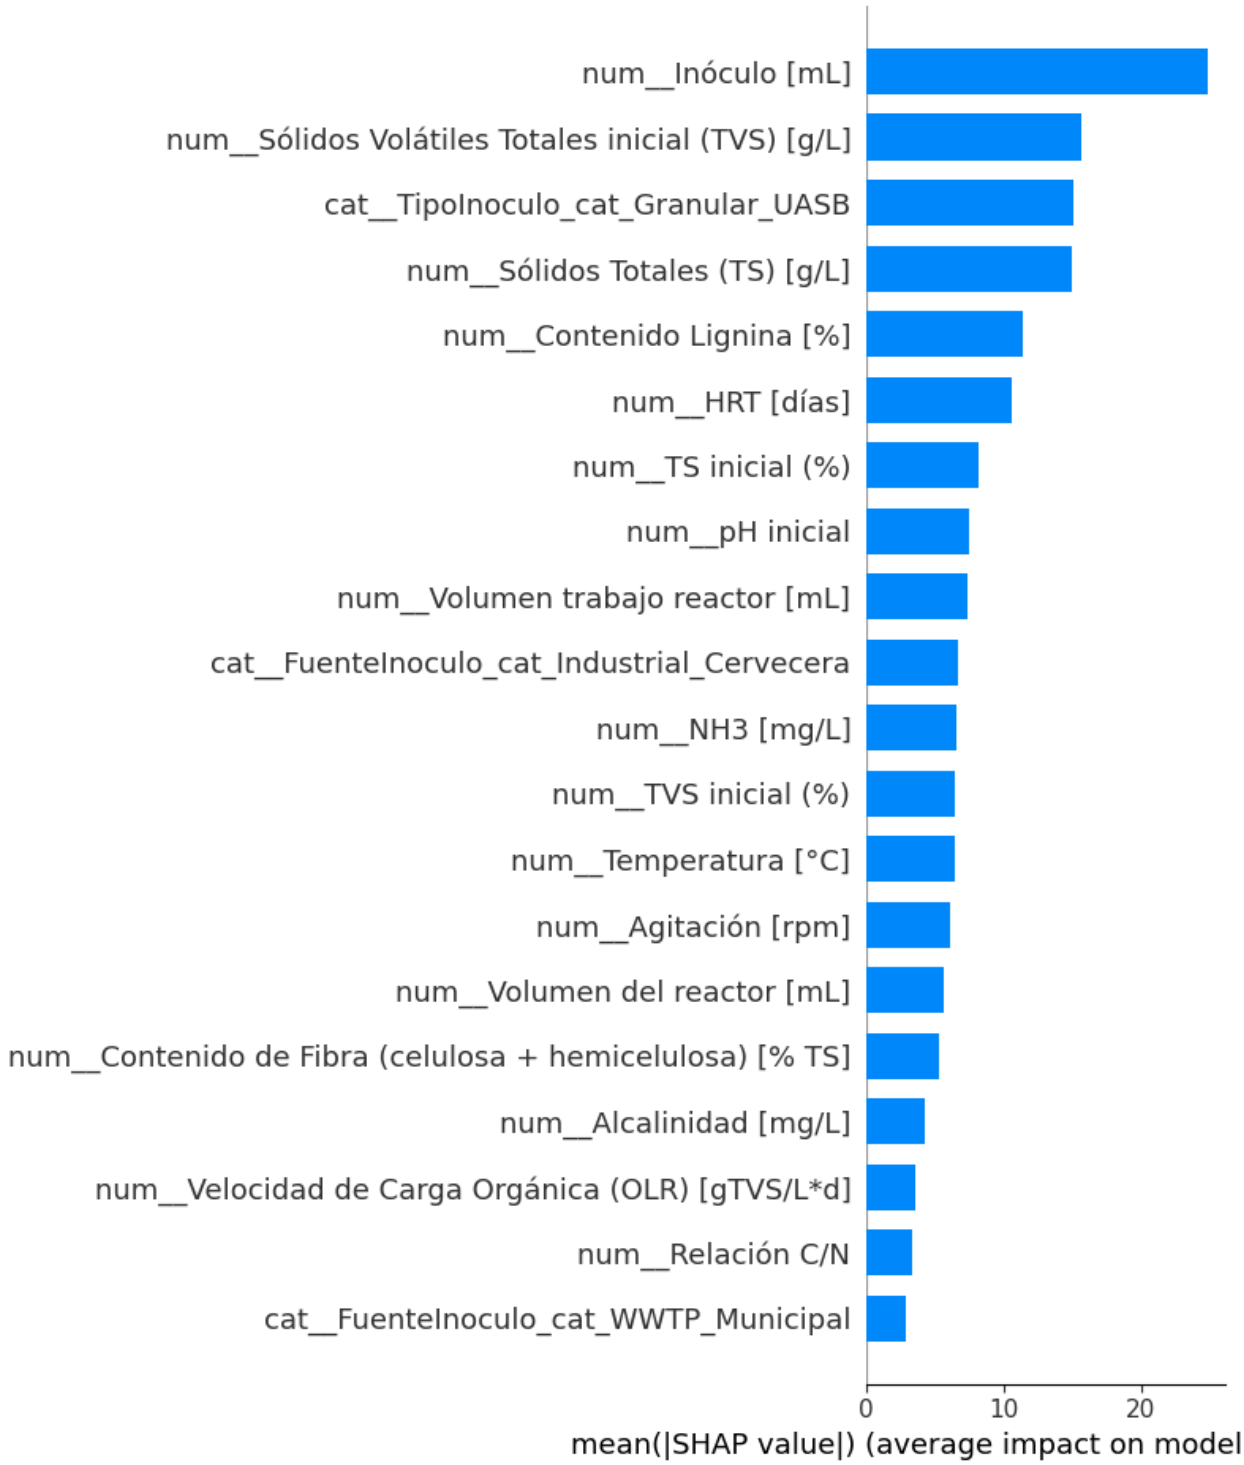

Figura 7.2: Bar Plot Producción total de Biogás.
Fuente: Elaboración propia.

En el modelo actualizado se observa que el volumen de inóculo [mL] continúa siendo la variable con mayor capacidad explicativa, seguido por los sólidos volátiles totales iniciales (TVS) [g/L],

los sólidos totales (TS) [g/L] y el tipo de inóculo: Granular UASB. Esta jerarquía refuerza la idea de que la producción total de biogás está fuertemente controlada tanto por la disponibilidad de biomasa activa como por la cantidad de materia orgánica biodegradable presente en el sistema. En particular, la relevancia simultánea de TVS y TS sugiere que el modelo distingue adecuadamente entre la fracción total de sólidos y aquella efectivamente susceptible de ser transformada en biogás.

Asimismo, el contenido de lignina [%] aparece dentro del grupo de variables con alta importancia relativa, lo que pone de manifiesto el rol limitante de las fracciones recalcitrantes del sustrato sobre la producción de biogás. Este resultado es consistente con la evidencia experimental que indica que un mayor contenido de lignina reduce la accesibilidad microbiana y disminuye la eficiencia global del proceso anaerobio.

Variables operacionales como el tiempo de retención hidráulica (HRT), el pH inicial y el volumen de trabajo del reactor presentan una importancia intermedia. Esto sugiere que, si bien influyen de manera significativa en la dinámica del proceso, su efecto es principalmente modulador dentro del rango experimental analizado, más que un factor determinante directo de la producción total de biogás. Este comportamiento concuerda con estudios que indican que, una vez aseguradas condiciones operacionales adecuadas, la producción de biogás depende principalmente de la cantidad y calidad del sustrato disponible (Appels et al., 2008).

Finalmente, variables como la relación C/N, la velocidad de carga orgánica (OLR) y ciertas fuentes de inóculo presentan una menor importancia relativa en el modelo. Esto puede atribuirse tanto a una menor variabilidad de estas variables en el dataset como a efectos indirectos ya capturados por otras variables altamente correlacionadas, como TS, TVS y el tipo de inóculo empleado.

7.2.1.3. Interpretación del SHAP Waterfall Plot

El SHAP waterfall plot, Figura 7.3, permite analizar una predicción individual del modelo, descomponiendo cómo cada variable contribuye a desplazar el valor base del modelo hacia la predicción final de producción de biogás.

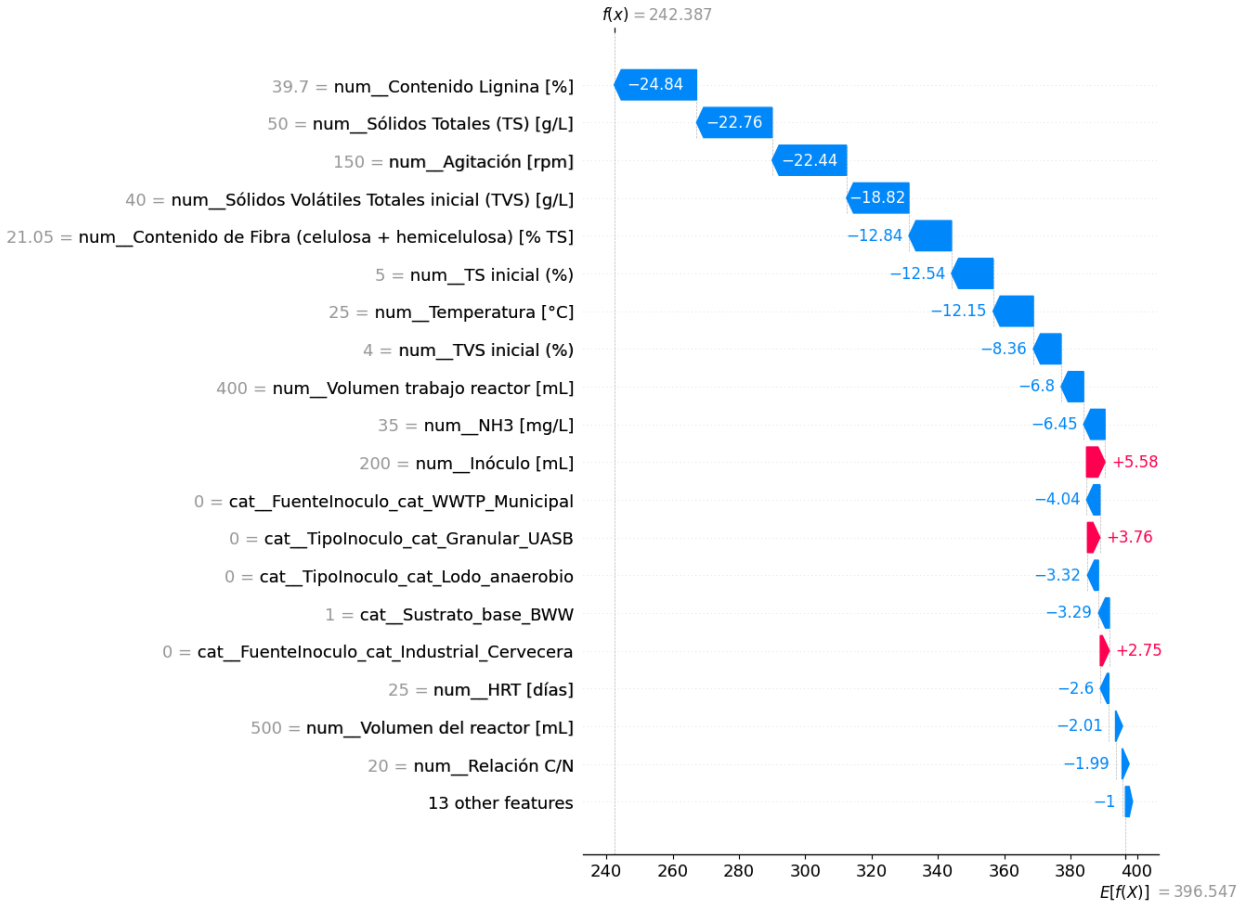

Figura 7.3: Waterfall Plot Producción total de Biogás.
Fuente: Elaboración propia.

En el caso analizado, se observa que valores elevados de contenido de lignina [%], sólidos totales (TS) [g/L] y sólidos volátiles totales iniciales (TVS) [g/L] generan contribuciones negativas significativas, reduciendo de manera importante la predicción respecto al valor esperado promedio del modelo. Este comportamiento sugiere que, bajo las condiciones evaluadas, una alta concentración de sólidos, especialmente asociados a fracciones estructurales recalcitrantes, puede inducir limitaciones en la biodegradabilidad del sustrato y en la transferencia de masa, restringiendo la eficiencia global del proceso de digestión anaerobia.

Asimismo, variables operacionales como la agitación [rpm] y el volumen de trabajo del reactor [mL] también presentan contribuciones negativas en este caso particular, lo que podría estar asociado a condiciones subóptimas de mezcla o a efectos de dilución y escala que afectan la interacción entre la biomasa y el sustrato. Estos resultados refuerzan la idea de que la producción de biogás no depende únicamente de la carga orgánica, sino también de la forma en que esta es gestionada dentro del reactor.

Por otro lado, el volumen de inóculo [mL] aporta una contribución positiva relevante, compensando parcialmente los efectos negativos asociados a la composición del sustrato. Esto indica que, para este escenario específico, un mayor aporte de biomasa activa permite amortiguar las limitaciones impuestas por la fracción recalcitrante del sustrato, favoreciendo la conversión a biogás. De manera similar, ciertas variables categóricas, como el tipo de inóculo (Granular UASB) y la fuente de inóculo industrial cervecera, muestran contribuciones positivas moderadas, lo que sugiere ventajas asociadas a una mayor estabilidad microbiana y adaptación a residuos de origen cervecero.

El análisis local proporcionado por el waterfall plot resulta especialmente útil para evaluar escenarios específicos y comprender por qué el modelo entrega determinadas predicciones. En este sentido, el gráfico evidencia la interacción compleja entre composición del sustrato, condiciones operacionales y características del inóculo, reforzando la aplicabilidad práctica del modelo como herramienta de apoyo a la toma de decisiones en sistemas de digestión anaerobia.

7.2.2. Interpretabilidad del modelo de Porcentaje de remoción TVS

El análisis de interpretabilidad mediante SHAP aplicado al modelo predictivo del porcentaje de remoción de sólidos volátiles totales permite profundizar en los mecanismos mediante los cuales las variables de entrada influyen en la eficiencia de degradación de la materia orgánica durante el proceso de digestión anaerobia. A diferencia de la producción total de biogás, la remoción de TVS está directamente asociada a la biodegradabilidad del sustrato y a la estabilidad de las condiciones operacionales, lo que introduce una mayor complejidad en su modelación.

7.2.2.1. Interpretación del summary plot

El summary plot del modelo de remoción de TVS muestra que las variables con mayor impacto global corresponden principalmente a parámetros operacionales y de control químico, los cuales gobiernan directamente la estabilidad y eficiencia de la degradación de la fracción orgánica. Entre las variables más influyentes destacan la concentración de amonio (NH_3), el volumen de inóculo [mL], la agitación [rpm] y la alcalinidad [mg/L], como se aprecia en la Figura 7.4.

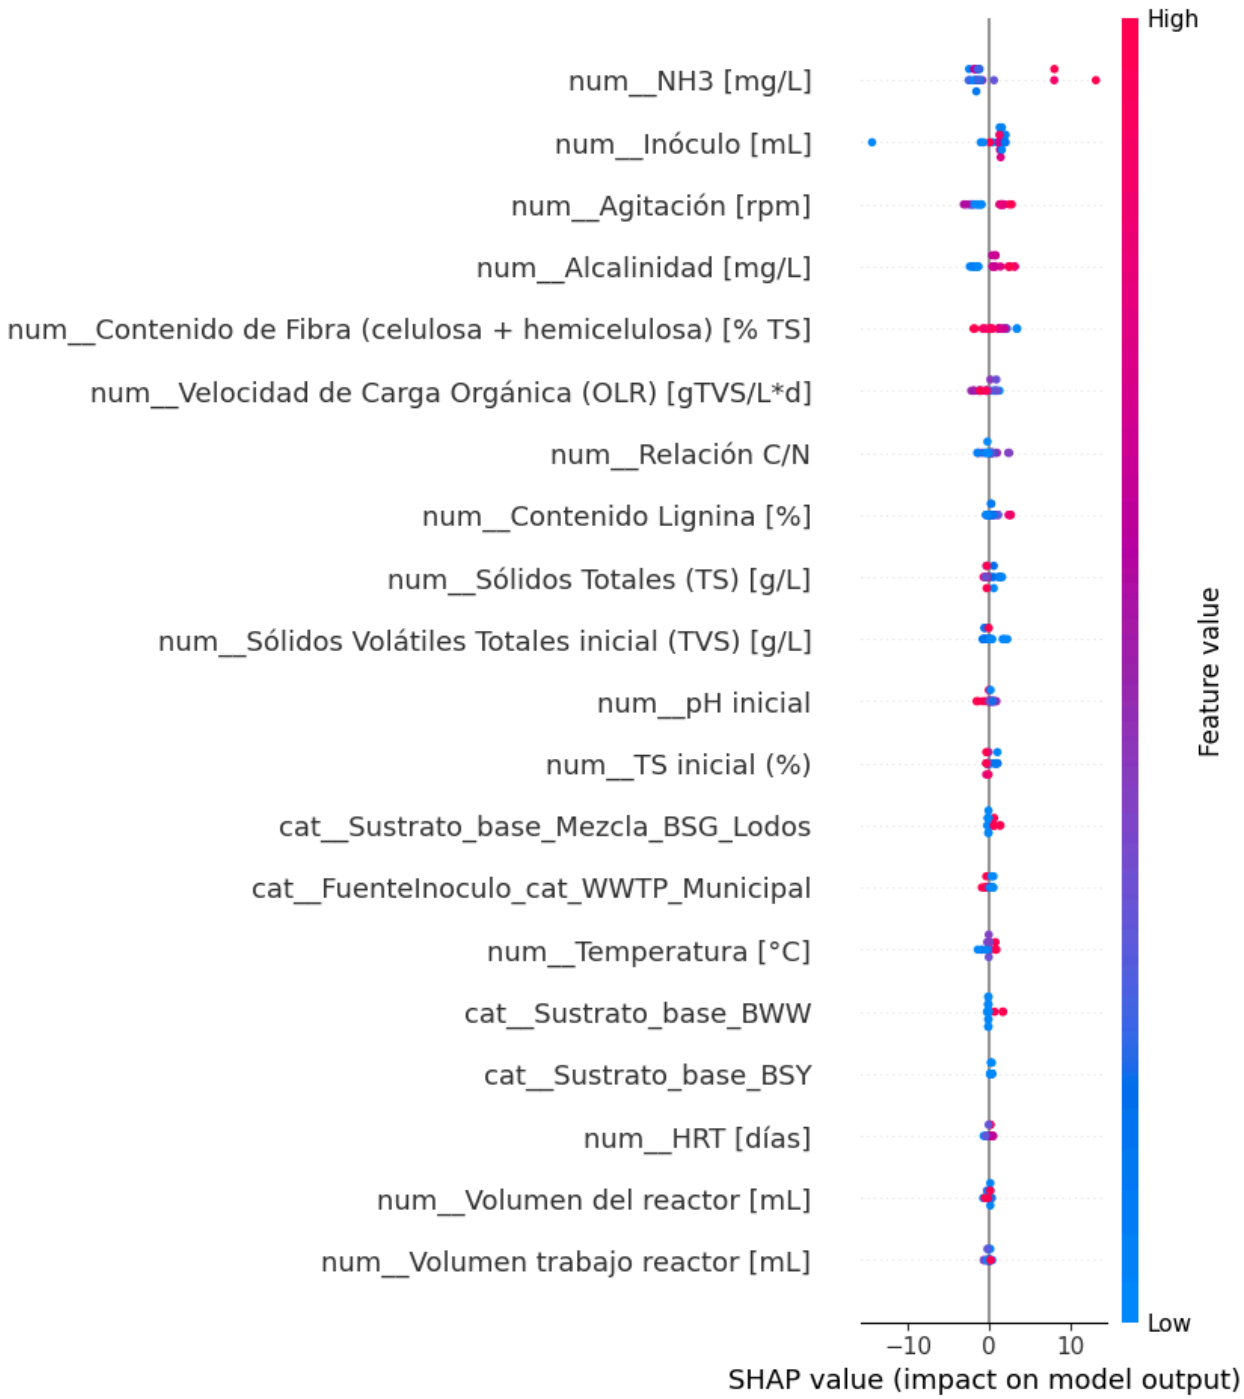

Figura 7.4: Summary Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

La distribución de los valores SHAP indica que concentraciones elevadas de NH_3 tienden a ejercer un efecto predominantemente negativo sobre la remoción de TVS, evidenciado por valores SHAP negativos asociados a puntos de color rojo. Este comportamiento es coherente con la literatura, donde el amoníaco es reconocido como uno de los principales inhibidores del

proceso anaerobio, afectando especialmente a las poblaciones metanogénicas y acetogénicas, y provocando una acumulación de sólidos no degradados (Chen et al., 2008; Yenigün & Demirel, 2013).

En contraste, mayores volúmenes de inóculo muestran contribuciones mayoritariamente positivas, lo que sugiere que una mayor cantidad de biomasa activa favorece la hidrólisis y conversión de los sólidos volátiles, aumentando la eficiencia de remoción de TVS. De manera similar, niveles adecuados de agitación presentan efectos positivos sobre la predicción, lo que puede asociarse a una mejora en la transferencia de masa, el contacto sustrato–microorganismo y la homogenización del sistema, factores clave para una degradación eficiente de la materia orgánica

.

La alcalinidad también aparece como una variable relevante, con contribuciones positivas asociadas a valores elevados, reflejando su rol fundamental como sistema tampón. Una alcalinidad adecuada permite amortiguar la acumulación de ácidos grasos volátiles, manteniendo condiciones favorables para la actividad microbiana y, por ende, para una mayor remoción de TVS.

Asimismo, variables asociadas a la composición del sustrato, como el contenido de lignina [%] y el contenido de fibra (celulosa + hemicelulosa), presentan impactos generalmente negativos cuando alcanzan valores elevados. Esto refleja la mayor resistencia estructural de los compuestos lignocelulósicos frente a la degradación anaerobia, lo que limita la conversión de sólidos volátiles y reduce la eficiencia de remoción (Mata-Alvarez et al., 2014).

7.2.2.2. Análisis del bar plot de importancia media

El bar plot de valores SHAP promedio confirma jerárquicamente la relevancia de las variables identificadas en el summary plot. En particular, la concentración de NH_3 [mg/L] emerge como el factor más influyente en términos absolutos, seguida por el volumen de inóculo [mL], la agitación [rpm] y la alcalinidad [mg/L], señalado en la Figura 7.5.

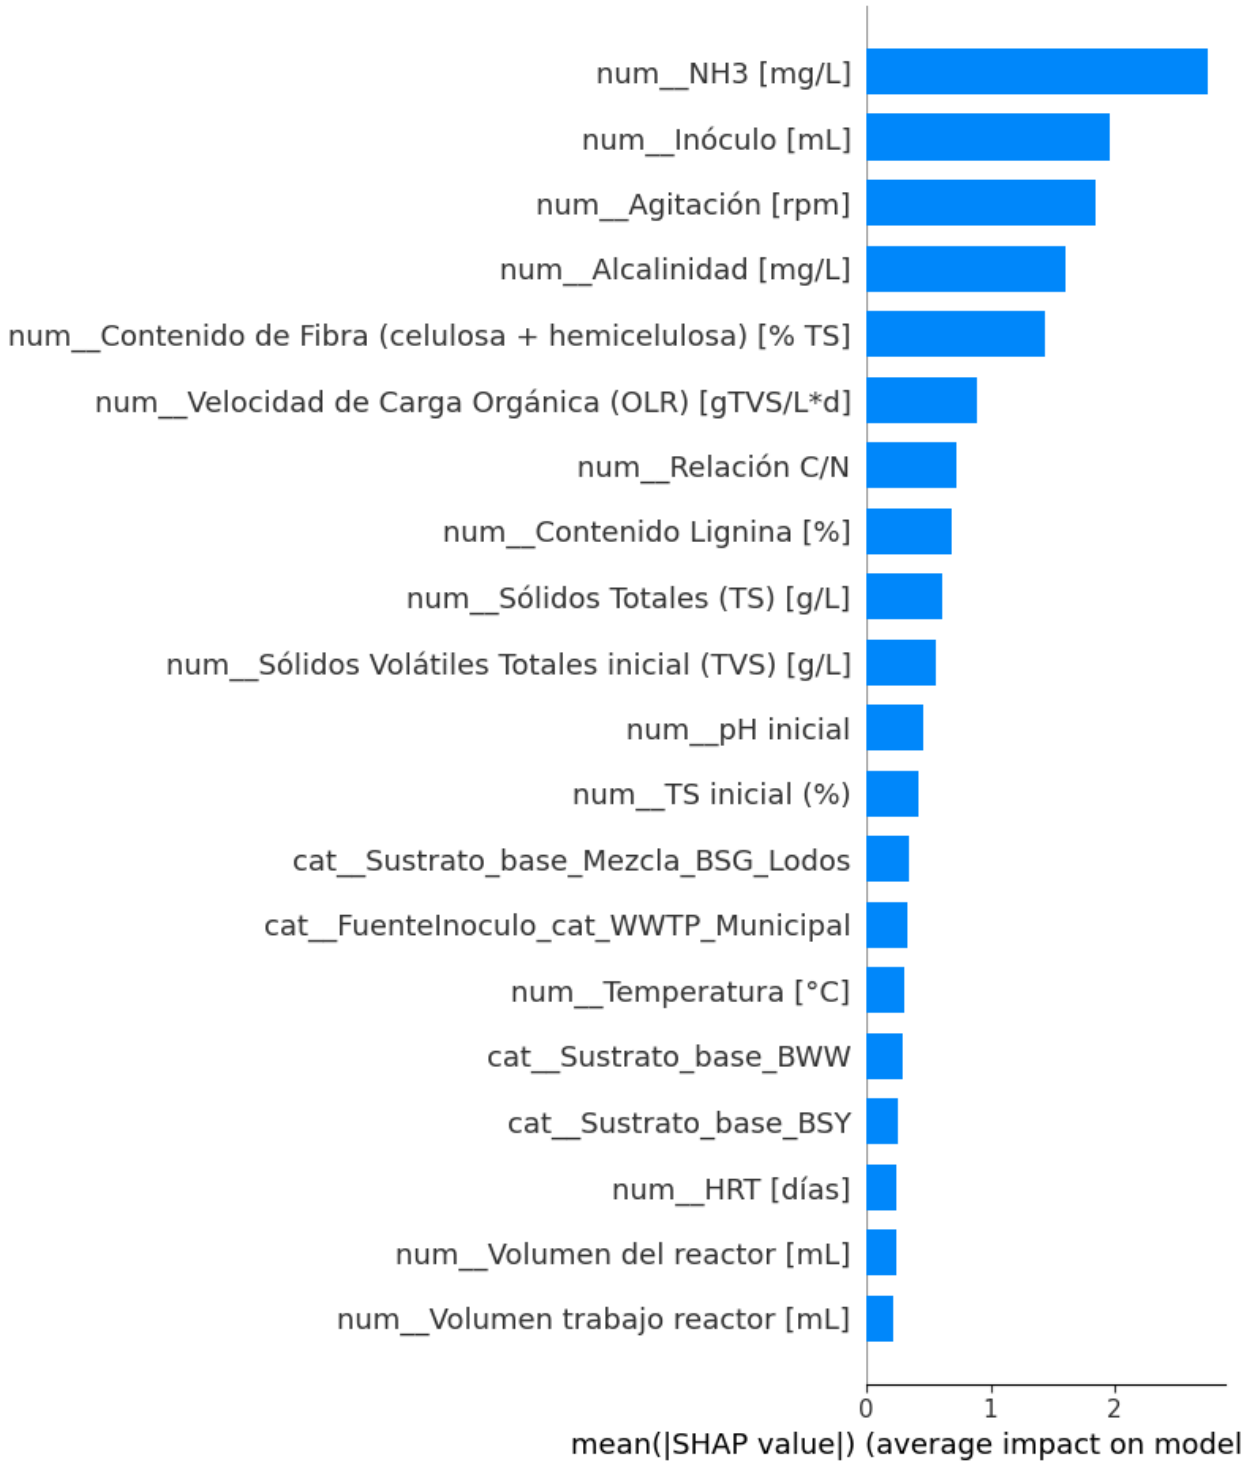

Figura 7.5: Bar Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

Este resultado pone de manifiesto que la remoción de TVS está fuertemente condicionada por el equilibrio fisicoquímico y biológico del sistema, más que por variables estrictamente geométricas

del reactor. La elevada importancia del NH_3 refuerza su rol crítico como variable de control del proceso, dado que concentraciones excesivas generan inhibición microbiana y reducen la capacidad de degradación de los sólidos volátiles.

Asimismo, la relevancia del volumen de inóculo y de la agitación indica que la disponibilidad de biomasa activa y las condiciones de transferencia de masa son determinantes para maximizar la conversión de la fracción orgánica. En este contexto, la alcalinidad actúa como un factor estabilizador del pH, amortiguando la acumulación de ácidos grasos volátiles y favoreciendo la continuidad del proceso de degradación anaerobia (Appels et al., 2008).

La importancia intermedia de la relación C/N y de la velocidad de carga orgánica (OLR) sugiere que, si bien estos parámetros influyen en la eficiencia del proceso, su efecto es altamente dependiente del contexto operativo y de su interacción con otras variables clave, como el NH_3 y la alcalinidad. Este comportamiento no lineal refuerza la idoneidad del uso de modelos basados en ensambles, como Random Forest, para capturar las dinámicas complejas propias de los sistemas de digestión anaerobia (Breiman, 2001).

7.2.2.3. Análisis del waterfall plot (ejemplo individual)

El waterfall plot, Figura 7.6, permite analizar de manera local cómo un conjunto específico de condiciones experimentales conduce a la predicción final del porcentaje de remoción de TVS, descomponiendo el valor base del modelo en contribuciones positivas y negativas asociadas a cada variable.

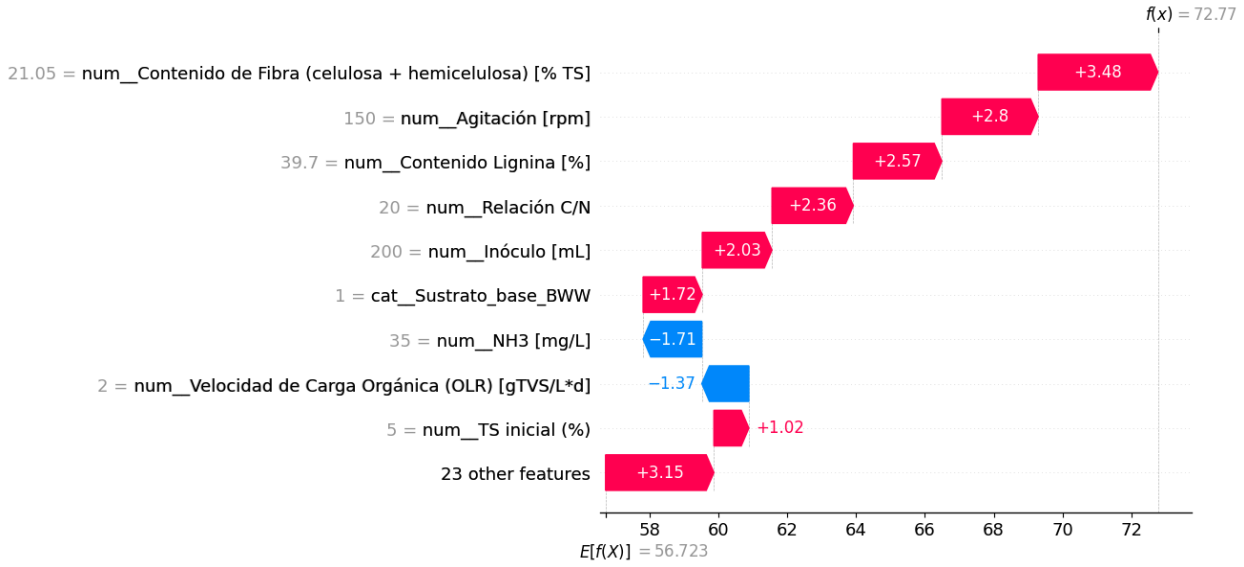

Figura 7.6: Waterfall Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

En el ejemplo analizado, se observa que concentraciones elevadas de NH_3 generan una contribución negativa dominante, reduciendo significativamente la remoción de TVS predicha, lo que es consistente con el efecto inhibitorio del amoníaco sobre la actividad microbiana y la degradación de la materia orgánica. De forma similar, ciertos niveles de velocidad de carga orgánica (OLR) también aportan efectos negativos, sugiriendo una posible sobrecarga del sistema que limita la eficiencia del proceso.

Por el contrario, variables como el volumen de inóculo, la agitación y una alcalinidad adecuada presentan contribuciones positivas, compensando parcialmente los efectos inhibitorios y favoreciendo la estabilidad del proceso. Estas variables reflejan condiciones operacionales que promueven una mayor actividad biológica y una mejor transferencia de masa, elementos clave para una remoción eficiente de los sólidos volátiles.

Este tipo de análisis resulta particularmente valioso desde un punto de vista operativo, ya que permite identificar con claridad qué variables son responsables de un desempeño subóptimo bajo condiciones específicas, facilitando la toma de decisiones orientadas a la optimización del proceso. La capacidad de SHAP para descomponer la predicción en contribuciones individuales refuerza su utilidad como herramienta de análisis de sensibilidad en sistemas biológicos complejos (Lundberg & Lee, 2017).

En conjunto, los resultados del análisis SHAP para la remoción de TVS evidencian que el modelo captura adecuadamente las interacciones entre factores inhibitorios, parámetros operacionales y características del sustrato, lo que explica tanto su desempeño predictivo como su potencial aplicación como herramienta de apoyo al análisis y ajuste de estrategias operacionales en sistemas de digestión anaerobia.

7.2.3. Interpretabilidad del modelo de Porcentaje de CH_4 en biogás

El análisis de interpretabilidad mediante SHAP aplicado al modelo Random Forest desarrollado para la predicción del porcentaje de metano en el biogás permite identificar las variables que ejercen mayor influencia sobre la composición del gas producido, así como el sentido y magnitud de su impacto. A diferencia de la producción total de biogás, esta variable responde a equilibrios metabólicos más finos dentro del consorcio microbiano, lo que se refleja en una estructura de importancia de variables distinta y más distribuida.

7.2.3.1. Interpretación del summary plot

El summary plot del modelo de porcentaje de CH_4, Figura 7.7, en biogás revela que el contenido de lignina del sustrato es la variable con mayor impacto global sobre la predicción del porcentaje de metano, seguida por la alcalinidad, la fuente de inóculo proveniente de planta de biogás, el TVS inicial (%) y la concentración de amonio (NH_3). La dispersión de los valores SHAP indica

que estas variables no solo presentan una alta relevancia, sino que además exhiben efectos dependientes de su magnitud y del contexto operativo en el que se insertan.

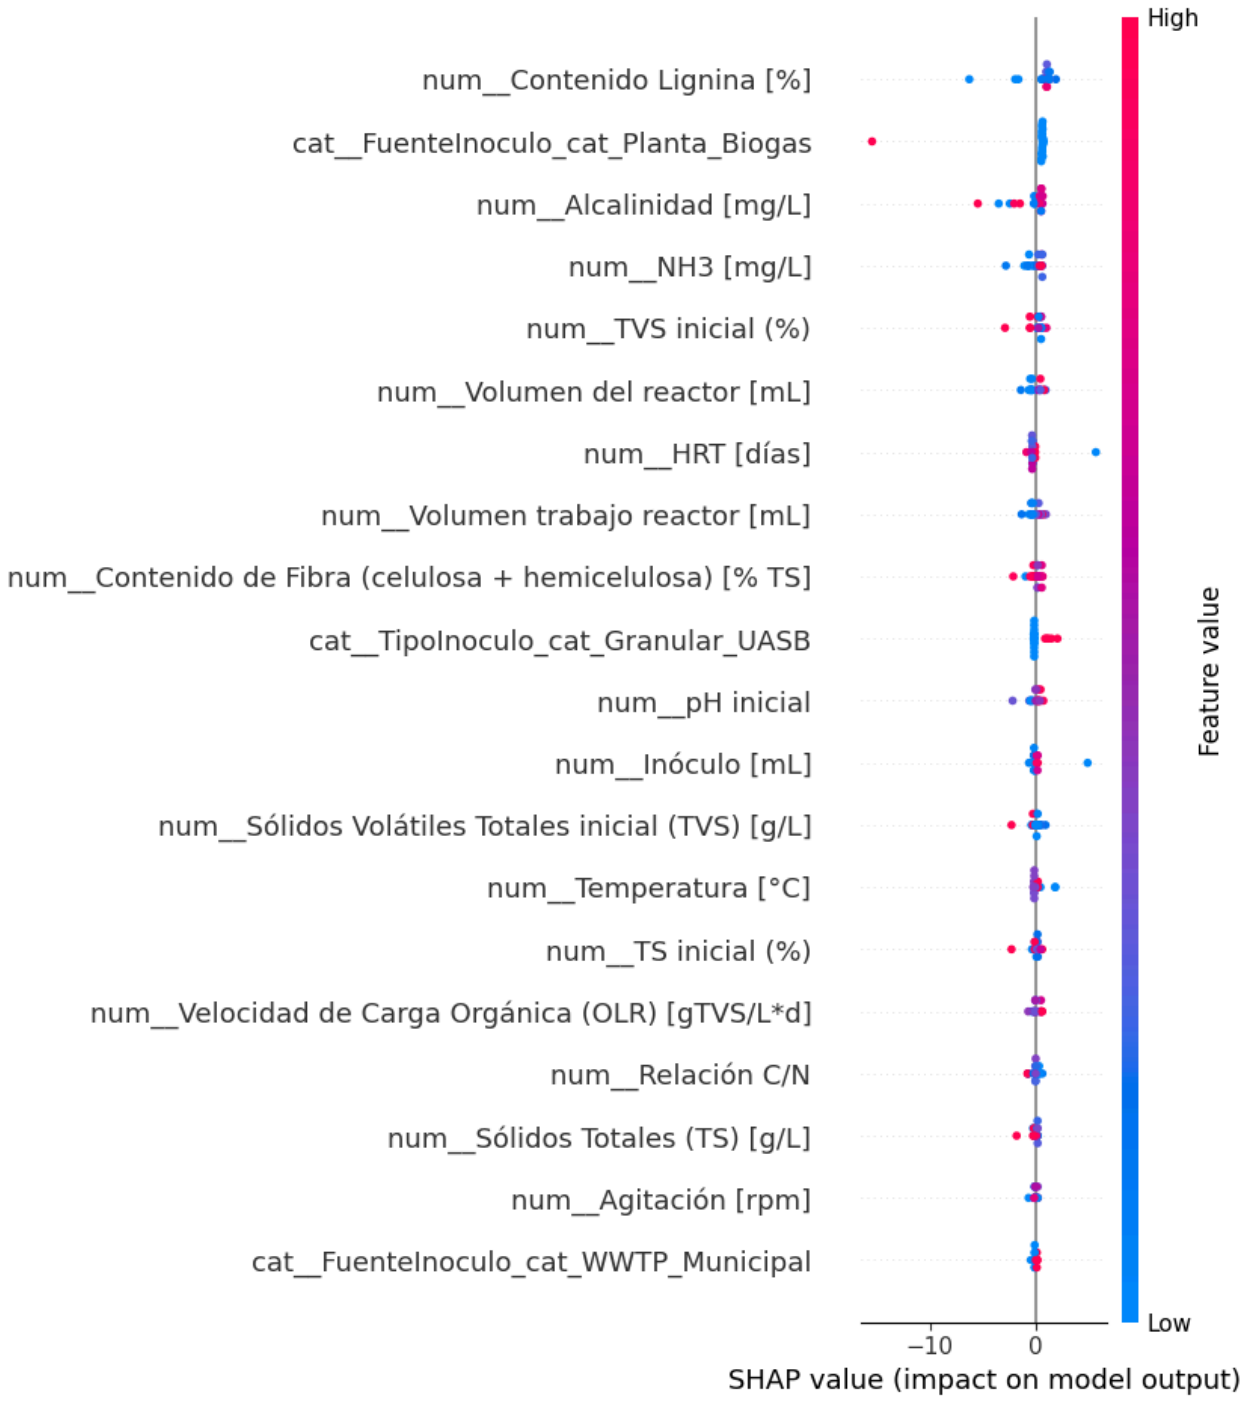

Figura 7.7: Summary Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

En particular, valores elevados de lignina tienden a generar contribuciones negativas sobre el porcentaje de CH_4, lo que resulta coherente con la naturaleza recalcitrante de este polímero. La alta proporción de lignina dificulta la hidrólisis de la materia orgánica y retrasa la disponibilidad de compuestos fácilmente fermentables, afectando indirectamente la eficiencia de las rutas metanogénicas y reduciendo la fracción de metano en el biogás producido.

Por el contrario, una alcalinidad adecuada muestra contribuciones predominantemente positivas, reflejando su rol fundamental en la estabilización del pH del sistema y en la protección de las arqueas metanogénicas frente a la acidificación causada por la acumulación de ácidos grasos volátiles. Este efecto amortiguador resulta especialmente relevante para sostener una metanogénesis eficiente y favorecer un mayor contenido de CH_4 en el biogás.

La presencia de la variable categórica asociada a la fuente de inóculo proveniente de plantas de biogás sugiere que inóculos previamente adaptados a procesos metanogénicos pueden favorecer una mayor eficiencia en la conversión final a metano. Sin embargo, el patrón observado también indica que este efecto no es uniforme, dependiendo de su interacción con la composición del sustrato y las condiciones operacionales.

Finalmente, variables como el TVS inicial (%) y la concentración de NH_3 presentan efectos mixtos, evidenciando que tanto la disponibilidad de materia orgánica como la presencia de compuestos potencialmente inhibitorios influyen de manera no lineal en la calidad del biogás. Este comportamiento refuerza la idea de que el porcentaje de CH_4 no depende únicamente de la cantidad de sustrato degradado, sino del equilibrio entre carga orgánica, estabilidad fisicoquímica y actividad metanogénica efectiva del sistema.

7.2.3.2. Análisis del bar plot (importancia media absoluta)

El bar plot de valores SHAP promedio absolutos confirma que el contenido de lignina y la alcalinidad concentran la mayor contribución explicativa del modelo de porcentaje de CH_4, señalados en la Figura 7.8, seguidas por la fuente de inóculo proveniente de plantas de biogás, el TVS inicial (%) y la concentración de NH_3. A diferencia del modelo de producción total de biogás, las variables operacionales asociadas a condiciones físicas del reactor, como la temperatura, el volumen del reactor o la agitación, presentan una importancia relativa menor en la explicación de la fracción de metano.

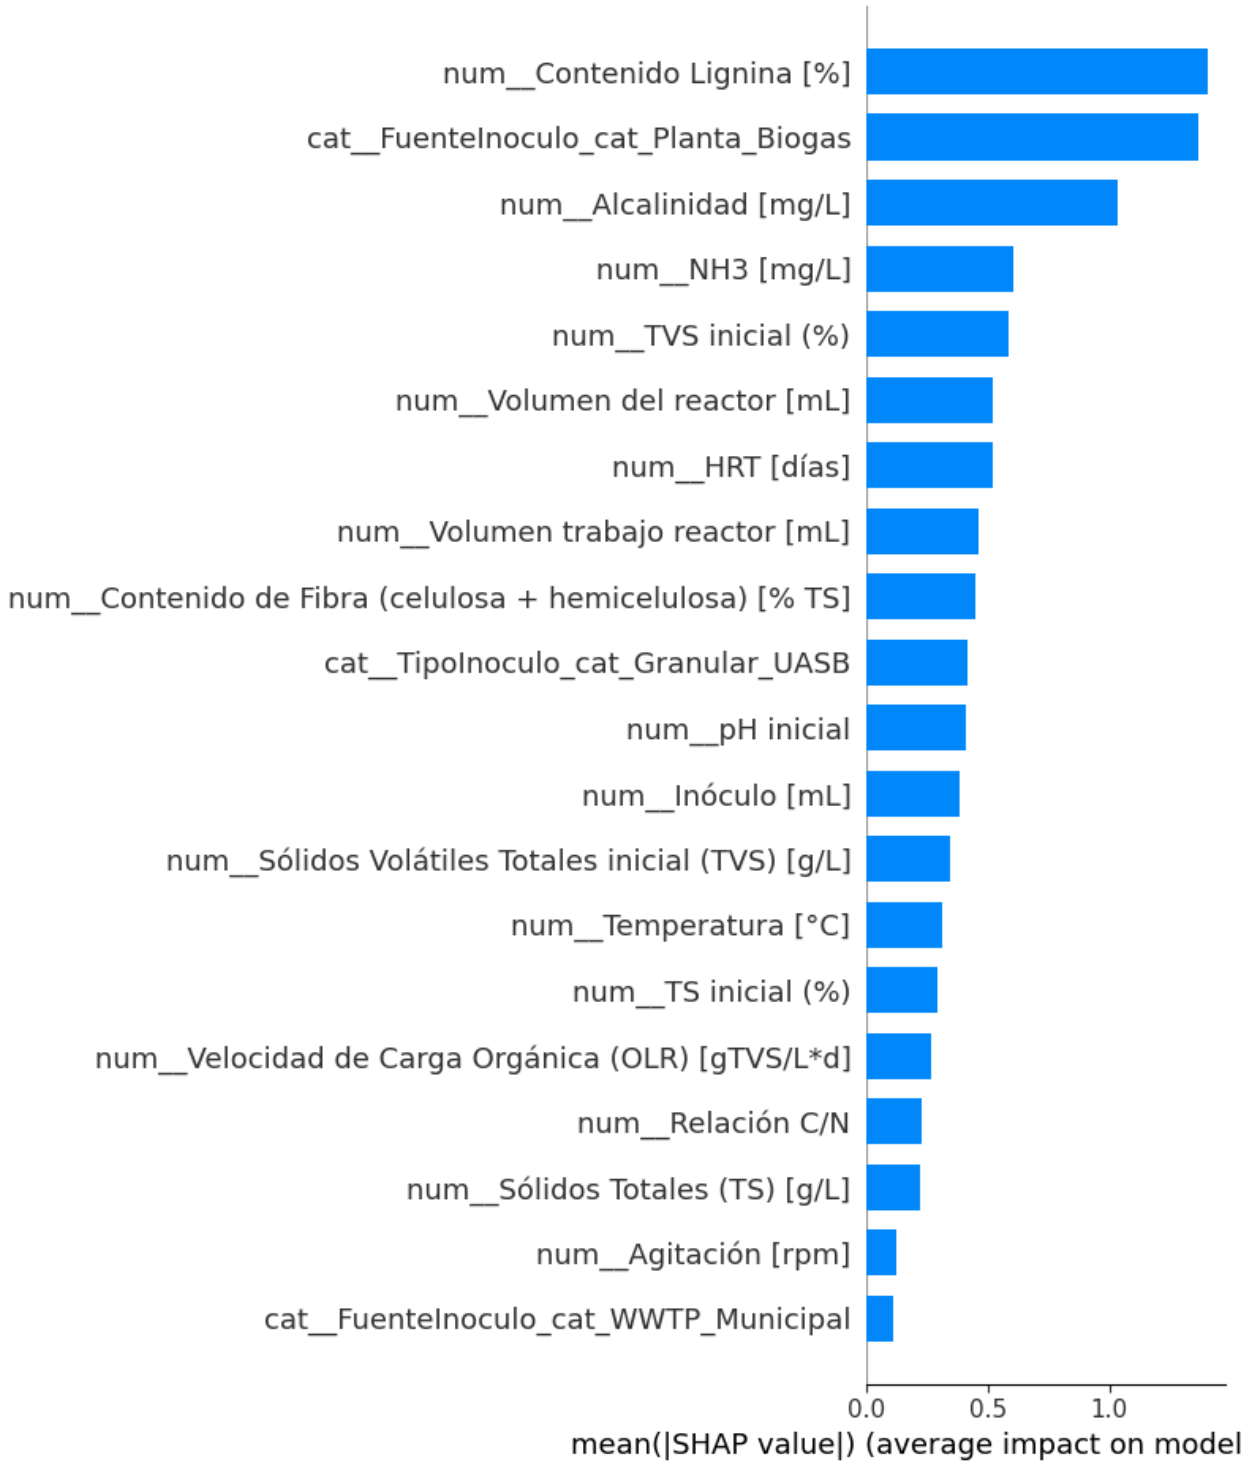

Figura 7.8: Bar Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

Este resultado sugiere que la composición del biogás está gobernada principalmente por factores químicos y bioquímicos internos del proceso, más que por variables hidráulicas o geométricas.

En este contexto, la alcalinidad emerge como un parámetro clave, ya que regula indirectamente la actividad metanogénica al mantener condiciones de pH estables y favorables para las arqueas metanogénicas, mientras que la lignina actúa como un factor estructural limitante que condiciona la accesibilidad del carbono biodegradable y, por ende, la eficiencia de conversión hacia metano.

La menor importancia relativa de variables como la velocidad de carga orgánica (OLR) y la relación C/N indica que, si bien estos parámetros son críticos para la estabilidad global del proceso de digestión anaerobia, su influencia sobre el porcentaje de CH_4 es más indirecta y se manifiesta principalmente a través de su interacción con variables dominantes como la alcalinidad, la composición del sustrato y la adaptación del inóculo.

7.2.3.3. Análisis del waterfall plot (explicación local de una predicción)

El waterfall plot permite analizar cómo una observación específica alcanza su valor final de porcentaje de CH_4 a partir del valor esperado del modelo. En el ejemplo analizado, la temperatura presenta el mayor aporte positivo individual, seguida por el contenido de lignina, la alcalinidad y el TVS inicial (%), mientras que la concentración de NH_3 y ciertos parámetros geométricos del reactor generan contribuciones negativas moderadas sobre la predicción, como se observa en la Figura 7.9.

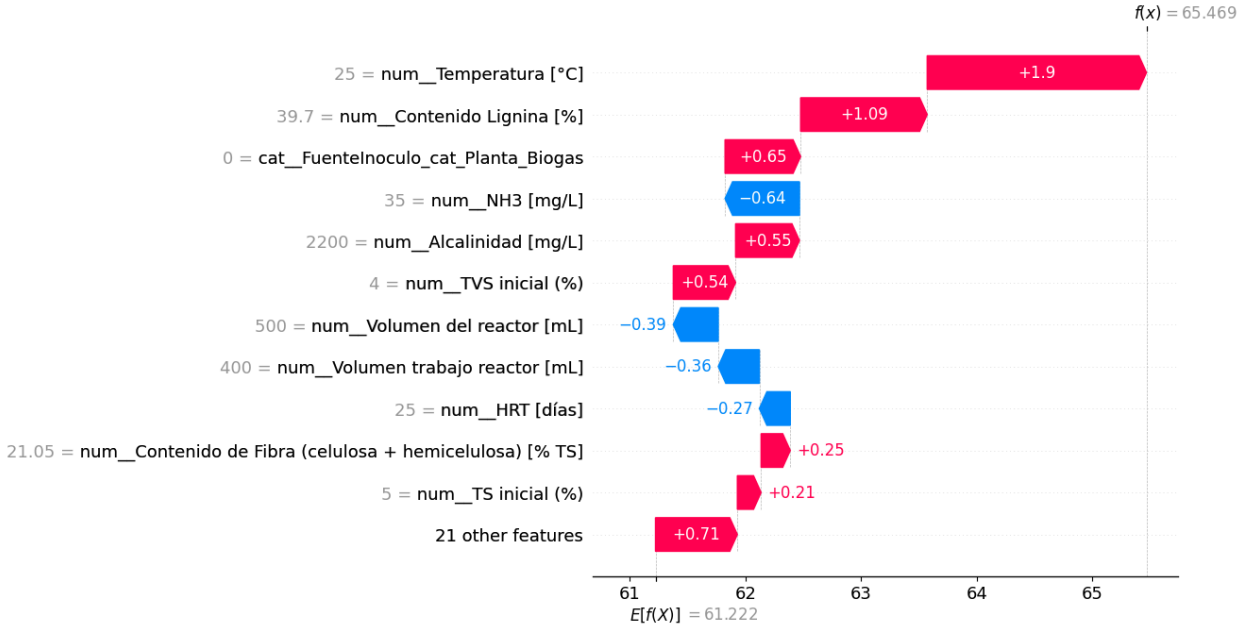

Figura 7.9: Waterfall Plot Porcentaje de remoción TVS.
Fuente: Elaboración propia.

Este comportamiento refleja que, a nivel local, condiciones térmicas adecuadas (rango mesofílico alto) pueden favorecer rutas metanogénicas más eficientes, incrementando la fracción de metano

del biogás. Asimismo, una alcalinidad elevada contribuye positivamente al mantener la estabilidad del pH y proteger la actividad de las arqueas metanogénicas, compensando parcialmente efectos inhibitorios asociados a la composición del sustrato.

Por otro lado, la concentración de NH_3 muestra un impacto negativo moderado, consistente con su conocido efecto inhibitorio cuando supera ciertos umbrales, mientras que variables como el volumen del reactor, el volumen de trabajo y el HRT presentan contribuciones negativas de menor magnitud, indicando un rol secundario en la determinación local del porcentaje de CH_4 frente a variables químicas y bioquímicas dominantes.

El análisis local confirma que la predicción del porcentaje de metano es el resultado de múltiples efectos compensatorios, donde ninguna variable domina de forma absoluta, sino que el valor final emerge de la interacción entre factores fisicoquímicos, composicionales y operacionales, lo que refuerza la capacidad del modelo para capturar dinámicas no lineales propias de sistemas de digestión anaerobia complejos.

7.2.3.4. Sintesis interpretativa

En conjunto, los resultados del análisis SHAP indican que el modelo de porcentaje de CH_4 captura adecuadamente la naturaleza compleja y multifactorial de la composición del biogás. A diferencia de la producción total, donde predominan variables asociadas a la cantidad de materia orgánica disponible y a la biomasa activa, la fracción de metano depende en mayor medida de condiciones de estabilidad fisicoquímica del sistema, características estructurales del sustrato y equilibrios bioquímicos internos, tales como la alcalinidad, la presencia de compuestos recalcitrantes y la temperatura de operación.

Esta mayor complejidad explicativa contribuye a entender por qué el modelo presenta un desempeño predictivo ligeramente inferior en comparación con la producción total de biogás, pero aun así resulta valioso para identificar tendencias operacionales, condiciones favorables para la metanogénesis y posibles restricciones asociadas a la calidad del sustrato, aportando información relevante para la optimización de la calidad del biogás producido.

7.2.4. Comparación de patrones de importancia entre modelos

El análisis comparativo de los resultados SHAP obtenidos para los tres modelos desarrollados —producción total de biogás, porcentaje de remoción de sólidos volátiles totales y porcentaje de CH_4 en el biogás— permite identificar diferencias estructurales en la forma en que las variables de entrada influyen sobre cada una de las salidas, así como comprender las razones subyacentes a las discrepancias observadas en el desempeño predictivo de los modelos.

En primer lugar, el modelo asociado a la producción total de biogás presenta una estructura de importancia de variables claramente dominada por parámetros relacionados con la cantidad de materia orgánica disponible y su accesibilidad, tales como el volumen de inóculo, los sólidos totales (TS), los sólidos volátiles totales iniciales (TVS) y el volumen de trabajo del reactor. En este caso, los valores SHAP muestran distribuciones amplias y coherentes, con tendencias relativamente claras en el sentido del impacto de las variables, lo que indica relaciones más estables y menos dependientes del contexto experimental. Esta característica explica el mejor desempeño global del modelo en términos de R^2 y errores de predicción, ya que la producción total de biogás responde a un balance acumulativo del proceso de digestión anaerobia (Breiman, 2001; Angelidaki et al., 2018).

Por su parte, el modelo de porcentaje de remoción de TVS exhibe una estructura intermedia. El análisis SHAP muestra que variables composicionales del sustrato (contenido de fibra, lignina, TVS inicial) y parámetros operacionales (OLR, alcalinidad, agitación) comparten niveles de importancia similares. A diferencia del caso anterior, ningún grupo de variables domina de manera absoluta la predicción, lo que refleja que la eficiencia de degradación de la materia orgánica depende de una interacción más compleja entre biodegradabilidad, condiciones ambientales y dinámica microbiana. Esta mayor dispersión en los valores SHAP se traduce en un desempeño predictivo moderadamente inferior al de la producción total de biogás, aunque aún consistente para análisis comparativos y evaluación de escenarios (Hastie et al., 2009; Guo et al., 2021).

En contraste, el modelo desarrollado para el porcentaje de CH_4 en el biogás presenta el patrón más distribuido y menos jerárquico en términos de importancia de variables. Los gráficos SHAP indican que factores como el contenido de lignina, la alcalinidad, el tipo de sustrato, la concentración de NH_3 y el pH inicial influyen de manera significativa, pero con impactos individuales de menor magnitud y con efectos altamente dependientes del contexto. Esto refleja la naturaleza intrínsecamente más compleja de la metanogénesis, la cual está gobernada por equilibrios metabólicos finos entre diferentes poblaciones microbianas y es altamente sensible a perturbaciones locales del sistema (De Clercq et al., 2020).

Desde una perspectiva transversal, el análisis SHAP permite concluir que la capacidad predictiva del modelo aumenta a medida que la variable de salida representa un fenómeno más agregado e integrador del proceso, y disminuye cuando la variable depende de mecanismos bioquímicos específicos y altamente interdependientes. En este sentido, la producción total de biogás constituye una señal más robusta y menos ruidosa, mientras que la fracción de metano representa una salida emergente de múltiples equilibrios internos, lo que incrementa la incertidumbre asociada a su predicción.

Finalmente, este análisis comparativo refuerza la validez del uso de técnicas de interpretabilidad como SHAP en estudios de digestión anaerobia, ya que no solo permiten identificar variables relevantes, sino también comprender por qué ciertos modelos funcionan mejor que otros y cuáles son las limitaciones estructurales asociadas a cada variable de salida. Esta comprensión resulta fundamental para una aplicación responsable y técnicamente informada de modelos de aprendizaje automático en sistemas biológicos complejos.

7.3. Análisis de sensibilidad del modelo

7.3.1. Concepto de análisis de sensibilidad en modelos de ML

El análisis de sensibilidad constituye una herramienta fundamental para evaluar cómo las variaciones en las variables de entrada afectan las predicciones generadas por un modelo predictivo. En el contexto de modelos de aprendizaje automático, este análisis permite identificar el grado de dependencia del modelo respecto a ciertas variables, así como detectar regiones del espacio de entrada donde pequeñas perturbaciones pueden generar cambios significativos en la salida del modelo (Saltelli et al., 2008).

A diferencia del análisis de importancia de variables —como el realizado mediante SHAP—, cuyo objetivo principal es cuantificar la contribución promedio de cada variable al resultado del modelo, el análisis de sensibilidad se enfoca en la respuesta dinámica del modelo ante variaciones controladas de los parámetros de entrada. En este sentido, mientras SHAP responde a la pregunta "qué variables son más relevantes", el análisis de sensibilidad permite abordar "qué tan robusta es la predicción frente a cambios en dichas variables" (Hastie et al., 2009).

En sistemas altamente no lineales y complejos como la digestión anaerobia, esta distinción resulta particularmente relevante. La producción de biogás depende de múltiples procesos bioquímicos interconectados —hidrólisis, acidogénesis, acetogénesis y metanogénesis— que responden de forma no lineal a variaciones en la composición del sustrato y en las condiciones operacionales (Appels et al., 2008). En consecuencia, un modelo predictivo puede presentar un buen desempeño global (alto R^2) y, aun así, mostrar una elevada sensibilidad ante cambios en variables específicas, lo que limita su aplicabilidad práctica si no se analiza adecuadamente este comportamiento.

Desde la perspectiva del aprendizaje automático, el análisis de sensibilidad también cumple un rol clave en la evaluación de la robustez y generalización del modelo. Modelos excesivamente sensibles a determinadas variables pueden estar capturando patrones específicos del conjunto de entrenamiento, aumentando el riesgo de sobreajuste y reduciendo su confiabilidad al extrapolar a nuevas condiciones experimentales (Breiman, 2001; Kuhn & Johnson, 2013).

En el presente estudio, el análisis de sensibilidad se emplea como un complemento al análisis de interpretabilidad basado en SHAP, con el objetivo de caracterizar cómo responden las predicciones del modelo Random Forest ante variaciones en las variables más influyentes. Este enfoque permite no solo evaluar la estabilidad del modelo desarrollado, sino también identificar variables críticas que requieren un mayor control experimental y operacional al momento de aplicar el modelo en contextos reales de digestión anaerobia.

7.3.2. Sensibilidad del modelo de producción total de biogás

Las variables operacionales desempeñan un rol central en la estabilidad y eficiencia del proceso de digestión anaerobia, por lo que resulta fundamental analizar cómo las variaciones en estos parámetros influyen en las predicciones generadas por el modelo Random Forest desarrollado. En este estudio, variables como el pH inicial, la temperatura de operación, el tiempo de retención hidráulica (HRT), la alcalinidad, la agitación y la velocidad de carga orgánica (OLR) fueron consideradas dentro del análisis de sensibilidad, dado su impacto directo sobre la actividad microbiana y la cinética del proceso.

El análisis de sensibilidad evidencia que el modelo presenta una respuesta relativamente estable frente a pequeñas variaciones en variables operacionales dentro de rangos típicos de operación. Esta estabilidad sugiere que el modelo ha logrado capturar relaciones generales del proceso, evitando una dependencia excesiva de condiciones puntuales específicas del conjunto de entrenamiento. En particular, variables como la temperatura y el pH inicial muestran una influencia moderada y coherente con la literatura, donde se ha reportado que la digestión anaerobia opera de manera óptima dentro de rangos relativamente estrechos, pero tolerantes a pequeñas fluctuaciones sin afectar drásticamente la producción de biogás (Appels et al., 2008).
En el caso del HRT, la sensibilidad del modelo refleja la importancia de este parámetro en la conversión de la materia orgánica, especialmente en sistemas discontinuos o semicontinuos. Variaciones en el HRT pueden modificar el equilibrio entre las distintas etapas del proceso anaerobio, afectando tanto la degradación de sólidos volátiles como la producción y composición del biogás. El comportamiento del modelo frente a cambios en esta variable sugiere que el Random Forest es capaz de captar estas interacciones no lineales, aunque con una sensibilidad controlada que evita predicciones abruptas ante variaciones moderadas del tiempo de retención (Batstone et al., 2002).

La alcalinidad y la agitación presentan una sensibilidad menor en comparación con otras variables operacionales, lo que resulta consistente con su rol principalmente regulador. Mientras la alcalinidad actúa como un sistema tampón que estabiliza el pH del reactor, la agitación favorece la homogeneización del sustrato y el contacto entre microorganismos y materia orgánica, sin constituir por sí sola un factor limitante directo en la producción de biogás dentro de los rangos evaluados (Chen et al., 2008).

En conjunto, el análisis de sensibilidad frente a variables operacionales indica que el modelo desarrollado presenta un comportamiento robusto y coherente con los principios del proceso de digestión anaerobia. Esta característica resulta especialmente relevante para su aplicación práctica, ya que sugiere que el modelo puede ser utilizado como herramienta de apoyo a la toma de decisiones sin requerir un control excesivamente rígido de todos los parámetros operacionales, siempre que estos se mantengan dentro de rangos técnicamente aceptables.

7.3.3. Sensibilidad del modelo de porcentaje de Remoción TVS

La remoción de sólidos volátiles totales en procesos de digestión anaerobia está fuertemente condicionada por la estabilidad fisicoquímica del sistema y por la actividad microbiana efectiva, más que exclusivamente por la composición inicial del sustrato. En este contexto, el análisis de sensibilidad del modelo Random Forest frente a variables operacionales y de control químico resulta fundamental para evaluar su capacidad de capturar los mecanismos que gobiernan la eficiencia de degradación de la fracción orgánica.

Los resultados obtenidos indican que el modelo presenta una sensibilidad elevada y consistente frente a la concentración de amonio (NH_3), el volumen de inóculo, la agitación y la alcalinidad, variables que concentran la mayor influencia sobre la predicción de la remoción de TVS. Este comportamiento es coherente con la literatura, donde se reconoce que el equilibrio entre carga nitrogenada, biomasa activa y condiciones de mezcla determina en gran medida la continuidad y eficiencia del proceso anaerobio (Chen et al., 2008; Yenigün & Demirel, 2013).

En particular, la concentración de NH_3 emerge como la variable más crítica desde el punto de vista de la sensibilidad del modelo. Incrementos en esta variable generan respuestas negativas claras en la remoción de TVS, reflejando el efecto inhibitorio del amoníaco sobre las poblaciones microbianas responsables de la degradación de la materia orgánica. El modelo penaliza de manera consistente escenarios con concentraciones elevadas de NH_3, lo que sugiere que ha internalizado adecuadamente este mecanismo inhibitorio no lineal.

El volumen de inóculo muestra una influencia positiva relevante, indicando que una mayor disponibilidad de biomasa activa favorece la hidrólisis y conversión de los sólidos volátiles, incrementando la eficiencia de remoción. De forma complementaria, la agitación presenta una sensibilidad positiva moderada, asociada a mejoras en la transferencia de masa y en el contacto sustrato–microorganismo, mientras que la alcalinidad actúa como un factor estabilizador que amortigua fluctuaciones de pH y favorece condiciones adecuadas para la actividad microbiana.
Las variables asociadas a la composición del sustrato, como el contenido de TVS inicial, la relación C/N, el contenido de lignina y la fracción de fibra, presentan una sensibilidad menor y más contextual en el modelo de remoción de TVS. Si bien estas variables influyen en la biodegradabilidad potencial del residuo, su efecto sobre la remoción efectiva aparece mediado

por las condiciones operacionales y químicas del sistema, lo que explica su menor jerarquía relativa en comparación con variables como NH_3 y alcalinidad.

En conjunto, el análisis de sensibilidad del modelo de remoción de TVS evidencia que la eficiencia de degradación de los sólidos volátiles depende principalmente del equilibrio fisicoquímico y biológico del reactor, más que de la composición inicial del sustrato por sí sola. Este resultado refuerza la utilidad del modelo como herramienta para identificar condiciones operacionales críticas y para apoyar el diseño de estrategias de control orientadas a maximizar la estabilidad y eficiencia del proceso de digestión anaerobia.

7.3.4. Sensibilidad del modelo de porcentaje de CH_4

El análisis de sensibilidad del modelo Random Forest desarrollado para la predicción del porcentaje de metano en el biogás permitió evaluar cómo variaciones en las variables de entrada influyen en la respuesta del modelo, entregando información clave sobre la estabilidad y robustez de las predicciones asociadas a la composición del gas producido.

A diferencia de la producción total de biogás, la fracción de CH_4 mostró una mayor sensibilidad frente a cambios combinados en variables fisicoquímicas y composicionales del sistema, más que frente a variaciones aisladas en parámetros hidráulicos u operacionales. En particular, el modelo evidenció una dependencia relevante de variables asociadas a la calidad del sustrato, como el contenido de lignina y el TVS inicial (%), así como de condiciones de estabilidad del reactor, destacando la alcalinidad y, en menor medida, la concentración de NH_3. Este comportamiento es consistente con la literatura, que señala que la metanogénesis es una etapa altamente sensible del proceso de digestión anaerobia, dependiente del equilibrio metabólico entre bacterias acidogénicas, acetogénicas y arqueas metanogénicas (Angelidaki et al., 2011).

El análisis de sensibilidad reveló que variaciones en la alcalinidad y en la temperatura pueden inducir cambios apreciables en la fracción de metano predicha, incluso cuando la producción total de biogás se mantiene relativamente estable. Esto se explica porque la producción de CH_4 no solo depende de la cantidad de sustrato degradado, sino también de la eficiencia con que los intermediarios metabólicos, como el hidrógeno y los ácidos grasos volátiles, son convertidos en metano. Alteraciones en estas condiciones pueden favorecer rutas metabólicas alternativas o generar desbalances parciales que afectan directamente la composición del gas (De Clercq et al., 2020).

Asimismo, el modelo mostró una sensibilidad contextual frente a variables asociadas al tipo de sustrato y al estado del sistema, más que al volumen de inóculo en sí mismo. En particular, la presencia de fracciones lignocelulósicas recalcitrantes, representadas por el contenido de lignina, condiciona la disponibilidad de carbono fácilmente convertible a metano, lo que se traduce en respuestas no lineales del porcentaje de CH_4 bajo diferentes escenarios operacionales. Este

comportamiento explica la dispersión observada en los valores SHAP y refuerza la dependencia del porcentaje de metano respecto de la interacción entre composición del sustrato y condiciones internas del reactor (Hastie et al., 2009).
Desde una perspectiva metodológica, esta mayor sensibilidad del modelo para el porcentaje de CH_4 explica, en parte, por qué esta variable presentó un desempeño predictivo más limitado en comparación con la producción total de biogás. La composición del biogás constituye una variable emergente, altamente dependiente de equilibrios bioquímicos internos y de procesos microbianos dinámicos que no siempre se encuentran completamente representados en datasets experimentales de escala limitada (Breiman, 2001).

No obstante, el análisis de sensibilidad realizado permite utilizar el modelo como una herramienta exploratoria valiosa, capaz de identificar rangos operacionales y composicionales favorables para maximizar la fracción de metano, así como de advertir escenarios en los que pequeñas variaciones en la calidad del sustrato o en la estabilidad fisicoquímica del sistema podrían generar cambios relevantes en la calidad del biogás producido. En este sentido, el modelo no debe interpretarse como un sustituto de la experimentación, sino como un apoyo para la toma de decisiones preliminares y el diseño de ensayos más focalizados.

7.3.5. Comparación de sensibilidad entre variables de salida

La comparación global del análisis de sensibilidad entre los tres modelos desarrollados —producción total de biogás, porcentaje de remoción de sólidos volátiles totales (% Remoción TVS) y porcentaje de CH_4 en el biogás— permite establecer diferencias claras en la forma en que cada variable responde a las condiciones del sustrato y del proceso, así como en la robustez de las predicciones generadas por los modelos Random Forest.

En primer lugar, la producción total de biogás presentó el comportamiento más estable desde el punto de vista de la sensibilidad del modelo. Las variaciones en las variables de entrada generaron cambios relativamente graduales y consistentes en la predicción, lo que indica que esta variable actúa como una medida integrada del proceso de digestión anaerobia. Al reflejar la suma de múltiples rutas metabólicas y etapas bioquímicas, la producción total de biogás tiende a suavizar la variabilidad asociada a fenómenos puntuales, reduciendo la sensibilidad extrema del modelo ante pequeñas perturbaciones en las condiciones operacionales (Breiman, 2001; Angelidaki et al., 2011).

En contraste, el porcentaje de remoción de TVS mostró una sensibilidad intermedia. El modelo evidenció respuestas más pronunciadas frente a cambios en variables relacionadas con la composición del sustrato, la carga orgánica y ciertos parámetros operacionales, lo que refleja la dependencia directa de esta variable respecto de la biodegradabilidad del material alimentado y

de la eficiencia global del proceso. Sin embargo, esta sensibilidad se mantuvo dentro de rangos controlables, permitiendo identificar tendencias generales sin que pequeñas variaciones en los datos de entrada generaran inestabilidad en las predicciones (Hastie et al., 2009).

Por su parte, el porcentaje de CH_4 en el biogás fue la variable que presentó la mayor sensibilidad global. A diferencia de la producción total, el modelo mostró una fuerte dependencia de variables fisicoquímicas y composicionales internas del sistema, destacando el contenido de lignina del sustrato, la alcalinidad y, de manera contextual, la temperatura de operación y la concentración de NH_3. Esta elevada sensibilidad se asocia a la naturaleza compleja de la metanogénesis, etapa final de la digestión anaerobia, que depende de equilibrios metabólicos finos entre distintas poblaciones microbianas y de condiciones ambientales específicas. Como resultado, pequeñas variaciones en estas variables pueden generar cambios significativos en la fracción de metano predicha, incrementando la incertidumbre del modelo para esta variable (De Clercq et al., 2020).

Desde una perspectiva comparativa, los resultados del análisis de sensibilidad explican coherentemente las diferencias observadas en el desempeño predictivo de los modelos. Las variables más agregadas y menos dependientes de equilibrios bioquímicos internos, como la producción total de biogás, tienden a ser más robustas y menos sensibles, mientras que variables asociadas a procesos metabólicos específicos y condicionadas por la calidad del sustrato, como la composición del biogás, presentan una mayor susceptibilidad a la variabilidad experimental. Este comportamiento ha sido reportado de manera consistente en estudios previos que aplican modelos de aprendizaje automático a procesos de digestión anaerobia (Wang et al., 2020; Hassan et al., 2025).

En conjunto, la comparación global del análisis de sensibilidad refuerza la importancia de interpretar los resultados del modelo en función de la naturaleza de cada variable de salida. Mientras que el modelo puede utilizarse con mayor confianza para la estimación del rendimiento global de biogás y la eficiencia de remoción de materia orgánica, la predicción del porcentaje de CH_4 debe considerarse como una herramienta orientativa, útil para análisis exploratorios y comparación de escenarios, pero sujeta a una mayor incertidumbre inherente al carácter multifactorial y dinámico del proceso biológico subyacente.

7.4. Discusión integrada de los resultados

La integración de los resultados obtenidos a lo largo del desarrollo del modelo predictivo permite evaluar de manera conjunta el cumplimiento de los objetivos específicos del estudio y el aporte real del enfoque basado en Random Forest al análisis del proceso de digestión anaerobia de residuos cerveceros. En este sentido, los resultados numéricos de desempeño, el análisis de

sensibilidad y la interpretabilidad mediante SHAP ofrecen una visión complementaria del comportamiento del sistema, más allá de la simple capacidad predictiva del modelo.

En primer lugar, los resultados confirman que la producción total de biogás es la variable que presenta el comportamiento más robusto y predecible dentro del conjunto de salidas analizadas. El alto valor de R^2 alcanzado por el modelo optimizado, junto con errores MAE y RMSE acotados en relación con el rango de la variable, indica que el algoritmo es capaz de capturar de manera efectiva las relaciones no lineales entre las características del sustrato, las condiciones operacionales y el rendimiento global del proceso. Esta estabilidad se ve reforzada por el análisis de sensibilidad, el cual mostró una respuesta gradual del modelo frente a variaciones en las variables de entrada, coherente con el carácter integrado de la producción total de biogás como indicador del proceso (Breiman, 2001; Angelidaki et al., 2011).

Por su parte, la remoción de sólidos volátiles totales (% Remoción TVS) evidenció un desempeño intermedio tanto en términos predictivos como de sensibilidad. Si bien el modelo logró reproducir tendencias generales de eficiencia del proceso, se observó una mayor dispersión en las predicciones, reflejada en valores de error superiores a los obtenidos para la producción de biogás. Esta diferencia puede atribuirse a la dependencia directa de la remoción de TVS respecto de la biodegradabilidad del sustrato y del equilibrio fisicoquímico del sistema, particularmente en relación con la concentración de NH_3, la alcalinidad y parámetros operacionales como la agitación. La heterogeneidad intrínseca de los residuos cerveceros, que pueden presentar variaciones significativas en su composición incluso bajo condiciones experimentales similares, contribuye adicionalmente a esta variabilidad (Hastie et al., 2009). No obstante, el modelo demostró ser útil para comparar escenarios operacionales y evaluar el impacto relativo de distintas variables del proceso.

En contraste, el porcentaje de CH_4 en el biogás fue la variable que presentó el mayor grado de complejidad en su modelación. A pesar de alcanzar valores elevados de R^2 en el modelo optimizado, el análisis integrado revela que esta aparente alta capacidad explicativa debe interpretarse con cautela. El análisis de sensibilidad y los resultados SHAP mostraron una marcada dependencia de variables asociadas a la calidad química del sustrato y a la estabilidad interna del sistema, destacando el contenido de lignina y la alcalinidad como factores dominantes, junto con la temperatura y la concentración de NH_3 como variables moduladoras del proceso. Este comportamiento refleja la naturaleza altamente sensible de la metanogénesis, etapa final de la digestión anaerobia, que depende de equilibrios metabólicos finos entre comunidades microbianas y de la accesibilidad real del carbono biodegradable. Este patrón es consistente con la literatura, que señala que la composición del biogás está fuertemente condicionada por la recalcitrancia del sustrato y por la capacidad del sistema para mantener condiciones estables favorables a las arqueas metanogénicas (De Clercq et al., 2020).

La integración de los análisis SHAP permitió además vincular el desempeño predictivo del modelo con fundamentos teóricos del proceso de digestión anaerobia. Variables como el contenido de lignina, la alcalinidad, la carga orgánica y el tiempo de retención hidráulica emergieron de manera consistente como factores clave, lo que coincide con el conocimiento clásico del proceso y refuerza la validez del modelo desde una perspectiva fisicoquímica y biológica. Este resultado es particularmente relevante, ya que demuestra que el modelo no solo aprende patrones estadísticos, sino que internaliza relaciones coherentes con la dinámica real del sistema, fortaleciendo su potencial uso como herramienta de apoyo a la toma de decisiones (Lundberg & Lee, 2017).

En conjunto, la discusión integrada de los resultados pone de manifiesto que el enfoque adoptado cumple con los objetivos planteados en el estudio. El uso de Random Forest permitió identificar variables relevantes, desarrollar modelos predictivos con un nivel adecuado de precisión y analizar la sensibilidad del sistema frente a distintas condiciones operacionales. Al mismo tiempo, los resultados evidencian las limitaciones inherentes a la modelación de procesos biológicos complejos, especialmente cuando se intenta predecir variables altamente dependientes de equilibrios microbianos dinámicos y de la calidad estructural del sustrato. En este contexto, el modelo desarrollado debe entenderse como una herramienta complementaria a la experimentación tradicional, capaz de apoyar el diseño y la optimización de procesos, pero no de reemplazar completamente el análisis experimental detallado.

8. CONCLUSIONES

8.1. Conclusión general

El presente estudio permitió desarrollar un modelo predictivo basado en Random Forest para estimar variables clave del proceso de digestión anaerobia de residuos cerveceros, logrando capturar relaciones no lineales entre las variables del sistema. El modelo presentó su mejor desempeño en la predicción del porcentaje de metano en el biogás, alcanzando un coeficiente de determinación $R^2 = 0,856$, seguido por la producción total de biogás ($R^2 = 0,749$) y la remoción de sólidos volátiles ($R^2 = 0,669$). Estos resultados evidencian la capacidad del modelo para representar el comportamiento del sistema, así como diferencias en la dificultad de predicción asociadas a la naturaleza de cada variable.

8.2. Cumplimiento de objetivos específicos

8.2.1. Objetivo específico 1: Identificar las variables más relevantes que influyen en la producción de biogás a partir de residuos cerveceros mediante digestión anaerobia

Se identificaron las principales variables que influyen en la producción de biogás a partir de residuos cerveceros, destacando la relación C/N, el contenido lignocelulósico, la temperatura, el pH y la carga orgánica como factores determinantes del proceso. Estas variables fueron incorporadas en el modelo y demostraron ser relevantes en la predicción de las variables objetivo, en coherencia con el análisis desarrollado en el estudio.

8.2.2. Objetivo específico 2: Desarrollar un modelo predictivo, basado en Random Forest, enfocado en el rendimiento de producción de biogás bajo distintas condiciones del sustrato y del proceso

Se desarrolló un modelo predictivo basado en Random Forest capaz de estimar la producción total de biogás, la remoción de sólidos volátiles y el contenido de metano. El modelo presentó un desempeño diferenciado según la variable de salida, obteniendo su mejor ajuste en la predicción del porcentaje de metano ($R^2 = 0,856$), seguido por la producción de biogás ($R^2 = 0,749$) y la remoción de TVS ($R^2 = 0,669$). Estas diferencias también se reflejan en las métricas de error (MAE y RMSE), evidenciando una mayor precisión en la predicción de variables más estables y acotadas.

8.2.3. Objetivo específico 3: Realizar un análisis de sensibilidad del modelo desarrollado

El análisis de sensibilidad permitió evaluar la influencia relativa de las variables de entrada sobre las variables objetivo del modelo. Los resultados evidenciaron que las variables asociadas a la composición del sustrato y a las condiciones operacionales tienen un impacto significativo en el rendimiento del proceso, permitiendo identificar los factores más influyentes y comprender el comportamiento del sistema de digestión anaerobia.

9. BIBLIOGRAFÍA

Abid, A., Farooq, A., & Zou, J. (2019). Gradio: Hassle-free sharing of machine learning models. *Journal of Machine Learning Research, 20*(1), 1–5.

Ahmad, M., Yousaf, B., & Rehman, A. (2020). Applications of machine learning for process control: A critical review. *Chemical Engineering Research and Design, 153*, 511–525.

Al Seadi, T., Rutz, D., Prassl, H., Köttner, M., Finsterwalder, T., Volk, S., & Janssen, R. (2008). *Biogas handbook*. University of Southern Denmark. https://www.task37.ieabioenergy.com/publications/biogas-handbook.html

Aliyu, D. S., & Bala, M. (2011). Brewer's spent grain: A review of its potentials and applications. *African Journal of Biotechnology, 10*(3), 324–331. https://doi.org/10.5897/AJBX10.009

Angelidaki, I., & Ahring, B. K. (1994). Anaerobic thermophilic digestion of manure at different ammonia loads: Effect of temperature. *Water Research, 28*(3), 727–731.

Angelidaki, I., Ellegaard, L., & Ahring, B. K. (2006). Operational strategies for thermophilic anaerobic digestion of organic fraction of municipal solid waste in continuously stirred tank reactors. *Environmental Technology, 27*(8), 855–861. https://doi.org/10.1080/09593332708618703

Angelidaki, I., Karakashev, D., Batstone, D. J., Plugge, C. M., & Stams, A. J. M. (2011). Biomethanation and its potential. *Methods in Enzymology, 494*, 327–351.

Angelidaki, I., Treu, L., Tsapekos, P., Luo, G., Campanaro, S., Wenzel, H., & Kougias, P. G. (2018). Biogas upgrading and utilization: Current status and perspectives. *Biotechnology Advances, 36*(2), 452–466.

Appels, L., Baeyens, J., Degrève, J., & Dewil, R. (2008). Principles and potential of the anaerobic digestion of waste-activated sludge. *Progress in Energy and Combustion Science, 34*(6), 755–781. https://doi.org/10.1016/j.pecs.2008.06.002

Batstone, D. J., Keller, J., Angelidaki, I., Kalyuzhnyi, S. V., Pavlostathis, S. G., Rozzi, A., Sanders, W. T. M., Siegrist, H., & Vavilin, V. A. (2002). Anaerobic Digestion Model No. 1 (ADM1). *Water Science and Technology, 45*(10), 65–73.

Beltramo, T., Klocke, M., & Hitzmann, B. (2019). Prediction of biogas production using GA and ACO input feature selection for ANN model. *Information Processing in Agriculture, 6*(3), 349–356.

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*, 281–305.

Bi, S., Yao, Q., Han, L., Ma, Y., Xu, Y., Yu, C., ... & Qiu, Y. (2019). Food waste, brewery waste, and agricultural residues as co-substrates for anaerobic digestion: A review. *Processes, 7*(7), 441. https://doi.org/10.3390/pr7070441

Braun, F., Reif, D., & Schaumann, G. E. (2022). Treatment of brewery wastewater: A review. *Bioresource Technology Reports, 19*, 101131. https://doi.org/10.1016/j.biteb.2022.101131

Breiman, L. (1996). Bagging predictors. *Machine Learning, 24*(2), 123–140.

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brownlee, J. (2020). *Train-Test Split for Evaluating Machine Learning Algorithms*. Machine Learning Mastery.

Camacho, J., Ferrer, A., & Picó, J. (2019). Data analytics for the efficient control of industrial processes. *Engineering Applications of Artificial Intelligence, 82*, 179–192.

Cebada Cervecera. (2025). Producción mundial de cerveza: evolución por continente. https://cebadacervecera.com.ar/cerveza-produccion-mundial-y-por-continente/

Chen, Y., Cheng, J. J., & Creamer, K. S. (2008). Inhibition of anaerobic digestion process: A review. *Bioresource Technology, 99*(10), 4044–4064.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Côté, P.-O., Nikanjam, A., Ahmed, N., Humeniuk, D., & Khomh, F. (2024). Data Cleaning and Machine Learning: A Systematic Literature Review. *Automated Software Engineering, 31*, 54.

De Clercq, D., Wen, Z., Fan, F., & Caicedo, L. (2019). Biomethane production potential from agricultural waste: A review. *Renewable and Sustainable Energy Reviews, 107*, 369–386.

De Clercq, D., Wen, Z., Fan, F., & Caicedo, L. (2020). Biogas production prediction from agricultural residues using machine learning models. *Renewable Energy, 146*, 109–120.

Demirel, B., & Scherer, P. (2008). The roles of acetotrophic and hydrogenotrophic methanogens during anaerobic conversion of biomass to methane: A review. *Reviews in Environmental Science and Biotechnology, 7*(2), 173–190. https://doi.org/10.1007/s11157-008-9131-1

Dietterich, T. G. (2000). An experimental comparison of three ensemble methods: bagging, boosting, and randomization. *Machine Learning, 40*(2), 139–157.

European Commission. (2020). *A new Circular Economy Action Plan: For a cleaner and more competitive Europe*. https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A52020DC0098

Fillaudeau, L., Blanpain-Avet, P., & Daufin, G. (2006). Water, wastewater and waste management in brewing industries. *Journal of Cleaner Production, 14*(5), 463–471. https://doi.org/10.1016/j.jclepro.2005.01.002

Figura 1. Etapas del proceso de digestión anaerobia. (s. f.). ResearchGate. https://www.researchgate.net/figure/Figura-1-Etapas-del-proceso-de-digestion-anaerobia_fig1_324970435

García, L., et al. (2021). Gestión de residuos orgánicos en la cervecería Antares: diagnóstico y oportunidades. *Universidad Nacional de Mar del Plata*. https://www.mdp.edu.ar/antares-residuos

García-González, M. C., & Vanotti, M. B. (2015). Recovery of ammonia from swine manure using gas-permeable membranes: Effect of aeration. *Journal of Environmental Management, 152*, 19–26. https://doi.org/10.1016/j.jenvman.2015.01.048

Gómez, M., & Morales, D. (2020). Turismo cervecero en Latinoamérica: oportunidades y desafíos para las microcervecerías. *Revista Estudios y Perspectivas en Turismo, 29*(4), 1021–1038.

Guo, X., Trably, E., Latrille, E., Carrère, H., & Steyer, J. P. (2021). Predicting anaerobic digestion performance using machine learning techniques: A critical review. *Bioresource Technology, 322*, 124537.

Hassan, M., Liu, Y., Khan, M. A., & Zhang, R. (2025). Application of machine learning models for biogas production prediction: A comparative study. *Journal of Cleaner Production, 401*, 139719.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

Huang, Y., Liu, H., Xu, X., & Zheng, X. (2022). Application of Random Forest in anaerobic digestion process modeling. *Bioresource Technology Reports, 18*, 101062.

Hyndman, R., & Koehler, A. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688.

IPCC. (2021). *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change.* https://www.ipcc.ch/report/ar6/wg1/

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.

Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.

Kunstmann. (2022). *Informe de gestión ambiental y residuos orgánicos 2021–2022*. https://www.kunstmann.cl/sustentabilidad

Lantz, B. (2019). *Machine Learning with R* (3rd ed.). Packt.

Li, Y., Park, S. Y., & Zhu, J. (2016). Solid-state anaerobic digestion for methane production from organic waste. *Renewable and Sustainable Energy Reviews, 15*(1), 821–826.

Loh, W.-Y. (2011). Classification and regression trees. *WIREs Data Mining and Knowledge Discovery, 1*(1), 14–23.

López, C., et al. (2020). Evaluación de residuos cerveceros en plantas artesanales del sur de Chile. *Revista Chilena de Ingeniería Ambiental.*

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774.

Ma, X., et al. (2021). Interpretable machine learning for biogas production prediction. *Renewable Energy, 177*, 98–109.

Mao, C., Feng, Y., Wang, X., & Ren, G. (2015). Review on research achievements of biogas from anaerobic digestion. *Renewable and Sustainable Energy Reviews, 45*, 540–555.

Mata-Álvarez, J., Dosta, J., Romero-Güiza, M. S., Fonoll, X., Peces, M., & Astals, S. (2014). A critical review on anaerobic co-digestion achievements between 2010 and 2013. *Renewable and Sustainable Energy Reviews, 36*, 412–427. https://doi.org/10.1016/j.rser.2014.04.039

Ministerio del Medio Ambiente. (2023). *Gestión de residuos orgánicos en microcervecerías: diagnóstico y oportunidades.* https://mma.gob.cl/publicaciones/gestion-residuos-microcervecerias

Molnar, C. (2022). *Interpretable Machine Learning.*

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis*. Wiley.

Mussatto, S. I., Dragone, G., & Roberto, I. C. (2006). Brewers' spent grain: Generation, characteristics and potential applications. *Journal of Cereal Science, 43*(1), 1–14. https://doi.org/10.1016/j.jcs.2005.06.001

Nasir, I. M., Ghazi, T. I. M., & Omar, R. (2015). Artificial intelligence modeling of biogas production: A review. *Renewable and Sustainable Energy Reviews, 52*, 1240–1251.

Okonkwo, U. C., Onokpite, E., & Onokwai, A. O. (2016). Comparative study of the optimal ratio of biogas production from various organic wastes and weeds for digester/restarted digester. *Journal of King Saud University – Engineering Sciences.*

Pan, J., et al. (2022). Application of machine learning methods for optimization of anaerobic digestion systems. *Bioresource Technology, 344*, 126–135.

Papirio, S., Taherzadeh, M. J., & Pirozzi, F. (2023). Application of anaerobic co-digestion of brewery by-products: Current status and perspectives. *Renewable and Sustainable Energy Reviews, 176*, 113163. https://doi.org/10.1016/j.rser.2023.113163

Patel, R. K., Tripathi, S., & Kumar, S. (2022). Application of artificial intelligence techniques for anaerobic digestion process modeling: A review. *Biochemical Engineering Journal, 183*, 108457. https://doi.org/10.1016/j.bej.2022.108457

Pesta, C., Muster-Slawitsch, B., Kriechbaum, M., Schnitzer, H., & Narodoslawsky, M. (2006). Anaerobic digestion of pretreated industrial residues and their energetic process integration. *Energies, 13*(13), 3275. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7318785

Ritchie, H., & Roser, M. (2023). Greenhouse gas emissions by gas, World, 1850 to 2023. *Our World in Data.* https://ourworldindata.org/grapher/ghg-emissions-by-gas

Saltelli, A., Ratto, M., Andres, T., Campolongo, F., Cariboni, J., Gatelli, D., Saisana, M., & Tarantola, S. (2008). *Global Sensitivity Analysis: The Primer.* Wiley.

Singh, R., Yadav, V., & Kumar, S. (2018). Artificial neural networks for predicting biogas production from anaerobic digestion: A review. *Renewable and Sustainable Energy Reviews, 81*, 1237–1252. https://doi.org/10.1016/j.rser.2017.08.031

Szaja, A., Wystalska, K., Karwowska, E., & Pajdak-Stós, A. (2020). The effect of brewery spent grain application on biogas yields and kinetics in co-digestion with sewage sludge. *PeerJ, 8*, e10590. https://doi.org/10.7717/peerj.10590

Szot. (2020). *Reporte de sostenibilidad de Cervecería Szot.* https://cervezaszot.cl/sustentabilidad/

Taherzadeh, M. J., & Karimi, K. (2008). Pretreatment of lignocellulosic wastes to improve ethanol and biogas production: A review. *International Journal of Molecular Sciences, 9*(9), 1621–1651.

Triolo, J. M., Sommer, S. G., Møller, H. B., Weisbjerg, M. R., & Jiang, X. Y. (2011). A new algorithm to characterize biodegradability of biomass during anaerobic digestion: Influence of lignin concentration on methane production potential. *Bioresource Technology, 102*(20), 9395–9402.

United States Environmental Protection Agency (US EPA). (2023). *Understanding global warming potentials.* https://www.epa.gov/ghgemissions/understanding-global-warming-potentials

Vitanza, C., Cristiano, G., & Milani, M. (2016). Biovalorization of brewery waste by applying anaerobic digestion: A case study. *Energy Procedia, 101*, 120–127. https://doi.org/10.1016/j.egypro.2016.11.016

Wainaina, S., Awasthi, M. K., Wong, J. W. C., Kumar, S., & Taherzadeh, M. J. (2021). Effect of temperature and bagasse addition on the anaerobic digestion of food waste: Methane yield and microbial dynamics. *Journal of Environmental Management, 285*, 112138. https://doi.org/10.1016/j.jenvman.2021.112138

Wainaina, S., et al. (2021). Enhancing anaerobic digestion of lignocellulosic biomass: Operational strategies and process optimization. *Bioresource Technology, 333*, 125–214.

Wang, Y., Li, G., Chi, Y., & Chen, J. (2020). Machine learning-based prediction of biogas production and methane content in anaerobic digestion: A review. *Energy, 214*, 118856.

Ward, A. J., Hobbs, P. J., Holliman, P. N., & Jones, D. L. (2008). Optimisation of the anaerobic digestion of agricultural resources. *Bioresource Technology, 99*(17), 7928–7940.

Weiland, P. (2010). Biogas production: current state and perspectives. *Applied Microbiology and Biotechnology, 85*(4), 849–860. https://doi.org/10.1007/s00253-009-2246-7

Yadvika, S., Sreekrishnan, T. R., Kohli, S., & Rana, V. (2004). Enhancement of biogas production from solid substrates using different techniques – a review. *Bioresource Technology, 95*(1), 1–10.

Yenigün, O., & Demirel, B. (2013). Ammonia inhibition in anaerobic digestion: A review. *Process Biochemistry, 48*(5–6), 901–911.

Zhang, L., Chen, Y., & Wang, Z. (2020). Prediction of biogas production from brewery wastes using artificial neural networks. *Journal of Cleaner Production, 258*, 120573. https://doi.org/10.1016/j.jclepro.2020.120573

Zhang, L., Lee, Y.-W., & Jahng, D. (2011). Anaerobic co-digestion of food waste and piggery wastewater: Focusing on the role of trace elements. *Bioresource Technology, 102*(8), 5048–5059.

Zhang, L., et al. (2020). Data-driven modeling and optimization of anaerobic digestion processes. *Energy Conversion and Management, 210*, 112–118.